

Framework metodológico para la reconstrucción de estructuras relacionales compactas a partir de representaciones latentes de modelos profundos

Resumen

Este trabajo propone un framework metodológico agnóstico al dominio que transforma la representación latente aprendida por un modelo profundo en una hipótesis relacional compacta, interpretable y evaluable. A diferencia de los modelos matemáticos tradicionales —rígidos y dependientes de supuestos predefinidos— y de los modelos profundos —opacos y cuya interpretación se limita al análisis de importancia de variables o a la recuperación de circuitos internos—, el framework propone una transformación intermedia donde la información aprendida se convierte progresivamente en estructuras simbólicas comparables. La validación se realiza sobre un caso de estudio concreto (series temporales de índices espectrales derivados de Sentinel-2), pero el enfoque está diseñado para generalizar a cualquier dominio donde existan relaciones multivariadas complejas, tales como minería, IoT, visión computacional, entre otros. Los resultados preliminares, sobre un ensamble de 50 modelos, sugieren invarianza espectral macroscópica y estabilidad de roles nodales, sugiriendo que la estructura relacional reconstruida trasciende la variabilidad estocástica del entrenamiento.

1. Introducción

1.1. Contexto

En numerosos problemas reales, los modelos profundos —en particular los basados en arquitecturas Transformer— alcanzan un desempeño predictivo superior al de los modelos matemáticos clásicos. Sin embargo, su naturaleza de caja negra impide entender *por qué* producen una salida dada, lo cual limita su adopción en dominios donde la interpretabilidad es crítica.

La mayoría de los métodos de explicabilidad (XAI) existentes se limitan a:

- Atribuir importancia marginal a variables de entrada (SHAP, LIME).
- Visualizar mapas de atención como heatmaps.
- Recuperar circuitos internos de capas y cabezas.

- Inyectar grafos causales conocidos previamente en la arquitectura.

Ninguno de estos enfoques convierte la representación latente en una **hipótesis relacional compacta** que pueda compararse, validarse y generalizarse entre dominios.

1.2. El problema

La atención de los Transformers es además **inestable**: pequeñas variaciones en la semilla de inicialización producen matrices de atención numéricamente distintas, aun cuando el desempeño predictivo sea equivalente. Esto invalida las explicaciones basadas en un único entrenamiento y exige un enfoque estadístico de consenso.

1.3. La propuesta

Se presenta un framework que:

1. Toma la representación latente de un modelo profundo arbitrario.
2. La transforma en un grafo dirigido ponderado.
3. Extrae una hipótesis relacional compacta.
4. La valida mediante estabilidad estadística y perturbación.

La interpretabilidad no busca una única verdad estática, sino una **hipótesis relacional de consenso** robusta frente a la variabilidad estocástica del entrenamiento.

2. Arquitectura: del Transformer estándar al ConvTransformer de Índices

2.1. Limitaciones del Transformer estándar

Un Transformer estándar, tal como se utiliza en procesamiento de lenguaje natural o en visión por computadora (ViT), aplica la atención entre *tokens* que típicamente representan posiciones espaciales (parches de una imagen) o posiciones en una secuencia (palabras en una frase). En problemas multivariantes donde el objetivo es modelar dependencias entre variables —no entre posiciones— esta arquitectura presenta dos limitaciones:

1. La atención se diluye entre miles de tokens espaciales, ocultando las relaciones entre variables.
2. No existe una matriz de atención $A \in \mathbb{R}^{n \times n}$ explícita entre variables que pueda extraerse y analizarse.

2.2. El ConvTransformer de Índices

El modelo utilizado en este trabajo (Figura 1) modifica el Transformer estándar en tres aspectos clave para producir una matriz de atención explícita entre variables:




Figura 1: Arquitectura del ConvTransformer de Índices (adaptada específicamente al caso de estudio). La entrada son n índices multiespectrales ($n = 12$ en el caso de estudio). Cada índice se procesa de forma independiente con el mismo encoder convolucional compartido, se proyecta a un espacio latente de dimensión $d = 128$, y se aplica Multi-Head Attention entre los n índices —no entre posiciones espaciales— produciendo una matriz de atención $A \in \mathbb{R}^{n \times n}$.

1. **Tokens = variables:** cada uno de los n índices (o sensores, o variables de proceso) se trata como un token independiente. La dimensión n es configurable y no está fijada al dominio agrícola.
2. **Encoder convolucional por token:** cada índice, de dimensiones $H \times W$, se procesa independientemente con un bloque **Conv2D** 3×3 (**stride=2**) que reduce la resolución espacial por un factor de 4 y extrae características locales.
3. **Proyección a espacio latente:** las características convolucionales de cada índice se aplanan y proyectan a un espacio de embedding de dimensión $d = 128$ mediante una capa lineal.
4. **Multi-Head Attention entre índices:** se aplica MHA con $h = 4$ cabezas sobre los n tokens. La atención se calcula *entre índices*, no entre posiciones espaciales ni entre timesteps. Esto produce explícitamente una matriz $A \in \mathbb{R}^{n \times n}$ por cada cabeza y capa.
5. **Decoder convolucional:** la salida del Transformer se decodifica con **ConvTranspose2D** 3×3 (upsampling $4 \times$) seguido de interpolación bicúbica para reconstruir la resolución original $H \times W$.

2.3. Por qué esta estructura

La arquitectura está diseñada para que el modelo **aprenda relaciones entre variables** y que dichas relaciones sean **extraíbles** como una matriz A interpretable. Si la atención se aplicara entre posiciones espaciales (como en ViT), se obtendría una matriz de tamaño $HW \times HW$, inmanejable y sin significado relacional claro entre variables. Al aplicar la atención entre los n índices, A tiene tamaño $n \times n$ y cada celda A_{ij} representa cuánto el índice i atiende al índice j al producir su predicción.

Esta arquitectura es **agnóstica al dominio**: los n tokens pueden ser índices vegetacionales, sensores IoT, variables de proceso minero o parámetros de una máquina industrial. Lo único que se requiere es que cada variable tenga una representación espacial o tabular procesable por el encoder.

2.4. Agregación: attention rollout

El modelo produce $L \times h$ matrices de atención (una por capa y cabeza). Para obtener una única matriz A que represente al modelo completo, se emplea el método de *attention rollout* [7]:

$$\tilde{A} = \prod_{\ell=1}^L (\alpha I + (1 - \alpha) \bar{A}_\ell)$$

donde $\bar{A}_\ell$ es el promedio de las h cabezas en la capa ℓ , I es la identidad que simula la conexión residual, y $\alpha = 0,5$ es la fracción residual. El resultado se normaliza por filas para ser estocástico.

3. Formalización matemática del framework

El objetivo del framework es transformar la representación latente aprendida por un modelo profundo en una hipótesis relacional interpretable. A diferencia de enfoques tradicionales basados en modelos matemáticos rígidos con supuestos predefinidos, o modelos profundos opacos cuya interpretación se limita al análisis de importancia de variables o recuperación de circuitos internos, el framework propone una transformación intermedia donde la información aprendida es convertida progresivamente en estructuras simbólicas.

Sea un modelo profundo entrenado sobre un conjunto de datos:

$$M_\theta : X \rightarrow Y$$

donde:

- X corresponde al espacio de entrada.
- Y corresponde al espacio de salida.
- θ representa los parámetros aprendidos.

Durante el entrenamiento, el modelo genera una representación latente:

$$Z = M_\theta^L(X)$$

donde Z representa el espacio interno aprendido por la red en una capa L .

A partir de esta representación se construye una matriz relacional:

$$A \in \mathbb{R}^{n \times n}$$

donde cada elemento A_{ij} representa la intensidad de interacción entre dos componentes latentes i y j . Esta matriz es **agnóstica al dominio**: n puede representar índices vegetacionales, sensores industriales, variables de proceso minero o cualquier conjunto de variables multivariantes.

3.1. Propiedades de la matriz relacional

La matriz A puede interpretarse como un operador relacional con las siguientes propiedades matemáticas:

- **No negatividad**: $A_{ij} \geq 0$.
- **Estocasticidad por filas**: $\sum_j A_{ij} \approx 1$, lo que permite interpretarla como una cadena de Markov dirigida.
- **Asimetría**: en general $A_{ij} \neq A_{ji}$, codificando relaciones direccionales.

4. Transformación matriz-grafo

La primera transformación del framework corresponde a:

$$\Phi : A \rightarrow G$$

donde $G = (V, E, W)$ es un grafo ponderado dirigido.

El conjunto de nodos está definido como:

$$V = \{v_1, v_2, \dots, v_n\}$$

Cada nodo representa una entidad o componente interpretable.

El conjunto de aristas está dado por:

$$E = \{(v_i, v_j) : A_{ij} > \tau\}$$

donde τ corresponde al criterio de selección utilizado para extraer relaciones relevantes.

Para evitar la dependencia de umbrales arbitrarios, se emplea un criterio **Top-K** fijo que selecciona las K aristas más fuertes, garantizando que el grafo nunca quede vacío.

La función $\Phi(A) = G$ puede expresarse como:

$$\Phi(A) = (V, \{(i, j, A_{ij}) \mid A_{ij} \in \text{Top-K}(A)\})$$

Por lo tanto, esta transformación convierte una representación continua de interacciones en una estructura discreta interpretable.

5. Transformación grafo-hipótesis

La segunda transformación corresponde a:

$$\Psi : G \rightarrow H$$

donde H representa una hipótesis relacional compacta.

Formalmente:

$$H = \Psi(G)$$

donde una hipótesis puede definirse como:

$$H = (E_H, \mathcal{R})$$

con:

- E_H conjunto reducido de relaciones relevantes.
- $\mathcal{R}$ interpretación semántica asociada.

La extracción de hipótesis puede formularse como un problema de compresión:

$$\min_H |H| \quad \text{sujeto a} \quad I(H, G) \geq \gamma$$

donde $I(H, G)$ mide la información preservada entre el grafo original y la hipótesis reducida.

De esta forma, el objetivo no es recuperar todos los circuitos internos del modelo, sino obtener una explicación estructural mínima capaz de conservar la información relevante.

5.1. Análisis estructural del grafo

Sobre G se aplican métricas estructurales independientes del dominio:

- **PageRank**: $\pi = \pi P$, donde P es la matriz de transición del grafo.
- **HITS**: descomposición en hubs (alta salida) y authorities (alta entrada).
- **Comunidades Louvain**: maximización de modularidad.
- **Roles nodales**: clasificación en *hub*, *source*, *bridge*, *isolated*.
- **Reciprocidad**: fracción de aristas bidireccionales.

6. Evaluación mediante perturbación

La tercera transformación corresponde a:

$$F : H \times M \rightarrow R$$

donde R representa la fidelidad de la hipótesis respecto al comportamiento del modelo.

Sea $M(X)$ la predicción original del modelo y $M_H(X)$ la predicción obtenida cuando solamente se conserva la información representada por H (bloqueando las aristas no incluidas en la hipótesis). Entonces:

$$F(H, M) = 1 - \mathcal{L}(M(X), M_H(X))$$

donde $\mathcal{L}$ corresponde a una función de pérdida. Una hipótesis será válida cuando $F(H, M) \rightarrow 1$.

7. Análisis espectral del operador relacional

Adicionalmente, la matriz A se analiza como operador matemático mediante:

- **Descomposición en valores singulares (SVD)**: $A = U\Sigma V^T$, de donde se obtienen $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n$.
- **Rango efectivo**: número de valores singulares que acumulan el 95 % de la energía.
- **Número de condición**: $\kappa = \sigma_1/\sigma_n$.
- **Norma nuclear**: $\|A\|_* = \sum_i \sigma_i$.
- **Traza de potencias**: $\text{tr}(A^k)$, que cuenta ciclos ponderados de longitud k .
- **Entropía de Shannon**: $H(A) = -\sum_{ij} P_{ij} \log P_{ij}$.
- **Descomposición simétrica/antisimétrica**: $S = (A + A^T)/2$, $K = (A - A^T)/2$, con ratio $\|K\|_F/\|S\|_F$.
- **Laplaciano random-walk**: $L = I - A$, con autovalores $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$. El *gap espectral* λ_2 mide la conectividad del grafo.

Este análisis espectral es **independiente del dominio** y permite comparar operadores relacionales aprendidos en contextos distintos.

8. Interpretación metodológica

El framework completo puede expresarse como la composición:

$$X \rightarrow M_\theta \rightarrow A \xrightarrow{\Phi} G \xrightarrow{\Psi} H \xrightarrow{F} R$$

Esta formulación diferencia el método propuesto de:

- **Modelos matemáticos tradicionales**, donde la estructura explicativa es impuesta previamente mediante supuestos.
- **Métodos de interpretabilidad clásicos** (SHAP, LIME), donde únicamente se calcula importancia de variables.
- **Visualización de atención** (heatmaps), que no extrae hipótesis ni modelo compacto.
- **Interpretabilidad mecanicista**, que recupera circuitos internos pero no produce hipótesis del fenómeno.
- **Grafos causales con conocimiento previo** [3], que requieren un grafo causal preexistente.

El objetivo del framework es utilizar el aprendizaje profundo como mecanismo para descubrir representaciones, y posteriormente convertir dicha representación latente en una hipótesis relacional compacta, interpretable y evaluable.

9. Diferenciación con el estado del arte

Los métodos actuales de interpretabilidad para modelos profundos pueden agruparse principalmente en dos categorías: métodos atribucionales, cuyo objetivo es identificar qué variables de entrada contribuyen a una predicción, y métodos mecanicistas, orientados a descubrir qué componentes internos del modelo producen determinado comportamiento. Sin embargo, ambos enfoques presentan una limitación común: entregan explicaciones centradas en el modelo o en la entrada, pero no transforman la representación aprendida por el modelo en una estructura relacional interpretable sobre el fenómeno analizado.

El framework propuesto aborda este vacío mediante una transformación de la representación latente del modelo hacia una hipótesis relacional compacta, permitiendo extraer patrones estructurales sin requerir conocimiento causal previo ni depender de la arquitectura interna específica.

9.1. vs. Chefer et al. (2021) — Transformer Interpretability Beyond Attention Visualization [1]

Chefer et al. proponen un método de atribución que combina información de atención y gradientes mediante propagación de relevancia para identificar la contribución de los elementos de entrada a la predicción final. La salida del método corresponde principalmente a mapas de relevancia espacial.

La diferencia fundamental es que estos métodos responden a la pregunta “¿qué elementos de entrada fueron importantes para la decisión?”, mientras que el framework propuesto

aborda una pregunta distinta: “¿qué relaciones entre variables emergen de la representación aprendida por el modelo?”. Por lo tanto, no busca generar una explicación por importancia individual, sino construir una estructura relacional interpretable entre variables.

9.2. vs. Kalnare et al. (2025) — Mechanistic Interpretability for Transformer-based Time Series Classification [2]

Kalnare et al. aplican técnicas de interpretabilidad mecanicista sobre Transformers de series temporales mediante análisis de activaciones, attention heads y circuitos internos. Su objetivo es identificar mecanismos dentro de la red que expliquen cómo el modelo procesa la información.

En contraste, el framework propuesto no intenta reconstruir el funcionamiento interno del Transformer ni identificar circuitos neuronales responsables de una predicción. Su objetivo es independiente de la arquitectura: utilizar la representación aprendida como fuente de información para generar hipótesis sobre las relaciones existentes entre variables del dominio.

Mientras la interpretabilidad mecanicista responde: “¿qué componentes internos del modelo producen la salida?”, el framework responde: “¿qué estructura relacional del fenómeno fue capturada por el modelo?”.

9.3. vs. Zhao et al. (2026) — Causal-guided Graph Transformer for Process Fault Diagnosis (CGTIA) [3]

Zhao et al. incorporan información causal previa mediante un grafo construido a partir de conocimiento del dominio y métodos de selección causal, utilizando dicha estructura para guiar la arquitectura Graph Transformer.

La principal diferencia es que el framework propuesto no requiere asumir una estructura causal inicial. En lugar de imponer relaciones conocidas al modelo, permite que las relaciones emerjan desde la representación aprendida y luego sean evaluadas mediante métricas de estabilidad y fidelidad.

Por esta razón, mientras CGTIA está diseñado para diagnóstico de fallas bajo una estructura causal definida, el framework propuesto busca ser aplicable a dominios donde las relaciones relevantes no están completamente establecidas previamente.

9.4. vs. Chen et al. (2025) — Interpretable Deep Learning for Forest Type Classification [4]

Chen et al. emplean modelos profundos para clasificación multiespectral y aplican técnicas como SHAP, Grad-CAM++ y occlusion sensitivity para estimar la importancia de variables espectrales.

Aunque estos métodos permiten identificar qué bandas o regiones influyen en la predicción, su análisis permanece en un nivel atribucional. El framework propuesto extiende esta perspectiva al buscar relaciones entre variables, permitiendo representar interacciones aprendidas por el modelo en forma de hipótesis estructurales.

La diferencia radica en pasar desde una interpretación basada en importancia:

$$x_i \rightarrow \text{importancia}$$

hacia una interpretación relacional:

$$(x_i, x_j, \dots, x_n) \rightarrow \text{estructura hipotetica}$$

9.5. vs. Trabajos de dominio en percepción remota

Los trabajos de Segarra et al. (2020) y Varghese et al. (2021) proporcionan fundamentos sobre el uso de Sentinel-2 y variables espectrales para aplicaciones agrícolas y ambientales. Sin embargo, corresponden principalmente a estudios de aplicación y revisión del dominio, sin abordar métodos para extraer conocimiento interpretable desde modelos profundos.

Estos trabajos justifican el contexto experimental, pero no representan competidores metodológicos del framework propuesto.

9.6. Síntesis de la contribución

La principal contribución del framework no consiste en proponer una nueva técnica de visualización de atención ni una nueva estrategia de atribución, sino en introducir un nivel intermedio entre el modelo profundo y el conocimiento interpretable.

Los métodos existentes explican principalmente:

- qué entradas influyen en una predicción;
- qué componentes internos generan una salida;
- o cómo se propagan relaciones causales previamente conocidas.

Sin embargo, ninguno aborda directamente la transformación de una representación latente aprendida hacia una hipótesis relacional interpretable y evaluable.

El framework propuesto formaliza este proceso mediante tres transformaciones:

$$\Phi : A \rightarrow G$$

donde una matriz relacional aprendida se convierte en un grafo interpretable;

$$\Psi : G \rightarrow H$$

donde el grafo se transforma en una hipótesis compacta;

y

$$F(H, M) \rightarrow R$$

donde la hipótesis es evaluada respecto a la fidelidad del modelo mediante perturbaciones.

De esta manera, el objetivo no es explicar el modelo en sí mismo, sino utilizarlo como instrumento de descubrimiento de estructuras relacionales ocultas en los datos.

10. Aplicabilidad a otros dominios

El framework es agnóstico al dominio. La única entrada requerida es una matriz $A \in \mathbb{R}^{n \times n}$ que represente interacciones entre variables, producible por cualquier modelo que emplee atención o mecanismos equivalentes. A continuación se detallan aplicaciones concretas:

Trabajo	Pregunta principal	Salida obtenida	Limitación abordada
Chefer 2021	¿Qué elementos de entrada son relevantes?	Mapa de relevancia	No representa relaciones entre variables
Kalnare 2025	¿Qué circuitos internos usa el Transformer?	Grafo mecanicista interno	Dependencia de la arquitectura
Zhao 2026	¿Cómo se propagan fallas conocidas?	Grafo causal guiado	Requiere estructura previa
Chen 2025	¿Qué variables tienen mayor impacto?	Importancia SHAP	Explicación individual, no estructural
Framework propuesto	¿Qué relaciones emergen desde la representación aprendida?	Hipótesis relacional interpretable	No requiere causalidad previa ni inspección interna

Cuadro 1: Diferencias conceptuales entre métodos existentes y el framework propuesto.

10.1. Minería

En procesos mineros, n variables de operación (por ejemplo, ley del mineral, throughput, consumo eléctrico, vibración de molinos, presión hidráulica, pH de pulpa y granulometría) son monitoreadas continuamente y presentan fuertes dependencias entre sí. Un Transformer multivariado puede aprender relaciones de influencia entre estas variables para modelar el rendimiento metalúrgico. En este contexto, el framework permitiría identificar variables de alta centralidad, detectar grupos de variables estrechamente relacionadas e identificar dependencias dominantes asociadas al comportamiento del proceso.

10.2. IoT e Industria 4.0

En entornos IoT e Industria 4.0, una planta puede estar instrumentada con n sensores que registran variables como temperatura, humedad, vibración, consumo energético y posición. El framework permitiría identificar sensores de alta centralidad, detectar módulos funcionales de sensores relacionados y comparar la estructura de dependencias entre distintas líneas de producción o entre diferentes estados operacionales de la planta.

10.3. Mantenimiento predictivo

En problemas de mantenimiento predictivo, como el conjunto de datos C-MAPSS de la NASA, se dispone de n sensores que monitorean continuamente el estado de un sistema mecánico. A partir de las matrices de atención aprendidas por un Transformer, el framework podría identificar sensores cuya relevancia aumenta en etapas tempranas de degradación y analizar cómo evolucionan las dependencias entre variables a medida que progresa el deterioro del sistema.

10.4. Visión computacional industrial

En sistemas de inspección visual industrial, es posible definir un conjunto de n características de calidad extraídas de las imágenes, tales como dimensiones, textura, color, rugosidad o presencia de defectos. Si dichas características son modeladas mediante mecanismos de atención, el framework permitiría identificar cuáles poseen mayor relevancia dentro del proceso de decisión y analizar las dependencias aprendidas entre las distintas características de calidad.

10.5. Procesos químicos

En procesos químicos continuos, variables como temperatura, presión, caudal, composición y pH presentan un fuerte acoplamiento dinámico. En este contexto, el framework puede identificar patrones de dependencia entre variables y detectar posibles rutas de influencia entre los distintos componentes del proceso, proporcionando una representación interpretable de la estructura relacional aprendida por el modelo.

10.6. Energía

En sistemas energéticos, las matrices de atención pueden construirse a partir de variables eléctricas o nodos de medición distribuidos en la red. El framework puede identificar nodos críticos de alta centralidad, detectar comunidades que operan de manera sincronizada y comparar la estructura de interacciones entre distintos regímenes operacionales o escenarios de perturbación.

10.7. Incendios forestales

En aplicaciones de monitoreo de incendios forestales, las variables de entrada pueden incluir temperatura, humedad relativa, precipitación, humedad del suelo, velocidad del viento e índices espectrales de vegetación. El framework puede identificar las variables más influyentes dentro del sistema, detectar grupos de variables estrechamente relacionadas y analizar cómo se modifican las dependencias aprendidas entre condiciones normales y escenarios de alto riesgo.

10.8. Monitoreo de océanos

En aplicaciones de observación oceánica, variables como temperatura superficial del mar, clorofila-*a*, salinidad, turbidez, velocidad de las corrientes y altura significativa de las olas presentan complejas interacciones físicas y biogeoquímicas. El framework permitiría identificar variables de alta centralidad, detectar estructuras de interacción entre procesos oceánicos y comparar patrones relacionales entre diferentes regiones geográficas o períodos temporales.

10.9. Monitoreo de glaciares

En estudios de dinámica glaciar, variables como extensión glaciar, albedo, temperatura superficial, precipitación, cobertura nival y radiación solar mantienen relaciones de dependencia asociadas a la evolución del sistema criosférico. El framework puede caracterizar dichas dependencias, identificar factores dominantes asociados a cambios en el estado del

glaciar y comparar la estructura de interacciones entre diferentes glaciares o estaciones del año.

11. Objetivos

11.1. Objetivo general

Desarrollar un framework metodológico agnóstico al dominio que transforme la representación latente aprendida por modelos profundos en una hipótesis relacional compacta, interpretable y evaluable, validada mediante estabilidad estadística y perturbación dirigida.

11.2. Objetivos específicos

1. Formalizar matemáticamente las transformaciones Φ , Ψ y F que componen el pipeline del framework.
2. Implementar el análisis espectral del operador relacional A como descriptor invariante del fenómeno aprendido.
3. Evaluar la estabilidad estructural del framework ante variaciones estocásticas del entrenamiento (bootstrap de semillas).
4. Identificar y validar el *núcleo relacional* (aristas estables) frente a la *periferia estocástica* (aristas variables).
5. Demostrar la invarianza espectral macroscópica frente a la variabilidad topológica microscópica.
6. Validar la hipótesis reconstruida mediante perturbación dirigida sobre el modelo.
7. Demostrar la generalidad del framework mediante su aplicación a un segundo dominio distinto al caso de estudio principal.

12. Hipótesis

12.1. Hipótesis principal

Se plantea que las representaciones latentes aprendidas por un modelo profundo no son completamente aleatorias, sino que contienen un conjunto de relaciones relativamente estables que reflejan patrones subyacentes del fenómeno estudiado, junto con otras relaciones más sensibles a la inicialización del entrenamiento. Por ello, una explicación basada en una sola ejecución del modelo puede ser insuficiente o incluso engañosa, siendo más apropiado obtener una interpretación a partir del consenso entre múltiples entrenamientos independientes.

12.2. Hipótesis secundaria

Se plantea que, aunque las matrices de atención individuales presenten variaciones entre diferentes entrenamientos, la estructura relacional reconstruida mantiene una organización global relativamente estable, observable en sus propiedades espectrales y en la persistencia de ciertos roles e interacciones dominantes.

13. Diseño del experimento

13.1. Caso de estudio

El caso de estudio utiliza 12 índices espectrales derivados de imágenes Sentinel-2 L2A sobre un área de interés agrícola (500×500 m, latitud $-32,552261$, longitud $-70,683716$) durante el periodo 2018–2023. Los frames fueron filtrados considerando un porcentaje de nubosidad menor al 2 %, obteniéndose finalmente 186 fechas válidas. Los 12 índices son: NDVI, MARI, ARI, EVI, EVI2, NDWI, NDMI, CHL_REDEGE, NDII, SAVI, PSRI, KNDVI.

13.2. Entrada, proceso y salida

- **Entrada:** tensor de dimensiones $(T \times H \times W \times n) = (186 \times 52 \times 51 \times 12)$, donde T es el número de fechas, $H \times W$ la dimensión espacial, y $n = 12$ el número de índices.
- **Preprocesamiento:** split temporal (80 % train, 20 % val), escalado StandardScaler ajustado solo con train, construcción de secuencias deslizantes de longitud 7 (predecir $t + 1$ a partir de $t - 6 \dots t$).
- **Modelo:** ConvTransformer con encoder convolucional (stride 2, embed_dim 32), proyección a $d = 128$, MHA con 4 cabezas y 2 capas, decoder convolucional con interpolación bicúbica.
- **Salida:** predicción del frame $t + 1$ para los 12 índices, más la matriz de atención rollout $A \in \mathbb{R}^{12 \times 12}$.
- **Framework:** las 5 capas (análisis matemático, grafo, métricas, hipótesis, validación) se aplican sobre A .

13.3. Por qué 50 semillas

El número de 50 semillas se elige por tres razones:

1. **Significancia estadística:** con $N = 50$, el intervalo de confianza al 95 % para una proporción tiene ancho $\approx \pm 0,14$, suficiente para distinguir entre “estable” (≥ 80 %) y “moderadamente estable” (60–80 %).
2. **Detección de outliers:** 50 modelos permiten identificar semillas atípicas sin que un solo caso distorsione el consenso.
3. **Costo computacional factible:** cada modelo entrena en ~ 12 –18 segundos en GPU T4 (15 GB VRAM) con mixed precision, totalizando ~ 15 minutos para los 50 modelos.

13.4. Parámetros del experimento

- Optimizador: AdamW ($lr = 10^{-3}$, $weight_decay = 10^{-5}$).
- Scheduler: ReduceLROnPlateau (factor 0.5, patience 3).
- Early stopping: patience 10 epochs.
- Batch size: 16.
- Mixed precision (AMP) activado.
- Análisis de sensibilidad sobre $K \in \{3, 5, 7, 10\}$.

14. Resultados experimentales

14.1. Estabilidad predictiva

Los 50 modelos alcanzan desempeño equivalente:

$$\text{Val MSE} = 0,3247 \pm 0,0165 \quad (CV = 5,1 \%)$$

14.2. Estabilidad espectral del operador relacional

Métrica	Media $\pm$ Desv.	CV (%)
σ_1 (SVD)	$1,0544 \pm 0,0631$	6,0
σ_3 (SVD)	$0,2605 \pm 0,0095$	3,6
Rango efectivo	$10,9 \pm 0,3$	2,8
Norma nuclear	$3,9002 \pm 0,1112$	2,9
$\text{tr}(A)$	$3,8545 \pm 0,1246$	3,2
$\text{tr}(A^2)$	$1,7623 \pm 0,0935$	5,3
$\text{tr}(A^3)$	$1,2139 \pm 0,0590$	4,9
Entropía (nats)	$26,317 \pm 0,727$	2,8
Gap espectral	$0,6504 \pm 0,0912$	14,0

Cuadro 2: Estabilidad espectral del operador relacional A en 50 modelos. Las métricas espectrales se calculan sobre la matriz continua de atención A , por lo que no dependen del parámetro de discretización K .

14.3. Análisis de sensibilidad y conclusión del experimento

Los resultados obtenidos muestran que el comportamiento del framework debe interpretarse en dos niveles complementarios. En primer lugar, la matriz de atención continua A representa el operador relacional aprendido por el modelo y mantiene propiedades espectrales estables entre entrenamientos. Estas propiedades son independientes del parámetro K , debido a que dicho parámetro únicamente modifica la transformación posterior $\Phi(A) \rightarrow G_K$, donde la matriz continua es convertida en un grafo dirigido mediante selección topológica de relaciones relevantes.

En segundo lugar, la sensibilidad del proceso de reconstrucción debe evaluarse sobre el grafo discretizado G_K . Los resultados muestran que no existe una proliferación de aristas completamente estables para todos los niveles de sparsificación; sin embargo, al utilizar $K = 10$ emerge un núcleo relacional mínimo compuesto por una única arista core, correspondiente a la relación $\text{PSRI} \rightarrow \text{NDWI}$, con una frecuencia de aparición del 80 % (40 de 50 modelos). Esta relación constituye el vínculo más reproducible aprendido por el ConvTransformer y se mantiene como la arista dominante para todos los valores de K evaluados.

La evolución del índice de Jaccard indica que el incremento del número de relaciones seleccionadas no produce una degradación abrupta de la estructura reconstruida. Aunque existe una disminución inicial entre $K = 3$ y $K = 5$ ($-19,3\%$), los valores posteriores muestran recuperación y estabilidad, alcanzando $\mu = 0,273$ para $K = 10$, con un aumento global de solamente $4,3\%$ respecto al caso base. Además, el Jaccard normalizado respecto a una selección aleatoria permanece considerablemente superior al azar, alcanzando valores de $22,7\times$, $10,9\times$, $8,1\times$ y $6,9\times$ para $K = 3, 5, 7, 10$ respectivamente. Esto indica que las relaciones incorporadas al aumentar K poseen estructura estadística y no corresponden a conexiones aleatorias.

Las métricas espectrales sobre A permanecen constantes frente a los distintos valores de K , sugiriendo que el filtrado top- K actúa únicamente sobre la representación gráfica posterior y no modifica el operador relacional aprendido. Por otro lado, las métricas calculadas sobre G_K muestran una transición gradual: la reciprocidad disminuye desde $0,373$ hasta $0,120$ al aumentar K , indicando una evolución desde relaciones más bidireccionales hacia una organización más dirigida y jerárquica. La modularidad permanece igual a cero en todos los escenarios, sugiriendo que las relaciones aprendidas no forman comunidades aisladas, sino una red integrada de interacciones espectrales.

En conjunto, estos resultados indican que el ConvTransformer aprende una estructura relacional parcialmente reproducible, compuesta por un núcleo altamente consistente y una periferia progresivamente incorporada con coherencia estadística superior al azar. Dentro del rango evaluado, $K^* = 10$ proporciona la representación más informativa, ya que maximiza el compromiso entre cantidad de relaciones retenidas y estabilidad estructural ($J \times K = 2,73$), permitiendo capturar una mayor cantidad de interacciones sin observar una pérdida significativa de consistencia.

15. Discusión

15.1. Consenso estocástico vs. estructura causal rígida

A diferencia del enfoque de Zhao et al. [3], que inyecta un grafo causal preexistente en el modelo, el framework propuesto **no impone** una causalidad rígida: extrae la estructura latente que el modelo aprendió genuinamente a partir de los datos. Esto evita sesgar la explicación hacia conocimiento previo que podría ser incompleto o incorrecto.

15.2. Novedad frente al estado del arte

El framework se diferencia de las familias existentes (Tabla 1): no atribuye importancia marginal (como SHAP/LIME o Chen et al. [4]), no se queda en heatmaps (como Chefer et al. [1]), no recupera circuitos internos (como Kalnare et al. [2]), y no requiere grafo causal previo (como Zhao et al. [3]). Su aporte específico es la **transformación de**

una representación latente en una hipótesis relacional compacta, validada por estabilidad y perturbación, agnóstica al dominio y al backbone.

15.3. Generalidad del framework

El caso de estudio agrícola demuestra empíricamente la viabilidad del framework, pero su diseño es agnóstico al dominio. La única entrada requerida es una matriz $A \in \mathbb{R}^{n \times n}$, producible por cualquier modelo con atención. Esto habilita su aplicación futura en minería, IoT, mantenimiento predictivo e Industria 4.0.

16. Carácter preliminar y hoja de ruta para la tesis

16.1. Estado actual

Los resultados presentados constituyen un **avance preliminar** que valida la viabilidad del framework. Se ha demostrado que:

- La arquitectura ConvTransformer produce matrices de atención extraíbles.
- El análisis espectral y estructural sobre A es estable entre entrenamientos.
- El par $\text{PSRI} \leftrightarrow \text{NDWI}$ emerge como atractor dominante.
- La periferia posee estructura estadística significativa, no ruido blanco.

Sin embargo, quedan áreas críticas por profundizar antes de la defensa.

16.2. Áreas a profundizar

1. **Validación por perturbación dirigida:** bloquear sistemáticamente cada arista de la hipótesis y medir la caída en la predicción. Esto permite determinar si las relaciones extraídas son funcionales para el modelo o si corresponden únicamente a asociaciones correlacionales.
2. **Comparación cuantitativa con *baselines*:** contrastar la hipótesis extraída contra medidas tradicionales como correlación de Pearson, información mutua y *attention rollout* sin filtrado top- K , con el fin de establecer el valor agregado del framework propuesto.
3. **Dataset sintético con *ground truth* conocido:** construir datos con relaciones causales diseñadas explícitamente (por ejemplo, $A \rightarrow B \rightarrow C$) y verificar que el framework sea capaz de recuperarlas, evaluando precisión y recall del grafo reconstruido.
4. **Demostración en un segundo dominio:** aplicar el framework a mantenimiento predictivo (por ejemplo, CMAPSS de la NASA) o a un escenario de IoT industrial, idealmente sin requerir modificaciones estructurales en el código, con el objetivo de evidenciar la generalidad metodológica de la propuesta.

5. **Agnosticismo de *backbone***: verificar la capacidad del framework para operar sobre arquitecturas distintas a Transformers, tales como LSTM con atención o modelos basados en *state-space*, a fin de reforzar que la metodología depende de la representación latente y no de una arquitectura específica.
6. **Análisis comparativo entre casos**: aplicar el framework a distintas zonas de estudio, regiones de interés o períodos temporales, y analizar si las hipótesis reconstruidas difieren de manera significativa, lo que permitiría evaluar su sensibilidad al contexto.
7. **Formalización matemática completa**: definir con mayor precisión los axiomas, propiedades y alcances de las transformaciones Φ , Ψ y F , incluyendo condiciones de estabilidad, fidelidad y comparabilidad entre hipótesis.
8. **Técnicas de explicabilidad complementarias**: incorporar e integrar métodos de explicabilidad adicionales, como SHAP, para contrastar la hipótesis relacional extraída con explicaciones atribuibles clásicas y fortalecer la interpretación del comportamiento del modelo.
9. **Métricas de validación del entrenamiento**: ampliar el conjunto de métricas de evaluación del modelo durante el entrenamiento y la validación, incorporando indicadores complementarios de ajuste, estabilidad y generalización más allá del error de reconstrucción.
10. **Definición del área de estudio**: seleccionar y justificar formalmente la zona geográfica o dominio específico sobre el cual se entrenará y evaluará el modelo, asegurando coherencia entre la hipótesis de investigación, la disponibilidad de datos y el caso de estudio elegido.

16.3. Pasos siguientes

Semestre 1 — Fundamentación y caso principal:

- Semanas 1–3: Revisión bibliográfica ampliada, refinamiento del problema de investigación y formalización matemática inicial del framework.
- Semanas 4–5: Implementación del pipeline completo de extracción de atención y evaluación preliminar mediante *attention rollout*.
- Semanas 6–8: Entrenamiento del ConvTransformer con los datos del caso principal, junto con la extracción de atención real y la construcción de la representación relacional.
- Semanas 9–12: Ejecución del experimento central de estabilidad mediante múltiples semillas y análisis espectral de las matrices obtenidas.
- Semanas 13–15: Implementación de validación por perturbación dirigida y análisis de fidelidad de la hipótesis reconstruida.
- Semana 16: Consolidación del estado del arte, redacción del informe de avance y revisión de la coherencia metodológica del framework.

Semestre 2 — Generalización, comparación y redacción:

- Semanas 1–3: Incorporación de técnicas de explicabilidad complementarias, como SHAP, y comparación cuantitativa con baselines clásicos.
- Semanas 4–5: Construcción y evaluación de un dataset sintético con *ground truth* conocido para validar la capacidad de recuperación estructural del framework.
- Semanas 6–7: Demostración experimental en un segundo dominio, como mantenimiento predictivo o IoT industrial, para evaluar la transferibilidad de la propuesta.
- Semanas 8–9: Análisis comparativo entre casos, revisión del comportamiento del framework frente a distintas zonas de estudio o períodos temporales, y evaluación de su agnosticismo respecto al *backbone*.
- Semanas 10–14: Redacción completa de la tesis, integración de resultados y discusión crítica de alcance, limitaciones y aportes.
- Semanas 15–16: Ajustes finales del manuscrito y preparación de la defensa.

16.4. Observación metodológica

Debe destacarse que este plan corresponde a una hoja de ruta tentativo y no a un calendario rígido, dado que la investigación puede evolucionar conforme avancen la experimentación, el análisis de resultados y la disponibilidad de datos. En consecuencia, la secuencia propuesta organiza de manera razonable las prioridades iniciales y los hitos esperados, pero mantiene flexibilidad para reordenar etapas, profundizar en resultados emergentes o ajustar el alcance de ciertas validaciones según las necesidades del proceso de investigación.

17. Conclusiones

El framework propuesto transforma representaciones latentes inestables en hipótesis relacionales compactas, estables y comparables. Los resultados preliminares sobre 50 modelos sugieren invarianza espectral macroscópica ($CV < 6\%$), estabilidad de roles nodales y presencia de un atractor dinámico dominante ($PSRI \leftrightarrow NDWI$), sugiriendo que la estructura relacional reconstruida trasciende la variabilidad estocástica del entrenamiento. La periferia, lejos de ser ruido blanco, posee coherencia estadística significativamente superior al azar. El framework es agnóstico al dominio y aplicable a cualquier problema donde existan relaciones multivariantes complejas.

Referencias

- [1] H. Chefer, S. Gur, and L. Wolf, “Transformer Interpretability Beyond Attention Visualization,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 782–791. <https://arxiv.org/abs/2012.09838>

- [2] M. Kalnāre, S. Kitharidis, T. Bäck, and N. van Stein, “Mechanistic Interpretability for Transformer-based Time Series Classification,” *arXiv preprint arXiv:2511.21514*, 2025. <https://arxiv.org/abs/2511.21514>
- [3] S. Zhao, H. Yang, Z. Wang, F. Khan, and Q. Wang, “A causal-guided graph transformer with interpretability analysis for process fault diagnosis,” *Journal of Loss Prevention in the Process Industries*, vol. 102, p. 106022, 2026. <https://doi.org/10.1016/j.jlp.2026.106022>
- [4] S. Chen, X. Wang, M. Shi, G. Tao, S. Qiao, and Z. Chen, “Developing Interpretable Deep Learning Model for Subtropical Forest Type Classification Using Beijing-2, Sentinel-1, and Time-Series NDVI Data of Sentinel-2,” *Forests*, vol. 16, no. 11, p. 1709, 2025. <https://doi.org/10.3390/f16111709>
- [5] J. Segarra, M. L. Buchailot, J. L. Araus, and S. C. Kefauver, “Remote Sensing for Precision Agriculture: Sentinel-2 Improved Features and Applications,” *Agronomy*, vol. 10, no. 5, p. 641, 2020. <https://doi.org/10.3390/agronomy10050641>
- [6] D. Varghese, M. Radulović, S. Stojković, and V. Crnojević, “Reviewing the Potential of Sentinel-2 in Assessing the Drought,” *Remote Sensing*, vol. 13, no. 17, p. 3355, 2021. <https://doi.org/10.3390/rs13173355>
- [7] S. Abnar and W. Zuidema, “Quantifying Attention Flow in Transformers,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 4190–4197. <https://arxiv.org/abs/2005.00928>