

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

RECONSTRUCCIÓN DE HIPÓTESIS RELACIONALES A PARTIR DE LA ATENCIÓN DE MODELOS PROFUNDOS

**PATRICIO FIGUEROA
GABRIEL SANZANA**

**SEMINARIO DE TÍTULO
INFORME DE AVANCE
SEPTIEMBRE 2026**

RESUMEN

Los modelos profundos basados en atención superan a los modelos clásicos en desempeño predictivo sobre problemas multivariados, pero no entregan una descripción de las relaciones entre variables que sostiene esa predicción. Los métodos de explicabilidad disponibles tampoco la entregan: asignan importancia a cada variable por separado, dibujan la relevancia como un mapa continuo, o parten de un grafo conocido de antemano. Ninguno de esos objetos puede enunciarse fuera del modelo que lo produjo, compararse con conocimiento previo del fenómeno ni someterse a refutación.

Este trabajo propone un framework metodológico que transforma la matriz de atención de un modelo ya entrenado en una hipótesis relacional compacta, es decir, un grafo dirigido y ponderado sobre variables con nombre, sin reentrenar el modelo ni modificar su arquitectura. La contribución no está en extraer el grafo, operación algorítmicamente sencilla, sino en el criterio que decide cuándo una relación extraída merece tratarse como hipótesis científica. Ese criterio se organiza como una cadena de evidencia acumulativa de cinco eslabones: estabilidad de la representación ante la semilla de entrenamiento, estabilidad estructural ante el criterio de discretización, consenso frente a un modelo nulo explícito, fidelidad predictiva por ablación dirigida, y especificidad junto a robustez y compacidad. La cadena se triangula con paradigmas que no comparten supuestos, de modo que la conclusión sobre una relación no dependa de una sola familia de métodos.

A la fecha de este informe de avance el framework está formalizado y el protocolo de validación está especificado, con umbrales de aprobación e indicadores de fallo declarados antes de su ejecución. Aplicarlo sobre el caso de estudio, un conjunto de índices espectrales derivados de imágenes satelitales, constituye el programa de trabajo de la etapa siguiente. El estado del arte que respalda el diseño proviene de una revisión sistemática conducida bajo el protocolo PRISMA 2020.

Palabras clave: interpretabilidad, mecanismos de atención, grafo relacional, series de tiempo multivariadas, revisión sistemática.

ABSTRACT

Attention-based deep models outperform classical models on multivariate prediction tasks, yet they do not expose the relations among variables that support those predictions. Available explainability methods do not expose them either: they assign importance to each variable in isolation, render relevance as a continuous map, or start from a graph that is known beforehand. None of these objects can be stated outside the model that produced it, compared against prior knowledge of the phenomenon, or subjected to refutation.

This work proposes a methodological framework that turns the attention matrix of an already trained model into a compact relational hypothesis, that is, a weighted directed graph over named variables, without retraining the model or modifying its architecture. The contribution does not lie in extracting the graph, which is algorithmically simple, but in the criterion that decides when an extracted relation deserves to be treated as a scientific hypothesis. That criterion is organised as a cumulative chain of evidence with five links: stability of the representation under the training seed, structural stability under the discretisation criterion, consensus against an explicit null model, predictive faithfulness under targeted ablation, and specificity together with robustness and compactness. The chain is triangulated with paradigms that do not share assumptions, so that the verdict on a relation does not rest on a single family of methods.

As of this progress report the framework is formalised and the validation protocol is specified, with approval thresholds and failure indicators declared before execution. Running it on the case study, a set of spectral indices derived from satellite imagery, is the work programme for the next stage. The state of the art supporting the design comes from a systematic review conducted under the PRISMA 2020 protocol.

Keywords: interpretability, attention mechanisms, relational graph, multivariate time series, systematic review.

ÍNDICE GENERAL

Resumen/Abstract	I
Índice General	III
Lista de Tablas	V
1. Introducción	1
1.1. Contexto del problema	1
1.2. El problema	1
1.3. Qué se ha hecho hasta ahora	2
1.4. Propuesta y contribución	2
2. Objetivos	3
2.1. Objetivo general	3
2.2. Objetivos específicos	3
3. Estado del arte	5
3.1. Obtención del corpus: protocolo PRISMA 2020	5
3.2. Trabajos similares	6
3.3. Contribución de la propuesta	7
4. Marco teórico	9
4.1. Definición formal del problema	9
4.2. Técnicas necesarias	10
5. Plan de trabajo	12
5.1. Estado a la fecha de este informe	12
5.2. Actividades y calendario	12
5.3. Dependencias y riesgos	13

6. Propuesta	14
6.1. Visión general	14
6.2. El instrumento: un ConvTransformer de índices	14
6.3. Transformación Φ : de la matriz al grafo	15
6.4. Transformación Ψ : del grafo a la hipótesis	15
6.5. Transformación F : la cadena de evidencia	15
6.6. Triangulación entre paradigmas	16
6.7. Taxonomía diagnóstica	16
6.8. Aplicabilidad a otros dominios	17
7. Conclusiones preliminares	18
Referencias	19

ÍNDICE DE CUADROS

3.1. Registros identificados por base de datos. 5

3.2. Familias metodológicas del estado del arte, con su aporte y su límite. 8

5.1. Actividades del plan de trabajo, con periodo estimado y estado. 12

1. INTRODUCCIÓN

1.1. Contexto del problema

En las ciencias de la Tierra el objetivo de un modelo no se agota en predecir. Se espera que el modelo aporte conocimiento sobre el proceso que hay detrás del dato, y esa expectativa es la que vuelve insuficiente un buen desempeño predictivo por sí solo Reichstein et al., 2019. El caso de estudio de este trabajo pertenece a ese ámbito: índices espectrales calculados sobre imágenes satelitales, un tipo de dato cuya disponibilidad y resolución temporal han crecido de forma sostenida con la constelación Sentinel-2 y sus aplicaciones en agricultura de precisión Segarra et al., 2020.

Sobre ese tipo de dato los modelos profundos funcionan. Un modelo que combina memoria convolucional, convolución de grafo y atención predice mapas completos de índices de vegetación con error bajo y transfiere entre sensores e índices distintos Bouaziz et al., 2026. Lo que ese mismo trabajo no hace, y ahí empieza el problema de este informe, es comprobar qué relación entre índices aprendió el modelo para lograrlo. La estructura relacional queda dentro del modelo, se usa para predecir y no se audita.

1.2. El problema

Un modelo profundo de atención sí calcula, internamente, algo parecido a una estructura relacional: la matriz de atención registra cuánto pesa cada variable al procesar las demás. Tratar esa matriz como si fuera una explicación tiene tres obstáculos documentados.

El primero es la inestabilidad. La matriz de atención no es un objeto fijo del problema sino un producto del entrenamiento, y dos entrenamientos del mismo modelo sobre los mismos datos, con semillas distintas, no producen la misma matriz aunque su desempeño sea equivalente. Una explicación derivada de una sola corrida no informa sobre su propia reproducibilidad.

El segundo es la fidelidad. Que un mecanismo interno sea legible no garantiza que gobierne la predicción. Al adaptar pruebas de fidelidad a un modelo de constancia de color temporal se observa que la atención no mantiene una relación causal con la salida, mientras que otra forma de saliencia interna del mismo modelo sí la mantiene Rizzo et al., 2022. La fidelidad de la atención, entonces, hay que medirla en cada caso y no darla por supuesta.

El tercero es la fragilidad de la alternativa habitual. Los métodos de atribución por perturbación, que son la práctica dominante cuando se quiere explicar un modelo opaco, pueden ser engañados de forma deliberada: un clasificador construido para discriminar por un atributo protegido logra que ni LIME ni SHAP lo señalen como relevante Slack et al., 2020. A esto se suma que un modelo con métricas excelentes puede estar resolviendo la tarea por un atajo espurio, como el clasificador que distinguía una categoría por una marca de agua presente solo en esas imágenes, algo invisible para las métricas de desempeño agregadas Lapuschkin et al., 2019.

El problema puede enunciarse en una frase: no existe un procedimiento que permita decidir,

con criterios declarados de antemano, cuándo una relación entre variables extraída de la representación interna de un modelo profundo constituye una hipótesis sobre el fenómeno y cuándo es un artefacto del entrenamiento.

1.3. Qué se ha hecho hasta ahora

La literatura ha avanzado sobre todo en el lado de la obtención de estructura, y poco en el de su verificación.

Por el lado arquitectónico, invertir las dimensiones del Transformer de modo que cada serie completa sea un token, y no cada instante, mejora el desempeño en pronóstico multivariado y hace que la atención pase a describir correlaciones entre variables Liu et al., 2024. Ese resultado es la base de que exista, hoy, una matriz de atención entre variables que valga la pena analizar.

Por el lado de la estructura relacional, existen trabajos que la aprenden como parte del modelo. Uno de ellos reemplaza el grafo de correlaciones entre sensores por uno de dependencias condicionales y contrasta la estructura aprendida contra la topología física real de una instalación de tuberías Zhang et al., 2026. Es el antecedente más exigente en cuanto a validación, porque dispone de una verdad de referencia externa, y también el que marca la dificultad del caso de estudio de este trabajo: entre índices espectrales no existe una topología conocida contra la cual comparar.

La brecha queda entre ambos extremos. Hay cómo obtener una estructura y hay dominios donde validarla contra una referencia física, pero no hay un procedimiento que permita sostener una estructura leída de un modelo ya entrenado cuando esa referencia externa no existe.

1.4. Propuesta y contribución

Este trabajo propone un framework que opera como capa posterior al entrenamiento y se compone de tres transformaciones encadenadas: convertir la matriz de atención en un grafo dirigido ponderado, reducir ese grafo a una hipótesis relacional compacta, y evaluar esa hipótesis contra el comportamiento del propio modelo.

La contribución que se reclama es el tercer paso. Extraer un grafo desde una matriz es simple; sostener que ese grafo dice algo del fenómeno es lo que falta en la literatura revisada. El framework responde con una cadena de evidencia acumulativa de cinco eslabones, con umbrales declarados antes de ejecutarla, y con una triangulación entre paradigmas que no comparten supuestos, de manera que el veredicto sobre una relación no dependa de una sola familia de métodos. El diseño se completa con una taxonomía que distingue una relación estructural genuina de un atajo predictivo, de un artefacto de la arquitectura y de ruido estocástico.

Este informe de avance documenta el diseño y su fundamento. La ejecución del protocolo sobre el caso de estudio corresponde a la etapa siguiente y aparece detallada en el plan de trabajo del capítulo 5.

2. OBJETIVOS

2.1. Objetivo general

Desarrollar un framework metodológico, independiente del dominio, que transforme la representación latente aprendida por un modelo profundo ya entrenado en una hipótesis relacional compacta, interpretable y evaluable, y que la valide mediante una cadena de evidencia multicriterio capaz de integrar estabilidad estadística, fidelidad predictiva y contraste contra criterios no probabilísticos.

2.2. Objetivos específicos

Los objetivos específicos se agrupan en tres etapas. La primera fija qué hay que conocer antes de diseñar, la segunda construye el artefacto y la tercera decide si el artefacto funciona.

2.2.1. Estudio

1. Conducir una revisión sistemática de la literatura bajo el protocolo PRISMA 2020 que permita identificar las familias metodológicas existentes, sus limitaciones y el espacio que deja abierto la propuesta.
2. Caracterizar la variabilidad de la representación interna de un modelo de atención frente a la semilla de entrenamiento, apoyándose en la evidencia de que una explicación más estable no es necesariamente más fiel al modelo que la produce Harikrishnan, 2026.
3. Determinar qué métricas resultan adecuadas para evaluar la propuesta, considerando que la métrica de fidelidad más extendida presenta fallas cuando se traslada a datos temporales Šimić et al., 2025, y que una estructura explicativa debe evaluarse a la vez por fidelidad y por tamaño Mekonnen et al., 2024.

2.2.2. Desarrollo

4. Formalizar matemáticamente las transformaciones Φ , Ψ y F que componen el pipeline del framework, junto con las condiciones que debe cumplir una representación para ser entrada válida.
5. Construir una cadena de evidencia acumulativa de cinco eslabones, a saber, estabilidad continua de la representación, estabilidad estructural bajo distintas reglas de discretización, consenso estadístico frente a un modelo nulo explícito, fidelidad predictiva por ablación dirigida y especificidad junto a robustez y compacidad, con umbrales de aprobación e indicadores de fallo declarados antes de la ejecución.
6. Formular una taxonomía diagnóstica que permita distinguir de forma operativa una relación estructural genuina de un atajo predictivo, de un artefacto de tipo sumidero de atención y de ruido estocástico.

2.2.3. Validación

7. Ejecutar la cadena de evidencia sobre el caso de estudio de índices espectrales y reportar, arista por arista, en qué eslabón sobrevive o falla cada relación extraída.
8. Triangular la evidencia con cuatro paradigmas ortogonales al enfoque frecuentista que ya emplea el eslabón de consenso estadístico, esto es, el intervencional, el geométrico-topológico, el de teoría de la información y el de baselines deterministas. Sumados a ese enfoque completan los cinco paradigmas de la triangulación.
9. Demostrar la generalidad del framework aplicándolo a un conjunto sintético con estructura conocida y a un segundo dominio real distinto del caso de estudio principal.

3. ESTADO DEL ARTE

3.1. Obtención del corpus: protocolo PRISMA 2020

La revisión de literatura se condujo bajo el protocolo PRISMA 2020, de modo que la selección de los trabajos que se contrastan más abajo sea trazable y reproducible por un tercero. El protocolo se organizó en siete etapas: definición de la pregunta de investigación, diseño del protocolo, diseño de la cadena de búsqueda, búsqueda en bases de datos, aplicación de filtros de inclusión y exclusión, extracción de datos y redacción.

La pregunta se formuló en formato PICO, con la población en los modelos Transformer cuya atención se calcula entre tokens que representan variables con significado físico, la intervención en su condición de caja negra y en la inestabilidad de sus matrices entre ejecuciones, el comparador en los métodos tradicionales de explicabilidad, y el resultado esperado en la reconstrucción de una hipótesis relacional compacta, dirigida y falsable. De esa formulación se derivó la cadena de búsqueda, con cuatro bloques de términos unidos por AND, uno por componente PICO, y sinónimos unidos por OR dentro de cada bloque.

La búsqueda se ejecutó sobre tres bases de datos, con los resultados de la tabla 3.1, y se complementó con búsquedas adicionales por citas y registros.

Cuadro 3.1: Registros identificados por base de datos.

Base de datos	Registros
Scopus	191
Web of Science	100
PubMed	28
Total identificado	319

Los criterios de inclusión fueron tres: publicación entre 2022 y 2026, idioma inglés, y tipo de documento restringido a artículos de investigación primaria y trabajos de conferencia en Scopus y Web of Science. En PubMed no se restringió por tipo de documento, para no perder literatura técnica no clínica. La depuración posterior se hizo en Zotero y avanzó en tres pasos: la deduplicación dejó 221 registros, el filtro por identificador DOI auditable dejó 201, y el filtro por disponibilidad de texto completo dejó 137 registros elegibles.

De ese conjunto elegible se seleccionaron, tras lectura de texto completo, las 25 referencias que componen el corpus de este informe. Para cada una se registró descripción, muestra, metodología, resultados y conclusión, junto con la sección del informe a la que aporta. Conviene declarar una limitación del protocolo en este punto: el paso que va de los 137 registros elegibles a las 25 referencias incluidas se resolvió mediante un juicio de relevancia temática documentado caso por caso, y no mediante un umbral cuantitativo explícito. Formalizar ese criterio es parte del trabajo pendiente de la revisión.

3.2. Trabajos similares

El contraste se organiza por familias metodológicas y no trabajo por trabajo, porque trabajos que se ven distintos comparten la misma limitación estructural. Cada familia se define por el tipo de objeto que entrega como explicación y por el momento del ciclo de vida del modelo en que ese objeto se produce.

3.2.1. Atribución y relevancia posteriores al entrenamiento

Esta familia calcula relevancia sobre un modelo ya entrenado, y es la práctica dominante cuando hay que explicar un modelo opaco sin tocarlo. La descomposición de Taylor propagada por capas, que incluye las conexiones residuales, supera a los mapas de atención crudos en tareas de segmentación y perturbación Chefer et al., 2021. Sobre un clasificador Transformer de texto médico, SHAP y gradientes integrados alcanzan una fidelidad comparable, cercana a 0,22, aunque solo correlacionan de forma moderada entre sí F. Zhou et al., 2026, es decir, dos métodos igualmente fieles ordenan las variables de manera distinta. Una evaluación sistemática sobre Vision Transformers agrava el punto: métricas que dicen medir la misma propiedad convergen mínimamente, de modo que el orden de mérito entre métodos depende de cuál métrica se elija Stassin et al., 2024. El límite de la familia es el tipo de objeto que produce, una importancia por variable o un mapa continuo, que no es una estructura de dependencias enumerable.

3.2.2. Evidencia sobre la fiabilidad de las explicaciones

Esta familia no propone explicaciones, sino que mide cuánto se puede confiar en ellas, y por eso condiciona el diseño de la propuesta en lugar de competir con ella. El muestreo de perturbación de LIME y SHAP puede engañarse de forma deliberada, al punto de que un clasificador abiertamente sesgado logra que ninguno de los dos señale el atributo protegido Slack et al., 2020. Un modelo con exactitud de estado del arte puede estar resolviendo la tarea por un atajo espurio invisible a las métricas agregadas Lapuschkin et al., 2019. Y al reentrenar redes convolucionales y Transformers de visión con siete semillas sobre la misma tarea, el Transformer resulta más estable entre semillas pero menos fiel, porque borrar las regiones que destaca apenas cambia su confianza Harikrishnan, 2026. Su límite es que diagnostican sin entregar un procedimiento de decisión.

3.2.3. Estructura relacional aprendida o impuesta

Aquí la estructura es parte del modelo. La convolución de grafo adaptativa combinada con descomposición en frecuencia aprende correlaciones entre series a varias escalas y expone un grafo interpretable Cai et al., 2024. Un Transformer de grafo recibe un grafo de propagación de fallos construido de antemano por cribado de causalidad de Granger y lo usa para condicionar el cálculo de la atención Zhao et al., 2026. Un tercer trabajo reemplaza el grafo de correlaciones entre sensores por uno de dependencias condicionales y lo contrasta con la topología física real de una instalación de tuberías Zhang et al., 2026, que es el único caso del corpus con una referencia externa verificable. Un cuarto destila un clasificador en un conjunto compacto de reglas y lo evalúa a la vez por fidelidad y por tamaño Mekonnen et al., 2024. El límite es común a los cuatro: cuando el grafo es componente entrenado existe porque fue entrenado para existir y auditarlo obliga a reentrenar, y cuando es supuesto previo no admite hipótesis nula frente a la cual pueda resultar improbable.

3.2.4. Extracción de estructura por intervención sobre el modelo

Esta es la familia más cercana a la propuesta. Traslada técnicas de interpretabilidad mecanicista desde el procesamiento de lenguaje a un Transformer de clasificación de series temporales y construye grafos causales del flujo interno de información entre cabezas de atención, mediante parcheo de activaciones, saliencia de atención y autocodificadores dispersos Kalnāre et al., 2025. Obtiene, entonces, el mismo tipo de objeto que este trabajo busca. Su límite está en el precio: interviene el modelo y necesita acceso a sus estados internos, lo que la vuelve inaplicable sobre un modelo desplegado del que solo se dispone de la matriz de atención.

3.2.5. Decisiones arquitectónicas sobre el eje de la atención

Esta familia no aborda interpretabilidad, sino dónde conviene aplicar la atención. Invertir el Transformer de modo que cada variable sea un token mejora el pronóstico multivariado de largo plazo Liu et al., 2024, y combinar atención de canal con atención temporal mediante parches múltiples iguala o supera el estado del arte Villaboni et al., 2025. En sentido contrario, un trabajo sostiene que buena parte del mérito atribuido a los Transformers procede del mecanismo de parcheo y muestra que un perceptrón multicapa sobre parches iguala a arquitecturas más complejas Tang y Zhang, 2024. La familia respalda la condición que hace posible este trabajo, que exista una matriz de atención entre variables, pero no zanja si la ganancia viene de la atención o del parcheo, y en todos los casos la matriz se descarta después de la propagación.

3.2.6. Aplicaciones en dominios afines

Esta familia aplica arquitecturas de grafo o de atención a dominios cercanos al caso de estudio. Un modelo que combina memoria convolucional, convolución de grafo y Transformer predice mapas de índices de vegetación con buen error y transfiere entre sensores, sin auditar qué relación entre índices aprendió Bouaziz et al., 2026. Un segundo inserta un grafo acíclico dirigido con sentido físico en el espacio latente de un autocodificador variacional y valida el resultado contra experimentos numéricos Spuler et al., 2026. Un tercero genera explicaciones agnósticas al modelo para redes de sensores espacio-temporales y muestra que las herramientas pensadas para datos tabulares o de imagen resultan inefectivas ahí Altieri et al., 2025. Un cuarto documenta un Transformer de visión cuya atención converge por sí sola sobre una banda de frecuencia que la teoría aerodinámica predice de forma independiente X. Zhou et al., 2026, que es el único caso del corpus donde la atención recupera un mecanismo verificable por fuera del modelo. Su límite es que la estructura aprendida no se audita, y que esa coincidencia con la teoría es un hallazgo puntual y no un procedimiento repetible.

3.3. Contribución de la propuesta

La tabla 3.2 resume el contraste. Leídas en conjunto, las seis familias muestran un patrón asimétrico: obtener un objeto relacional está resuelto por varias vías, mientras que decidir si ese objeto merece crédito no lo está.

La dimensión vacía es la falsación de una estructura leída, es decir, ni aprendida, ni impuesta, ni obtenida por intervención sobre el modelo. Los trabajos que evalúan explicaciones lo hacen sobre

atribuciones por variable y con métricas que no convergen entre sí Stassin et al., 2024; F. Zhou et al., 2026, no sobre aristas de un grafo. Los que aplican estas arquitecturas a dominios afines, incluido uno en el mismo dominio de índices espectrales, predicen bien sin auditar la estructura que aprendieron Altieri et al., 2025; Bouaziz et al., 2026. Y el único caso en que la atención cruda demuestra ser informativa lo hace por coincidencia con un mecanismo ya conocido por otra vía X. Zhou et al., 2026.

La propuesta ocupa ese vacío combinando cinco elementos que la literatura revisada tiene por separado y no reúne: extracción posterior al entrenamiento sin reentrenar ni intervenir activaciones, consenso estadístico contra un modelo nulo explícito, fidelidad medida por ablación arista por arista, triangulación con paradigmas que no comparten supuestos, y una taxonomía que distinga relación genuina de atajo predictivo, artefacto y ruido. Cada elemento tiene precedente aislado; la contribución está en su composición.

Cuadro 3.2: Familias metodológicas del estado del arte, con su aporte y su límite.

Familia	Trabajos	A favor	En contra
Atribución y relevancia post-entrenamiento	Chefer et al., 2021; Stassin et al., 2024; F. Zhou et al., 2026	Aplicables sin reentrenar, maduras y disponibles	Entregan importancia por variable o mapa continuo; las métricas que las comparan no convergen
Fiabilidad de las explicaciones	Harikrishnan, 2026; Lapuschkin et al., 2019; Slack et al., 2020	Acotan el problema con evidencia experimental	Diagnostican sin dar un procedimiento de decisión
Estructura aprendida o impuesta	Cai et al., 2024; Mekonnen et al., 2024; Zhang et al., 2026; Zhao et al., 2026	Estructura explícita; un caso la contrasta con topología física	Auditarla exige reentrenar, o bien es supuesto previo sin hipótesis nula
Extracción por intervención	Kalnāre et al., 2025	Grafo causal verificable del interior del modelo	Requiere parchear activaciones y acceso a estados internos
Eje de la atención	Liu et al., 2024; Tang y Zhang, 2024; Villaboni et al., 2025	Respaldan tratar cada variable como token	No zanján si la ganancia viene de la atención o del parcheo
Dominios afines	Altieri et al., 2025; Bouaziz et al., 2026; Spuler et al., 2026; X. Zhou et al., 2026	Viabilidad demostrada en dominios cercanos	No auditan la estructura aprendida; la coincidencia con la teoría es puntual
Propuesta	Extracción posterior al entrenamiento sin intervenir el modelo, más cadena de cinco eslabones, modelo nulo explícito, triangulación entre paradigmas y taxonomía diagnóstica		

4. MARCO TEÓRICO

4.1. Definición formal del problema

La entrada del framework es una representación relacional y no un modelo. Sea $M_\theta : X \rightarrow Y$ un modelo profundo ya entrenado, del cual se extrae una matriz $A \in \mathbb{R}^{n \times n}$ donde cada elemento A_{ij} representa la intensidad de interacción dirigida entre las componentes i y j . Todo lo que el framework requiere de M_θ está contenido en esa matriz, que debe satisfacer tres propiedades:

1. No negatividad: $A_{ij} \geq 0$.
2. Estocasticidad por filas: $\sum_j A_{ij} \approx 1$, lo que permite leer la matriz como una cadena de Markov dirigida.
3. Asimetría: en general $A_{ij} \neq A_{ji}$, lo que codifica dirección.

Estas tres propiedades constituyen la condición de admisibilidad. Una representación que no las satisfaga no es entrada válida para el framework sin una adaptación previa explícita. Puesto que la definición no menciona en ningún punto el origen de A , el índice n puede corresponder a índices espectrales, sensores industriales o variables de proceso indistintamente.

El problema puede entonces plantearse así: dada A , producir un objeto discreto H de tamaño acotado, definido sobre variables con nombre, que preserve la información relacional relevante de A y que admita ser sometido a prueba. Formalmente se busca

$$\min_H |H| \quad \text{sujeto a} \quad I(H, G) \geq \epsilon, \quad (4.1)$$

donde G es el grafo dirigido obtenido a partir de A , $I(H, G)$ mide la información preservada entre ese grafo y la hipótesis reducida, y ϵ es el mínimo tolerado. El objetivo no es recuperar todos los circuitos internos del modelo, sino obtener una explicación estructural mínima capaz de conservar la información relevante.

A esa exigencia de compacidad se suma una de fidelidad. Si $M(X)$ es la predicción original y $M_H(X)$ la que se obtiene cuando solo se conserva la información representada por H , entonces

$$F(H, M) = 1 - \mathcal{L}(M(X), M_H(X)), \quad (4.2)$$

y la hipótesis se considera fiel cuando $F(H, M) \geq \delta$. El problema completo, por lo tanto, no consiste en encontrar un H cualquiera, sino uno que sea simultáneamente compacto, fiel al modelo y estable frente a las fuentes de variación que se detallan en el capítulo 6.

4.2. Técnicas necesarias

4.2.1. Atención entre variables

El mecanismo de atención de un Transformer produce, para cada capa y cada cabeza, una matriz que indica cuánto pesa cada token al construir la representación de los demás. El eje sobre el que se aplica la atención determina qué significa esa matriz. Si los tokens son posiciones espaciales o instantes de tiempo, la matriz describe relaciones entre posiciones y su tamaño crece con la resolución del dato. Si cada token es una variable completa, la matriz tiene tamaño $n \times n$ sobre las variables del fenómeno y cada celda admite la lectura directa que el framework necesita. Invertir las dimensiones del Transformer en ese sentido está validado como decisión de diseño efectiva y no solo conveniente Liu et al., 2024.

4.2.2. Agregación entre capas: attention rollout

Un modelo con L capas y h cabezas produce $L \times h$ matrices, de modo que hace falta un procedimiento para obtener una sola matriz representativa. El attention rollout propaga la atención a través de las capas incorporando las conexiones residuales Abnar y Zuidema, 2020:

$$\tilde{A} = \prod_{\ell=1}^L (\gamma I + (1 - \gamma) \bar{A}^{(\ell)}), \quad (4.3)$$

donde $\bar{A}^{(\ell)}$ es el promedio de las h cabezas de la capa ℓ , I es la identidad que simula la conexión residual y γ es la fracción residual. El resultado se normaliza por filas para que siga siendo estocástico.

El mismo trabajo que introduce el procedimiento advierte su límite: en un Transformer la información se mezcla progresivamente entre tokens al atravesar capas y conexiones residuales, por lo que los pesos crudos dejan de corresponder de forma confiable a los tokens de entrada Abnar y Zuidema, 2020. El rollout atenúa esa mezcla sin eliminarla. Por eso el grafo que se obtiene después debe tratarse como hipótesis sujeta a verificación y no como lectura directa del mecanismo interno.

4.2.3. Fidelidad de la atención

Que un mecanismo interno sea legible no implica que gobierne la salida. Al adaptar pruebas de fidelidad a un modelo de constancia de color temporal se observa que la atención no sostiene una relación causal con la predicción, mientras que otra forma de saliencia interna del mismo modelo sí la sostiene Rizzo et al., 2022. Ese resultado obliga a medir la fidelidad en cada caso, que es justamente lo que hace el cuarto eslabón de la cadena de evidencia.

4.2.4. Perturbación y ablación

La forma habitual de medir fidelidad consiste en perturbar una entrada y observar cuánto cae el desempeño. La técnica arrastra un problema conocido: una perturbación destructiva saca al dato

de la distribución con la que el modelo fue entrenado, con lo cual se termina midiendo la fragilidad del modelo y no la relevancia de lo perturbado. Generar perturbaciones que permanezcan dentro de la distribución evita ese efecto e identifica menos características críticas para explicar la misma decisión Meng et al., 2023. A esto se agrega que la métrica de fidelidad más extendida presenta fallas al trasladarse a series temporales, y que ningún método de perturbación resulta óptimo para todas las arquitecturas y conjuntos evaluados Šimić et al., 2025.

4.2.5. Discretización y variabilidad de la explicación

Pasar de una matriz continua a un conjunto finito de relaciones exige una regla de corte, y esa regla es una fuente de variación por sí misma. El fenómeno de fondo es que dos configuraciones que coinciden en la predicción pueden diferir en la explicación, algo documentado al comparar la variabilidad de explicaciones humanas con la de explicaciones generadas por modelos; en ese mismo trabajo, aplicar esquemas de discretización aumenta la similitud con el juicio humano sin alterar las predicciones Bogaert et al., 2026. De ahí que el framework trate la regla de discretización como un parámetro cuyo efecto hay que medir, y no como un detalle de implementación.

4.2.6. Dominio del caso de estudio

El caso de estudio trabaja con índices espectrales derivados de imágenes satelitales. Las bandas, resoluciones e índices disponibles en la constelación Sentinel-2, junto con sus aplicaciones en seguimiento agrícola, constituyen la referencia técnica de las variables que forman los nodos del grafo Segarra et al., 2020. Estos índices son fuertemente colineales entre sí, lo que hace que la estructura relacional entre ellos sea difícil de establecer por inspección y motiva el interés por extraerla desde el modelo.

5. PLAN DE TRABAJO

5.1. Estado a la fecha de este informe

El trabajo se organiza en tres etapas, que corresponden a los tres grupos de objetivos específicos del capítulo 2. La etapa de estudio está concluida: la revisión sistemática recorrió las seis primeras etapas del protocolo PRISMA, desde la formulación de la pregunta hasta la extracción de datos, y produjo el corpus de 25 referencias sobre el que se apoya el capítulo 3. La séptima etapa del protocolo, la redacción del estudio, se cierra con este informe.

La etapa de desarrollo está concluida en su parte formal. Las transformaciones que componen el pipeline están definidas, la cadena de evidencia está especificada eslabón por eslabón y la taxonomía diagnóstica está formulada. Lo que queda pendiente es la ejecución, que constituye la etapa de validación y ocupa el resto del calendario.

5.2. Actividades y calendario

La tabla 5.1 detalla las actividades. Las tres primeras filas registran trabajo ya concluido y se incluyen para dejar constancia del punto de partida. El resto corresponde a la etapa de validación, ordenada por dependencia: cada eslabón de la cadena de evidencia solo tiene sentido si el anterior fue superado, de modo que el orden de las filas es también el orden de ejecución obligado.

Cuadro 5.1: Actividades del plan de trabajo, con periodo estimado y estado.

Actividad	Periodo	Estado
Revisión sistemática bajo protocolo PRISMA 2020, etapas 1 a 6	Hasta septiembre 2026	Concluida
Formalización de las transformaciones del pipeline y de la condición de admisibilidad	Hasta septiembre 2026	Concluida
Especificación de la cadena de evidencia y de la taxonomía diagnóstica	Hasta septiembre 2026	Concluida
Redacción del informe de avance y cierre de la etapa 7 del protocolo	Septiembre 2026	En curso
Implementación del pipeline sobre el caso de estudio y entrenamiento del ensamble multi-semilla	Octubre 2026	Pendiente
Eslabón 1, estabilidad continua de la representación ante la semilla	Octubre 2026	Pendiente
Eslabón 2, estabilidad estructural ante el criterio de discretización	Octubre 2026	Pendiente
Eslabón 3, consenso frente al modelo nulo con corrección por comparaciones múltiples	Noviembre 2026	Pendiente
Eslabón 4, fidelidad predictiva por ablación dirigida con renormalización	Noviembre 2026	Pendiente

Actividad	Periodo	Estado
Eslabón 5, especificidad, robustez y compacidad	Noviembre a diciembre 2026	Pendiente
Triangulación con los cuatro paradigmas ortogonales y los baselines deterministas	Diciembre 2026	Pendiente
Construcción de la matriz de perfiles diagnósticos sobre los resultados	Diciembre 2026	Pendiente
Validación sobre conjunto sintético con estructura conocida	Enero 2027	Pendiente
Validación sobre un segundo dominio real	Enero a febrero 2027	Pendiente
Redacción del informe final	Marzo 2027	Pendiente

5.3. Dependencias y riesgos

Tres dependencias condicionan el calendario. La primera es de cómputo: los eslabones 1 y 2 requieren entrenar varias decenas de modelos con semillas distintas, de modo que el costo por corrida fija cuánto puede avanzarse por semana. La segunda es la disponibilidad del segundo dominio, que exige acceso al modelo y no solo a su matriz de atención, porque el eslabón de fidelidad necesita intervenir y volver a predecir. La tercera es la construcción del conjunto sintético, cuya estructura conocida es la única referencia externa disponible para el caso de estudio, dado que entre índices espectrales no existe una topología física verificada.

El riesgo principal del plan es que la cadena de evidencia se detenga en un eslabón temprano, es decir, que las relaciones extraídas no superen el umbral de estabilidad y no quede nada que evaluar en los eslabones siguientes. Ese desenlace no invalida el trabajo, porque la cadena está diseñada para que el eslabón en que una relación falla sea, por construcción, el diagnóstico de por qué falla. Un resultado de ese tipo se reportaría como tal.

6. PROPUESTA

6.1. Visión general

El framework se compone de tres transformaciones encadenadas que se aplican sobre un modelo ya entrenado, sin modificar sus pesos ni su arquitectura:

$$A \xrightarrow{\Phi} G \xrightarrow{\Psi} H \xrightarrow{F} \mathbb{R} \quad (6.1)$$

La primera convierte la matriz de atención en un grafo dirigido y ponderado. La segunda reduce ese grafo a una hipótesis relacional compacta. La tercera evalúa esa hipótesis contra el comportamiento del modelo del que salió. Las tres operan después del entrenamiento, que es lo que distingue a la propuesta de los enfoques donde el grafo se aprende como parámetro Cai et al., 2024 o se impone como conocimiento previo Zhao et al., 2026, y también del enfoque que obtiene estructura causal interviniendo las activaciones del modelo Kalnāre et al., 2025.

6.2. El instrumento: un ConvTransformer de índices

Para disponer de una matriz A entre variables hace falta un modelo cuya atención opere sobre ese eje. El modelo empleado modifica el Transformer estándar en cinco aspectos, todos orientados a ese fin:

1. **Tokens iguales a variables.** Cada uno de los n índices se trata como un token independiente. La dimensión n es configurable y no está atada al dominio del caso de estudio.
2. **Encoder convolucional por token.** Cada variable, de dimensiones $H \times W$, se procesa con un bloque convolucional que reduce la resolución espacial y extrae características locales. El encoder se comparte entre tokens, de modo que A no refleje capacidades desiguales de codificación.
3. **Proyección al espacio latente.** Las características de cada variable se aplanan y se proyectan a un espacio de embedding mediante una capa lineal.
4. **Atención multi-cabeza entre variables.** La atención se calcula entre los n tokens, no entre posiciones espaciales ni entre pasos temporales, lo que produce explícitamente una matriz $A \in \mathbb{R}^{n \times n}$ por cabeza y capa.
5. **Decoder convolucional.** La salida se decodifica para reconstruir la resolución original.

Conviene delimitar el alcance de este componente. El ConvTransformer no constituye la novedad del trabajo: es un vehículo instrumental cuya única función es producir, de manera controlada, una matriz A entre variables interpretables sin depender de un grafo predefinido. La contribución reclamada son las transformaciones y el sistema de validación que las acompaña. La delimitación importa por dos razones. Una es de honestidad comparativa: los trabajos que compiten en desempeño predictivo lo hacen bajo protocolos de benchmarking establecidos Liu et al.,

2024; Villaboni et al., 2025, y este trabajo no compite ahí, ya que el desempeño se reporta solo como condición de admisibilidad para verificar que la representación proviene de un modelo que aprendió algo del fenómeno. La otra es de generalidad: Φ depende de las propiedades algebraicas de A y no de su procedencia, de modo que en principio puede aplicarse a la matriz de atención entre variables de otras arquitecturas sin tocar sus pesos.

6.3. Transformación Φ : de la matriz al grafo

La primera transformación produce $G = (V, E, W)$, un grafo ponderado dirigido cuyos nodos $V = \{v_1, \dots, v_n\}$ son variables interpretables. Para evitar la dependencia de umbrales arbitrarios se emplea un criterio Top-K fijo que selecciona las K aristas más fuertes por fila, con lo cual el grafo nunca queda vacío:

$$\Phi(A) = (V, \{(i, j, A_{ij}) \mid A_{ij} \in \text{Top-}K(A_{i.})\}). \quad (6.2)$$

El operador Top-K rígido presenta una discontinuidad conocida: cuando $A_{i,(K)}$ y $A_{i,(K+1)}$ son numéricamente próximos, perturbaciones pequeñas invierten el orden y cambian el conjunto seleccionado. Por eso el segundo eslabón de la cadena contempla evaluar operadores alternativos, entre ellos Top-P adaptativo y α -entmax, y medir cuánto cambia la hipótesis al cambiar la regla. Tratar la discretización como parámetro medible, y no como detalle de implementación, responde a la observación de que dos configuraciones que coinciden en la predicción pueden diferir en la explicación Bogaert et al., 2026.

6.4. Transformación Ψ : del grafo a la hipótesis

La segunda transformación reduce G a $H = (E_H, R)$, con E_H el conjunto de relaciones que sobreviven y R su interpretación semántica. La reducción se plantea como el problema de compresión enunciado en el capítulo 4: el menor H que preserve al menos ϵ de la información del grafo. La doble exigencia de fidelidad y tamaño sigue el criterio de los métodos que destilan un modelo en un conjunto compacto de reglas y lo evalúan por ambas dimensiones a la vez Mekonnen et al., 2024.

El resultado de este paso es lo que distingue a la propuesta de la familia de mapas continuos. Un conjunto finito de aristas dirigidas sobre variables con nombre admite una operación que un mapa de relevancia no admite: eliminar una unidad concreta y medir qué pasa.

6.5. Transformación F : la cadena de evidencia

La tercera transformación no es una métrica única. Es una cadena de cinco eslabones acumulativos, con umbrales declarados antes de ejecutarla, donde cada eslabón solo se evalúa sobre las relaciones que superaron el anterior.

1. **Estabilidad continua.** Se entrena un ensamble de modelos con semillas distintas y se mide cuánto varía A entre corridas. Una relación que solo aparece en una corrida no es candidata a hipótesis. Este eslabón atiende directamente el hecho de que la explicación de un modelo

de atención cambia al reentrenar Harikrishnan, 2026.

2. **Estabilidad estructural.** Se varía la regla de discretización, en particular el valor de K y el operador empleado, y se mide cuánto cambia el conjunto de aristas seleccionadas. Una relación que aparece solo bajo un corte específico se descarta.
3. **Consenso frente a un modelo nulo.** Se contrasta la frecuencia con que una arista persiste entre semillas contra la probabilidad de que persista por azar, $P_{\text{azar}} = K/(N - 1)$, mediante una prueba binomial exacta. Como la prueba se aplica sobre las $N(N - 1)$ aristas posibles, se corrige por comparaciones múltiples con Bonferroni y con Benjamini-Hochberg.
4. **Fidelidad por ablación dirigida.** Se anula la entrada (i, j) de la matriz y se renormaliza la fila para preservar su estocasticidad, de modo que el modelo siga recibiendo una entrada válida, y se mide la caída de desempeño. La renormalización responde al problema documentado de que una perturbación destructiva mide la fragilidad del modelo y no la relevancia de lo perturbado Meng et al., 2023. La métrica concreta se elige con las precauciones que señala el análisis de métodos de perturbación sobre clasificadores temporales Šimić et al., 2025.
5. **Especificidad, robustez y compacidad.** Se verifica que la caída de desempeño sea específica de la arista ablacionada y no un efecto general, que la hipótesis resista ruido sobre A , y que su tamaño se mantenga acotado.

Ordenar los eslabones cumple una función diagnóstica. Cuando las métricas de explicabilidad se aplican en paralelo informan que algo falla sin indicar dónde, que es la crítica documentada sobre su falta de convergencia Stassin et al., 2024. En una cadena ordenada, el eslabón en que una relación cae es la respuesta a por qué cayó.

6.6. Triangulación entre paradigmas

Los cinco eslabones comparten, en parte, familia de supuestos. Para que el veredicto sobre una arista no dependa de una sola familia, la evidencia se triangula con cinco paradigmas: el probabilístico, que ya opera en el tercer eslabón, más cuatro ortogonales a él. El intervencional interviene la matriz y vuelve a predecir. El geométrico-topológico compara los grafos por distancia espectral del laplaciano, distancia de edición y estabilidad de los roles de cada nodo. El de teoría de la información mide dependencia sin suponer linealidad. El de baselines deterministas contrasta el grafo obtenido contra cuatro referencias construidas por fuera del modelo: correlación de Pearson, causalidad de Granger, un grafo aleatorio de Erdős-Rényi evaluado por Z-score y un grafo de vecindad espectral.

El baseline de Pearson se lee de forma invertida respecto de lo habitual. Si el grafo extraído coincide en alto grado con el de correlación lineal, la conclusión es que el modelo no aprendió nada que no estuviera ya en la correlación, y que el framework no aportó valor en ese caso. Es un criterio de falsación de la propia contribución.

6.7. Taxonomía diagnóstica

Cada arista termina caracterizada por un vector de cinco coordenadas, una por eslabón, que no se colapsa en un escalar. La discordancia entre coordenadas es informativa y un promedio pon-

derado la perdería. El vector se mapea a cuatro perfiles:

- **Relación estructural genuina:** estable entre semillas, estable ante la discretización, improbable bajo el modelo nulo y fiel bajo ablación.
- **Atajo predictivo:** fiel bajo ablación, porque el modelo efectivamente la usa, pero sin respaldo en los paradigmas ortogonales ni correspondencia con conocimiento del fenómeno.
- **Artefacto de arquitectura:** estable y frecuente, pero sin efecto al ablacionarla, lo que caracteriza a un sumidero de atención.
- **Ruido estocástico:** inestable ya en el primer eslabón.

La distinción entre las dos primeras categorías es la que motiva todo el diseño, y recoge la evidencia de que un modelo con métricas excelentes puede estar apoyándose en un atajo espurio invisible al desempeño agregado Lapuschkin et al., 2019.

6.8. Aplicabilidad a otros dominios

Como Φ solo exige que A cumpla la condición de admisibilidad, la pregunta por la transferencia a otro dominio no es sobre el fenómeno sino sobre el eje de la atención del modelo disponible. La respuesta admite tres casos.

Hay dominios de aplicación directa, donde el modelo publicado ya expone una representación relacional entre variables, como las redes de sensores espacio-temporales documentadas sobre calidad del aire, generación solar y plantas fotovoltaicas Altieri et al., 2025 o la reconstrucción de dependencias condicionales entre sensores industriales Zhang et al., 2026. Hay dominios que requieren adaptación, donde existe atención accesible pero su eje no son las variables nombradas, como la predicción de mapas de vegetación Bouaziz et al., 2026 o el modelo de aerodinámica cuya atención opera sobre espectrogramas X. Zhou et al., 2026. Y hay dominios que requieren un modelo nuevo, donde la estructura se impone de antemano en el espacio latente en lugar de leerse de una representación entrenada Spuler et al., 2026.

Para elegir el segundo dominio de validación se aplican cinco criterios ordenados por peso: que los tokens sean variables, que haya acceso al modelo y no solo a la matriz, porque el cuarto eslabón exige intervenir y volver a predecir, que el costo de entrenamiento admita un ensamble de varias decenas de semillas, que los datos sean públicos, y que exista conocimiento previo del fenómeno contra el cual contrastar el grafo. El candidato más realista bajo esos criterios son las redes de sensores ambientales con datos públicos Altieri et al., 2025.

7. CONCLUSIONES PRELIMINARES

La revisión sistemática deja una conclusión bastante clara sobre el estado del campo: obtener una estructura relacional desde un modelo profundo está resuelto por varias vías, y decidir si esa estructura merece crédito no lo está. Hay trabajos que aprenden el grafo como parámetro, otros que lo reciben como conocimiento previo y otros que lo obtienen interviniendo las activaciones del modelo. Lo que no aparece en el corpus revisado es un procedimiento para sostener una estructura leída de un modelo ya entrenado cuando no se dispone de una referencia externa contra la cual compararla.

Sobre esa brecha, el aporte de esta etapa es un diseño completo y no un resultado. Las tres transformaciones del pipeline están formalizadas, la condición de admisibilidad que debe cumplir la matriz de entrada está explícita, la cadena de cinco eslabones está especificada con umbrales declarados antes de ejecutarla, y la taxonomía que separa relación genuina de atajo predictivo, artefacto y ruido está formulada. Corresponde ser literal en este punto: nada de eso ha sido ejecutado todavía sobre el caso de estudio, y por lo tanto este informe no reporta resultados experimentales. La ejecución es el contenido de la etapa siguiente y está calendarizada en el capítulo 5.

Del propio corpus se desprenden tres advertencias que conviene dejar anotadas antes de ejecutar el plan. La primera es que buena parte de la ganancia atribuida a los Transformers en pronóstico de largo plazo podría provenir del mecanismo de parcheo y no de la atención entre variables Tang y Zhang, 2024; la propuesta no queda invalidada, porque no reclama que la atención mejore el desempeño, pero sí queda obligada a no presentarla como fuente privilegiada de conocimiento sin mostrarlo. La segunda es que el único caso del corpus donde la atención recupera un mecanismo verificable lo hace por coincidencia con una frecuencia que la teoría ya predecía X. Zhou et al., 2026, es decir, como hallazgo puntual y no como procedimiento repetible. La tercera es sobre la referencia externa: el trabajo más exigente en validación dispone de la topología física real de la instalación que modela Zhang et al., 2026, y entre índices espectrales no existe nada equivalente, con lo cual el conjunto sintético de estructura conocida deja de ser un complemento y pasa a ser la única referencia externa del plan.

Queda además una limitación del propio protocolo de revisión, que se declara aquí porque afecta la trazabilidad del corpus: el paso que va de los registros elegibles a las referencias finalmente incluidas se resolvió por juicio de relevancia documentado caso por caso, sin umbral cuantitativo explícito, y formalizarlo queda pendiente. En una línea parecida, el corpus documenta que dos configuraciones que coinciden en la predicción pueden diferir en la explicación Bogaert et al., 2026, lo que sugiere reportar la variabilidad entre semillas como parte del resultado y no tratarla como ruido a suprimir.

REFERENCIAS

- Abnar, S., & Zuidema, W. (2020). Quantifying Attention Flow in Transformers. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 4190-4197. <https://doi.org/10.48550/arXiv.2005.00928>
- Altieri, M., Ceci, M., & Corizzo, R. (2025). An end-to-end explainability framework for spatio-temporal predictive modeling. *Machine Learning*, 114(4). <https://doi.org/10.1007/s10994-024-06733-6>
- Bogaert, J., Escoufflaire, L., Descampe, A., Fairon, C., de Marneffe, M.-C., & Standaert, F.-X. (2026). Explanation Variability in Text Classification: Humans vs. LLMs. *Computational Linguistics*, 1-31. <https://doi.org/10.1162/COLI.a.624>
- Bouaziz, M., Ben Abbes, A., El Koundi, M., & Farah, I. R. (2026). ConvLSTM-GCN-Transformer: Spatiotemporal graph-attention model for vegetation index map forecasting. *Expert Systems with Applications*, 314, 131596. <https://doi.org/10.1016/j.eswa.2026.131596>
- Cai, W., Liang, Y., Liu, X., Feng, J., & Wu, Y. (2024). MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10), 11141-11149. <https://doi.org/10.48550/arXiv.2401.00423>
- Chefer, H., Gur, S., & Wolf, L. (2021). Transformer Interpretability Beyond Attention Visualization. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 782-791. <https://doi.org/10.48550/arXiv.2012.09838>
- Harikrishnan, S. (2026). Instability and interpretability discrepancies between CNNs and vision transformers in keratoconus detection. *Pattern Recognition Letters*, 204, 107-112. <https://doi.org/10.1016/j.patrec.2026.03.020>
- Kalnāre, M., Kitharidis, S., Bäck, T., & van Stein, N. (2025). *Mechanistic Interpretability for Transformer-based Time Series Classification*. arXiv: 2511.21514. <https://doi.org/10.48550/arXiv.2511.21514>
- Lapuschkin, S., Wäldchen, S., Binder, A., Montavon, G., Samek, W., & Müller, K.-R. (2019). Unmasking Clever Hans Predictors and Assessing What Machines Really Learn. *Nature Communications*, 10(1), 1096. <https://doi.org/10.48550/arXiv.1902.10178>
- Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. *International Conference on Learning Representations*. <https://doi.org/10.48550/arXiv.2310.06625>
- Mekonnen, E. T., Longo, L., & Dondio, P. (2024). A global model-agnostic rule-based XAI method based on Parameterized Event Primitives for time series classifiers. *Frontiers in Artificial Intelligence*, 7. <https://doi.org/10.3389/frai.2024.1381921>
- Meng, H., Wagner, C., & Triguero, I. (2023). Explaining time series classifiers through meaningful perturbation and optimisation. *Information Sciences*, 645, 119334. <https://doi.org/10.1016/j.ins.2023.119334>
- Reichstein, M., Camps-Valls, G., Stevens, B., Jung, M., Denzler, J., Carvalhais, N., & Prabhat. (2019). Deep learning and process understanding for data-driven Earth system science. *Nature*, 566(7743), 195-204. <https://doi.org/10.1038/s41586-019-0912-1>

- Rizzo, M., Conati, C., Jang, D., & Hu, H. (2022). *Evaluating the Faithfulness of Saliency-based Explanations for Deep Learning Models for Temporal Colour Constancy*. arXiv: 2211.07982. <https://doi.org/10.48550/arXiv.2211.07982>
- Segarra, J., Buchailot, M. L., Araus, J. L., & Kefauver, S. C. (2020). Remote Sensing for Precision Agriculture: Sentinel-2 Improved Features and Applications. *Agronomy*, 10(5), 641. <https://doi.org/10.3390/agronomy10050641>
- Šimić, I., Veas, E., & Sabol, V. (2025). A comprehensive analysis of perturbation methods in explainable AI feature attribution validation for neural time series classifiers. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-09538-2>
- Slack, D., Hilgard, S., Jia, E., Singh, S., & Lakkaraju, H. (2020). Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 180-186. <https://doi.org/10.48550/arXiv.1911.02508>
- Spuler, F., Kretschmer, M., Balmaseda, M. A., Gudoshava, M., & Shepherd, T. G. (2026). Disentangling Regional Impacts of Joint Teleconnections Using Causal Representation Learning. *Journal of Climate*, 39(17), 5173-5192. <https://doi.org/10.1175/JCLI-D-25-0700.1>
- Stassin, S., Corduant, V., Mahmoudi, S. A., & Siebert, X. (2024). Explainability and Evaluation of Vision Transformers: An In-Depth Experimental Study. *Electronics*, 13(1), 175. <https://doi.org/10.3390/electronics13010175>
- Tang, P., & Zhang, W. (2024). *Unlocking the Power of Patch: Patch-Based MLP for Long-Term Time Series Forecasting*. arXiv: 2405.13575. <https://doi.org/10.48550/arXiv.2405.13575>
- Villaboni, D., Castellini, A., Danesi, I. L., & Farinelli, A. (2025). *SENTINEL: Multi-Patch Transformer with Temporal and Channel Attention for Time Series Forecasting*. arXiv: 2503.17658. <https://doi.org/10.48550/arXiv.2503.17658>
- Zhang, Y., Lu, Y., Li, D., Bader, S., & Zio, E. (2026). Dynamic Causal Graph Network for Reliable Pipeline Leak Detection. *Reliability Engineering & System Safety*, 275, 112795. <https://doi.org/10.1016/j.ress.2026.112795>
- Zhao, S., Yang, H., Wang, Z., Khan, F., & Wang, Q. (2026). A causal-guided graph transformer with interpretability analysis for process fault diagnosis. *Journal of Loss Prevention in the Process Industries*, 102, 106022. <https://doi.org/10.1016/j.jlp.2026.106022>
- Zhou, F., Saha, A., Afzal, M., Parrish, R., Haynes, R. B., Iorio, A., & Lokker, C. (2026). Understanding Transformer-Based Classifications of Medical Text Using a Large Language Model for the Attribution of Feature Importance. *JMIR Medical Informatics*, 14, e81644. <https://doi.org/10.2196/81644>
- Zhou, X., Sun, J., Zhao, J., & Shuang, F. (2026). Explainable AI in Rotorcraft Aerodynamics: Autonomous Discovery and Dynamic Tracking of Vortex Ring State Mechanisms via Vision Transformers. *Aerospace*, 13(7), 590. <https://doi.org/10.3390/aerospace13070590>