

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

FRAMEWORK PARA RECONSTRUCCIÓN DE ESTRUCTURAS RELACIONALES DESDE REPRESENTACIONES LATENTES

PATRICIO JAVIER FIGUEROA GALLARDO
GABRIEL LEONARDO SANZANA CUIBIN

PROFESOR GUÍA: CHRISTOFFER MARCO LOFFLER

SEMINARIO DE TÍTULO

INFORME DE AVANCE

SEPTIEMBRE 2026

RESUMEN

Quien estudia un fenómeno con muchas variables acopladas elige hoy entre dos herramientas incompletas: los modelos matemáticos clásicos escriben la relación entre variables en sus ecuaciones, pero obligan a fijarla de antemano; los modelos de aprendizaje automático la ajustan desde los datos y no la declaran.

Este trabajo propone un framework metodológico para ese espacio intermedio, que opera sobre cualquier modelo cuya atención se calcule entre tokens que representan variables con nombre. De él extrae una matriz de interacción, conserva lo que persiste al repetir el entrenamiento con inicializaciones distintas y convierte esa estructura estable en un grafo dirigido y después en una hipótesis relacional compacta, enunciable fuera del modelo y evaluable.

El documento corresponde a la etapa de avance y presenta el diseño: las transformaciones del procedimiento, las condiciones que debe cumplir la representación de entrada y el criterio que decide cuándo una relación extraída se sostiene. Lo respaldan veinticinco referencias, doce identificadas mediante una revisión sistemática bajo el protocolo PRISMA 2020 y trece provenientes de una búsqueda complementaria. La aplicación al caso de estudio, índices espectrales derivados de imágenes satelitales, está en curso y este informe no reporta resultados experimentales.

Palabras clave: interpretabilidad, aprendizaje automático, mecanismos de atención, hipótesis relacional, revisión sistemática.

ABSTRACT

Anyone studying a phenomenon with many coupled variables chooses today between two incomplete tools: classical mathematical models write the relation among variables into their equations, but force it to be fixed beforehand; machine learning models fit it from the data and never state it.

This work proposes a methodological framework for that middle ground, one that operates over any model whose attention is computed among tokens representing named variables. From such a model it extracts an interaction matrix, keeps whatever persists when training is repeated under different initialisations, and turns that stable structure into a directed graph and then into a compact relational hypothesis, storable outside the model and open to evaluation.

This document corresponds to the progress stage and presents the design: the transformations of the procedure, the conditions the input representation must satisfy, and the criterion that decides when an extracted relation holds. It rests on twenty-five references, twelve identified through a systematic review under the PRISMA 2020 protocol and thirteen from a complementary search. Applying it to the case study, spectral indices derived from satellite imagery, is under way, and this report presents no experimental results.

Keywords: interpretability, machine learning, attention mechanisms, relational hypothesis, systematic review.

ÍNDICE GENERAL

Resumen/Abstract	i
Índice General	ii
Lista de Figuras	iv
Lista de Tablas	v
1. Introducción	1
1.1. Contexto del problema	1
1.2. Descripción del problema	1
1.3. Antecedentes	2
1.4. Propuesta y contribución	3
2. Objetivos	4
2.1. Objetivo general	4
2.2. Objetivos específicos	4
3. Estado del arte	5
3.1. Metodología de la revisión	5
3.1.1. Definición de la investigación	5
3.1.2. Búsqueda de literatura	5
3.1.3. Verificación de los artículos	7
3.2. Trabajos similares	8
3.2.1. Explicabilidad posterior al entrenamiento	8
3.2.2. Cuán confiable es una explicación	8
3.2.3. Estructura relacional aprendida, impuesta o intervenida	9
3.2.4. Atención entre variables y aplicaciones de dominio	10
3.3. Contribución de la propuesta	10
4. Marco teórico	12
4.1. Del Transformer estándar al ConvTransformer de índices	12
4.2. Agregación entre capas	12
4.3. Formalización del operador relacional	13
4.4. Medición de la calidad de una explicación	13
4.5. Dominio del caso de estudio	14
5. Metodología y plan de trabajo	15
5.1. Estado a la fecha de este informe	15
5.2. Datos	15
5.3. Procedimiento	17
5.4. Actividades y calendario	17
6. Propuesta	19
6.1. Planteamiento	19
6.2. Transformación matriz-grafo	19
6.3. Transformación grafo-hipótesis	20
6.4. Interpretación metodológica	20

6.5. Propiedades exigibles a una hipótesis relacional extraída de un modelo	21
7. Conclusiones preliminares	24
Referencias	26

LISTA DE FIGURAS

3.1. Diagrama de flujo PRISMA 2020 del proceso de identificación, cribado y selección de estudios. 7

6.1. Composición del framework: de los datos del fenómeno a una hipótesis relacional evaluada por fidelidad. 21

LISTA DE TABLAS

3.1. Familias del estado del arte, con su aporte y su límite. 11

5.1. Índices espectrales del caso de estudio, con la magnitud que describen y las bandas
Sentinel-2 de las que se calculan. 15

5.2. Plan de trabajo semana a semana del equipo, integrado por Patricio Javier Figueroa
Gallardo y Gabriel Leonardo Sanzana Cuibin. 17

1. INTRODUCCIÓN

1.1. Contexto del problema

Al diseñar el protocolo de revisión sistemática, se definió la siguiente pregunta de investigación: si es posible desarrollar un framework metodológico que transforme las matrices de atención de modelos de aprendizaje profundo en grafos dirigidos compactos, capaces de generar hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales de explicabilidad posteriores al entrenamiento.

Esa pregunta nace de una tensión que atraviesa cualquier disciplina que trabaje con fenómenos multivariantes. Por un lado están los modelos matemáticos clásicos, donde la relación entre variables se escribe explícitamente en las ecuaciones. Son transparentes y auditables, y su límite es la rigidez: obligan a decidir de antemano qué depende de qué, de modo que cuando el fenómeno no se comporta según esos supuestos el modelo no tiene cómo acomodarse. Por otro lado está el aprendizaje automático, que invierte ambas propiedades. Ajusta los datos sin exigir una estructura previa y predice mejor, pero no dice qué relación aprendió para lograrlo. La consecuencia práctica es que quien estudia un fenómeno complejo debe elegir entre una herramienta que entiende y no se adapta, y otra que se adapta y no explica.

Esa elección resulta especialmente incómoda en disciplinas donde el objetivo no se agota en predecir. En las ciencias de la Tierra se espera que un modelo aporte conocimiento sobre el proceso subyacente, y no solamente un pronóstico ajustado [1]. Un modelo que anticipa correctamente el comportamiento de un conjunto de índices espectrales, pero que no permite formular ninguna hipótesis sobre cómo se relacionan entre sí, deja el trabajo científico a medio camino. El interés por cerrar esa brecha es lo que motiva el presente trabajo.

Los componentes de la pregunta acotan el alcance. La población son los modelos de aprendizaje profundo cuya representación interna produce una matriz de atención, y dentro de ellos aquellos donde esa atención se calcula entre tokens que representan variables con significado propio, no entre posiciones espaciales ni entre instantes de tiempo. Esa distinción determina qué describe la matriz de atención y, por lo tanto, si tiene sentido leerla como una afirmación sobre el fenómeno. La condición que se problematiza es la opacidad de esos modelos, agravada porque sus matrices cambian entre ejecuciones aunque el desempeño se mantenga. El comparador son las técnicas de explicabilidad ya establecidas, que atribuyen importancia a cada variable por separado o presentan la relevancia como un mapa continuo. Y el resultado buscado es una hipótesis relacional compacta y dirigida, definida sobre variables con nombre, que pueda enunciarse fuera del modelo y someterse a refutación.

1.2. Descripción del problema

La matriz de atención parece el lugar natural donde buscar esa estructura relacional, porque registra cuánto pesa cada variable al procesar a las demás. Leerla directamente como si fuera una explicación tropieza, sin embargo, con tres obstáculos que la literatura revisada documenta con evidencia experimental.

El primero es la inestabilidad. La matriz no es una propiedad del fenómeno sino un producto del entrenamiento, y dos corridas del mismo modelo sobre los mismos datos, con semillas distintas, producen matrices que no coinciden aunque su desempeño sea equivalente. Toda explicación derivada de una sola corrida hereda ese problema sin declararlo, porque nada en el resultado informa sobre su propia reproducibilidad.

El segundo es que la legibilidad de un mecanismo interno no garantiza que ese mecanismo gobierne la predicción. Rizzo et al. [2] adaptaron dos pruebas de fidelidad provenientes del procesamiento de lenguaje natural a un modelo de constancia de color temporal, y observaron que la atención no sostiene una relación causal con la salida, mientras que la confianza, otra forma de saliencia interna del mismo modelo, sí la sostiene. El resultado obliga a medir la fidelidad en cada caso en lugar de suponerla.

El tercero es que la alternativa más difundida tampoco resiste el escrutinio. Slack et al. [3] construyeron una técnica capaz de detectar cuándo una entrada proviene de las perturbaciones que generan LIME y SHAP, y con ella lograron que un clasificador abiertamente discriminatorio no fuera señalado por ninguno de los dos métodos en ninguna instancia de prueba. Antes que ellos, Lapuschkin et al. [4] evidenciaron que modelos con un desempeño de estado del arte pueden resolver la tarea mediante atajos espurios; en su estudio, identificaron un clasificador que distinguía una categoría basándose únicamente en una marca de agua presente en las imágenes, sin que las métricas de desempeño estándar detectaran dicha anomalía. De acuerdo con Kalnāre et al. [5], “Existing explainability methods often focus on input-output attributions, leaving the internal mechanisms largely opaque”.

De ahí se sigue el enunciado del problema. No existe un procedimiento que permita decidir, con criterios declarados de antemano, cuándo una relación entre variables obtenida desde la representación interna de un modelo de aprendizaje automático constituye una hipótesis sobre el fenómeno, y cuándo es un artefacto del entrenamiento.

1.3. Antecedentes

La literatura avanzó bastante en obtener estructura relacional y bastante menos en verificarla. Esa asimetría es el hueco donde se inserta la propuesta, y conviene mostrarla con los dos extremos que la delimitan.

Del lado arquitectónico, Liu et al. [6] demostraron que invertir las dimensiones del Transformer, de manera que cada serie completa constituya un token en lugar de cada instante, mejora el desempeño en pronóstico multivariado de largo plazo. Ese resultado es la condición de posibilidad del problema aquí planteado: de él se sigue que un modelo puede diseñarse para que su atención describa relaciones entre variables, en vez de relaciones entre posiciones. Sin esa inversión previa, la matriz que se quiere analizar simplemente no existiría.

En cuanto a la validación, el estudio de Zhang et al. [7] es el más riguroso del corpus, ya que emplea una referencia externa verificable. A diferencia de la mayoría de los trabajos, que validan el grafo mediante métricas internas del modelo, este enfoque permite contrastar la estructura aprendida con la topología física real de la instalación de tuberías. Ese contraste fija el estándar de análisis y, al mismo tiempo, mide la distancia que lo separa del caso de estudio de este trabajo: entre índices espectrales no existe una topología conocida contra la cual comparar. Lo único disponible ahí es la partición en grupos de índices que comparten bandas de origen, descrita en el capítulo 5, que sale de la aritmética de las fórmulas y no dice nada sobre la relación entre esos grupos. En el extremo opuesto está el uso puramente predictivo, ejemplificado por Bouaziz et al. [8], cuyo modelo combina memoria convolucional, convolución de grafo y atención, predice con error bajo, transfiere entre sensores, y en ningún momento comprueba qué relación entre variables aprendió para conseguirlo.

Entre ambos extremos queda el espacio vacío: existen maneras de obtener una estructura y existen dominios donde compararla contra una verdad conocida, pero falta un procedimiento que permita sostener una estructura obtenida de un modelo cuando esa verdad conocida no está

disponible.

1.4. Propuesta y contribución

La propuesta opera de forma agnóstica sobre cualquier modelo cuya atención se calcule entre tokens que representan variables con nombre. Si el modelo ya desplegado cumple esa condición, el procedimiento se aplica directamente sobre él para extraer su matriz de interacción; si no la cumple, o para el caso de estudio de este trabajo, se entrena una arquitectura alternativa sobre los mismos datos que sí la satisfaga. El entrenamiento se repite muchas veces con inicializaciones distintas y se conserva lo que persiste entre repeticiones. Sobre esa estructura estable operan tres transformaciones encadenadas, que convierten la matriz en un grafo dirigido, el grafo en una hipótesis relacional compacta, y la hipótesis en una medida de su propia fidelidad.

La contribución que se reclama está en el criterio, no en la extracción. Obtener un grafo desde una matriz es un ejercicio algorítmicamente simple, y varios de los trabajos revisados lo resuelven de una u otra forma. Lo que ninguno reúne es una manera explícita de decidir si ese grafo dice algo del fenómeno o solo del entrenamiento que lo produjo. El framework responde con una lista declarada de propiedades que una relación debe exhibir para sostenerse, verificadas por separado y fijadas antes de ejecutar el procedimiento, y con una taxonomía que separa una relación estructural genuina de un atajo predictivo, de un hallazgo no reproducible y de ruido.

El presente informe documenta ese diseño y la revisión que lo sustenta. La ejecución del procedimiento sobre el caso de estudio ya está en curso, según el periodo detallado en el capítulo 5, pero este informe no reporta resultados experimentales.

2. OBJETIVOS

2.1. Objetivo general

Desarrollar un framework metodológico que, operando de forma agnóstica sobre cualquier modelo cuya atención se calcule entre tokens de variables con nombre, transforme esa representación en una hipótesis relacional compacta e interpretable sobre las variables del fenómeno, y establecer el criterio que decide cuándo esa hipótesis puede sostenerse.

2.2. Objetivos específicos

Los tres objetivos siguientes cubren, en orden, la formalización del método, la construcción del criterio con que se lo evalúa y su aplicación sobre el caso de estudio.

1. Formalizar matemáticamente las transformaciones que llevan de la matriz de interacción entre variables al grafo dirigido, y de este a la hipótesis relacional compacta, junto con las condiciones que debe cumplir una representación para ser entrada válida del framework.
2. Diseñar un criterio que evalúe las relaciones extraídas y determine cuáles se sostienen como hipótesis estructurales genuinas.
3. Aplicar el framework sobre el caso de estudio de índices espectrales y evaluar la hipótesis obtenida con el criterio anterior, reportando relación por relación cuáles se sostienen y cuáles quedan descartadas.

3. ESTADO DEL ARTE

3.1. Metodología de la revisión

Esta sección describe, en cuatro fases (definición de la investigación, búsqueda de literatura, verificación de los artículos y análisis de la investigación), el procedimiento seguido para identificar, filtrar y analizar la literatura sobre la conversión de matrices de atención en estructuras relacionales interpretables, según las directrices PRISMA 2020¹, elegidas porque dejan registro de cada decisión de selección y permiten reconstruir el corpus a partir de ese registro.

3.1.1. Definición de la investigación

El área de estudio son los modelos de aprendizaje profundo cuya representación interna produce una matriz de atención, específicamente aquellos donde esa atención se calcula entre tokens que representan variables con significado físico, con foco en la opacidad de sus mecanismos de decisión y en la inestabilidad estocástica de sus matrices de atención entre ejecuciones de entrenamiento. La revisión responde a la siguiente pregunta, formulada según el modelo PICO: ¿es posible desarrollar un framework metodológico que transforme las matrices de atención de modelos de aprendizaje profundo en grafos dirigidos compactos, capaces de generar hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales de explicabilidad posteriores al entrenamiento?

El alcance queda delimitado por los cuatro componentes de la pregunta y por un marco temporal de publicaciones entre 2022 y 2026:

- **Población.** Modelos de aprendizaje profundo cuya representación interna produce una matriz de atención que opera entre tokens que representan variables con significado físico.
- **Intervención.** La condición de caja negra de estos modelos: opacidad del mecanismo de decisión e inestabilidad de la matriz de atención entre ejecuciones.
- **Comparador.** Métodos tradicionales de explicabilidad, es decir técnicas de atribución marginal por variable como SHAP y LIME, y la visualización de mapas continuos de atención.
- **Resultado.** La reconstrucción de una hipótesis relacional compacta, dirigida y falsable sobre las variables, estadísticamente reproducible y fiel al comportamiento del modelo.

3.1.2. Búsqueda de literatura

Se construyó un conjunto de términos por cada componente PICO, con sinónimos unidos por el operador OR dentro de cada componente y los cuatro grupos combinados entre sí con AND. La cadena resultante, que se transcribe completa para que la búsqueda sea reproducible, es la siguiente:

```
("Transformer" OR "multivariate Transformer" OR "multivariate time series" OR "time series" OR "MTS" OR "latent representation" OR "latent space" OR "attention matrix" OR "attention weights" OR "tokenization" OR "variable tokenization" OR "channel independence" OR "patching" OR "inverted transformer" OR "iTransformer")  
  
AND ("black box" OR "black-box" OR "model opacity" OR "opacity" OR "attention instability" OR "instability" OR "seed variability" OR "seed" OR "variability" OR "stochasticity" OR "spurious shortcuts")
```

¹M. J. Page, J. E. McKenzie, P. M. Bossuyt *et al.*, “The PRISMA 2020 statement: an updated guideline for reporting systematic reviews”, *BMJ*, vol. 372, art. n71, 2021. <https://doi.org/10.1136/bmj.n71>. Plantilla del diagrama de flujo disponible en <https://www.prisma-statement.org/prisma-2020-flow-diagram>.

```

OR "shortcut learning" OR "spurious correlation" OR "Clever Hans"
OR "uninterpretable" OR "uninterpretability" OR "mechanistic
interpretability")

AND ("Explainable AI" OR "XAI" OR "SHAP" OR "LIME" OR "feature
attribution" OR "saliency maps" OR "saliency" OR "attention maps" OR
"integrated gradients" OR "Granger causality" OR "causal inference")

AND ("relational graph" OR "directed graph" OR "relational
structure" OR "compact graph" OR "graph" OR "knowledge graph" OR
"causal graph" OR "falsifiable" OR "falsifiability" OR "auditable"
OR "auditability" OR "reproducible" OR "reproducibility" OR
"faithfulness" OR "fidelity" OR "sanity checks" OR "post-hoc
explanation")

```

Los cuatro bloques corresponden, en ese orden, a población, intervención, comparador y resultado. La cadena se aplicó de forma consistente en las tres bases consultadas, sobre los campos de título, resumen y palabras clave: Scopus ($n = 191$), Web of Science ($n = 100$) y PubMed ($n = 28$), con un total de 319 registros identificados; no se consultaron registros de protocolos. La consolidación de los archivos .ris, la deduplicación y el filtrado progresivo se realizaron en Zotero, con la última actualización del conjunto de referencias el 5 de septiembre de 2026.

Además de las bases de datos se realizó una búsqueda complementaria asistida por inteligencia artificial, anterior a la aplicación del protocolo e incorporada después a su flujo como vía de identificación por otros métodos, que es la columna derecha de la figura 3.1. La herramienta empleada fue Claude Scientist², puesta a disposición del equipo por el profesor guía, y se usó con dos propósitos: localizar artículos que la cadena booleana no recuperaba y revisar el formato del documento contra la pauta de la Escuela. Esa búsqueda aportó 36 artículos obtenidos a texto completo el 5 de septiembre de 2026, ninguno duplicado respecto de los registros ya recuperados. La herramienta propone candidatos y no decide la inclusión: cada estudio se leyó a texto completo, se verificó su DOI y se contrastaron contra el artículo los datos extraídos de él, con el procedimiento que describe la sección 3.1.3. Al obtenerse ya completos y de forma individual, estos documentos no pasaron por los filtros de deduplicación, identificador DOI, acceso al texto ni marco temporal de publicación, ni por el cribado de título y resumen: entraron directamente a la evaluación de elegibilidad con los criterios de la sección 3.1.3, y de ellos quedaron 13 incluidos. El diagrama de flujo de la figura 3.1 recoge esa diferencia de recorrido: la columna de otros métodos va de la identificación a la evaluación de elegibilidad, sin cajas de cribado. De los 25 estudios incluidos, 13 provienen de esta búsqueda complementaria y 12 de las bases de datos; entre los primeros están las referencias fundacionales de las técnicas que la propuesta emplea, incluida la que introduce la propagación de atención por capas, que la cadena booleana no recuperó. Seis de esas referencias son anteriores a 2022 y quedan fuera del marco temporal fijado para las bases de datos. Se conservan por dos razones: la búsqueda que las trajo es previa al protocolo y no estaba sujeta a ese filtro, y son las obras que definen las técnicas sobre las que el trabajo se apoya, no literatura reciente que el cribado hubiera debido recuperar.

Se consideraron únicamente artículos redactados en inglés; los escritos en otros idiomas se descartaron. En total se incluyeron 25 documentos en la revisión, y la figura 3.1 ilustra el flujo detallado de cribado e inclusión según PRISMA 2020.

²Anthropic, *Claude Scientist* [modelo de lenguaje de gran tamaño], 2026. <https://claude.com/programs/team-plan-for-scientists>.




Figura 3.1: Diagrama de flujo PRISMA 2020 del proceso de identificación, cribado y selección de estudios.

3.1.3. Verificación de los artículos

Se llevó a cabo un cribado por resumen de los 137 registros, seguido de una evaluación a texto completo, contrastando cada documento con los criterios de inclusión (periodo de publicación 2022–2026, redacción en inglés, y tipo de documento restringido a artículos de investigación primaria y trabajos de conferencia en Scopus y Web of Science, sin restricción en PubMed para no perder literatura técnica no clínica) y de exclusión (lo opuesto, más registro duplicado detectado en Zotero, de 319 a 221 registros (–98); ausencia de identificador DOI auditable, de 221 a 201 (–20); y texto completo no disponible a través de los accesos institucionales del equipo, de 201 a 137 (–64)). Los desacuerdos entre revisores se resolvieron por discusión hasta alcanzar una decisión común sobre cada estudio.

Sobre los 137 registros restantes se aplicó el cribado por resumen, que excluyó 116 documentos por no auditar un mecanismo interno de atención ni producir una estructura relacional entre variables. De los 21 estudios buscados a texto completo se recuperaron 17; de estos se excluyeron 5 durante la evaluación de elegibilidad, cuatro por contenido redundante con un estudio ya incluido y uno por quedar superado por evidencia primaria localizada en la búsqueda complementaria. En esa búsqueda se evaluaron los 36 documentos y se excluyeron 23: cuatro por no disponer de un mecanismo interno de atención auditable, ocho por ser revisiones de dominio sin aporte metodológico y once por aplicar explicabilidad posterior al entrenamiento sin producir ni evaluar estructura relacional entre variables.

Los 25 estudios incluidos se clasificaron en seis bloques temáticos según su función en la revisión (premisa de la atención como objeto auditable, insuficiencia de la explicabilidad tradicional, validación por perturbación, estructura relacional compacta, arquitectura y tokenización, y dominio y aplicación), y se asociaron, mediante una matriz de doble entrada entre estudio y sección, a las secciones del informe a las que aportan; eso admite que un mismo estudio se cite en más de una.

Para el análisis, de cada estudio incluido se extrajeron título, DOI, descripción del aporte, fecha de publicación, muestra, metodología, resultados y conclusión, verificados contra el texto completo y no contra el resumen, para corregir descripciones cuyo detalle experimental no coincidía con lo declarado en él. Los datos se analizaron señalando el aporte al framework propuesto y sus límites, incorporando a la síntesis tanto los estudios que la respaldan como aquellos cuyos resultados la cuestionan, entre ellos los que atribuyen la mejora de rendimiento al mecanismo de parcheo y no a la atención, y los que muestran que dos métodos de atribución igualmente fieles ordenan las variables de forma distinta. El análisis de las citas de estas veinticinco referencias, es decir a qué trabajos citan ellas mismas, queda fuera del alcance de esta revisión y se declara como línea de trabajo futuro.

3.2. Trabajos similares

El contraste se organiza por familias y no trabajo por trabajo, porque investigaciones que a primera vista no se parecen terminan compartiendo la misma limitación. Lo que define cada familia es el tipo de objeto que entrega como explicación y el momento del ciclo de vida del modelo en que ese objeto se produce.

3.2.1. Explicabilidad posterior al entrenamiento

La primera familia calcula relevancia sobre un modelo ya entrenado. Chefer et al. [9] propusieron calcularla mediante descomposición de Taylor propagada por capas, conservando la relevancia total a través de los bloques de atención y de las conexiones residuales; evaluada sobre el conjunto de validación de ImageNet, sobre el subconjunto anotado ImageNet-Segmentation y sobre una tarea de texto, su propuesta supera de forma consistente a los mapas de atención crudos y a la propagación heurística. Aun así, su salida es un mapa de relevancia espacial: responde qué partes de la entrada pesaron, no qué relación entre variables sostiene la predicción.

El límite se vuelve más incómodo al comparar métodos entre sí. Zhou et al. [10] evaluaron cuatro explicadores sobre un clasificador Transformer de texto médico, con doscientos estudios estratificados y más de ochenta mil tokens atribuidos, y encontraron que SHAP y gradientes integrados alcanzan una fidelidad prácticamente igual, en torno a 0,22, con correlación mutua apenas moderada: dos explicaciones igualmente fieles ordenan las variables de manera distinta. Stassin et al. [11] generalizaron el problema al cruzar varios métodos de explicación con métricas de fidelidad, coherencia, robustez y complejidad sobre arquitecturas de visión: métricas que declaran medir la misma propiedad muestran convergencia y correlación mínimas entre sí, de modo que el orden de mérito entre métodos depende de cuál métrica se haya elegido para construirlo. Por eso este trabajo no adopta valores de referencia tomados de la literatura: verifica cada propiedad por separado y contrasta cada una contra un control declarado antes de medir, como se detalla en la sección 6.5.

3.2.2. Cuán confiable es una explicación

La segunda familia no propone explicaciones, sino que mide cuánto se puede confiar en ellas. Slack et al. [3] construyeron una técnica de andamiaje que detecta si una entrada proviene de la distribución real o de las perturbaciones que generan LIME y SHAP, y responde con un modelo distinto en cada caso; aplicada sobre tres conjuntos de decisiones de alto riesgo, consiguió que clasificadores contruidos para discriminar por raza no fueran señalados por ninguno de los dos métodos en ninguna instancia. Lapuschkin et al. [4] habían mostrado antes, mediante propagación de relevancia y análisis espectral sobre PASCAL VOC 2007 y sobre agentes de aprendizaje por

refuerzo, que un modelo con exactitud de estado del arte puede estar resolviendo la tarea por un atajo espurio: el caso de la categoría caballo, detectada en realidad por una marca de agua presente solo en esas imágenes, es el origen del término *Clever Hans*, uno de los descriptores con que se construyó el bloque de intervención de la cadena de búsqueda. La conclusión conjunta es que el rendimiento no valida el mecanismo.

A esos resultados se suma un hallazgo más reciente. Harikrishnan [12] entrenaron una red convolucional y un Transformer de visión con siete semillas distintas sobre cuatro mil imágenes de topografía corneal, y midieron la fiabilidad de las explicaciones por inestabilidad de los mapas, similitud estructural entre semillas y caída de rendimiento al borrar las regiones destacadas. El Transformer resultó bastante más estable entre semillas que la red convolucional, con un orden de magnitud menos de inestabilidad, y a la vez menos fiel: borrar lo que señala apenas afecta su confianza. Estabilidad y fidelidad no son la misma propiedad y pueden moverse en direcciones opuestas, razón por la cual el criterio de validación de este trabajo las trata como dos exigencias separadas.

3.2.3. Estructura relacional aprendida, impuesta o intervenida

La tercera familia sí produce estructura, aunque por vías que la propuesta no puede seguir. Una parte la aprende como componente del modelo: Cai et al. [13] descomponen la serie en el dominio de la frecuencia para separar escalas y aplican convolución de grafo adaptativa de saltos múltiples, con lo que obtienen un grafo interpretable por escala temporal. Otra parte la recibe de antemano, como el Graph Transformer de Zhao et al. [14], que construye un grafo de propagación de fallos mediante cribado de causalidad de Granger consciente del retardo, lo esparsifica y lo usa para condicionar el cálculo de la atención: es el trabajo más parecido a la tubería completa que aquí se propone, y a la vez muestra la diferencia de fondo, pues su análisis de interpretabilidad se realiza sobre una topología que el modelo recibió y no puede poner a prueba.

El caso mejor validado del corpus es el de Zhang et al. [7], que reemplaza el grafo de correlaciones entre sensores por uno de dependencias condicionales, reconstruido mediante independencia condicional momentánea, y lo contrasta contra la topología física real de la instalación: el esqueleto causal aprendido coincide con la disposición conocida de la planta, incluso bajo ruido severo en la señal. Ese trabajo fija el estándar de validación y delimita la dificultad del problema abordado aquí: la validación es posible porque existe una verdad de referencia física, y entre índices espectrales no la hay. Cierra el grupo Mekonnen et al. [15], que destila un clasificador de series temporales en un conjunto compacto de reglas a partir de primitivas de evento parametrizadas, evaluándolo con cinco métricas que incluyen exactitud, fidelidad, robustez, profundidad del árbol y número de nodos; su doble exigencia, que la estructura sea fiel al modelo y lo bastante pequeña para inspeccionarse, es la que este trabajo adopta.

Un caso aparte es el de Kalnāre et al. [5], que traslada técnicas de interpretabilidad mecanicista desde el procesamiento de lenguaje a un Transformer de clasificación de series temporales. Mediante parcheo de activaciones, saliencia de atención y autocodificadores dispersos, tratando cada cabeza y cada instante como unidades causales que se intervienen de forma sistemática, construyen grafos causales dirigidos del flujo interno de información hasta los logits de clase: el objeto que obtienen es exactamente el que aquí se persigue. La diferencia está en el precio que pagan, pues intervenir el modelo exige acceso a sus estados internos y a la posibilidad de modificarlos durante la inferencia, algo que no siempre está disponible; la propuesta renuncia a eso y asume el costo de validar por otra vía.

3.2.4. Atención entre variables y aplicaciones de dominio

La cuarta familia no aborda interpretabilidad sino dónde conviene aplicar la atención, y de ella depende que exista siquiera la matriz que este trabajo analiza. Liu et al. [6] invirtieron las dimensiones del Transformer para que cada serie completa fuera un token, y dejaron establecido el punto que la propuesta hereda: cuando el token agrupa varias variables del mismo instante, los mapas de atención resultan poco significativos. Villaboni et al. [16] avanzan en la misma dirección combinando atención de canal con atención temporal mediante un mecanismo de parches múltiples. En sentido contrario, Tang y Zhang [17] atribuyen buena parte del mérito de los Transformers al mecanismo de parcheo antes que a la atención entre variables, y lo sostienen mostrando que un perceptrón multicapa sobre parches iguala a arquitecturas bastante más complejas; obliga a no presentar la atención como fuente privilegiada de conocimiento sin haberlo demostrado.

Las aplicaciones a dominios cercanos muestran el mismo vacío. Bouaziz et al. [8] predicen mapas completos de índices de vegetación combinando memoria convolucional, convolución de grafo y Transformer, y en ningún momento comprueban qué relación entre índices aprendió el modelo; Spuler et al. [18] sí obtienen una estructura con sentido físico, pero insertándola de antemano en el espacio latente de un autocodificador variacional en lugar de extraerla; y Altieri et al. [19] muestran que las herramientas de explicabilidad pensadas para datos tabulares, de imagen o de grafo resultan inefectivas sobre redes de sensores espacio-temporales. El caso más llamativo del corpus es el de Zhou et al. [20], donde la atención de un Transformer de visión sobre señales de vibración se concentra en una banda que coincide con una frecuencia que la teoría aerodinámica ya predecía de forma independiente: es el único trabajo revisado donde la atención recupera un mecanismo verificable fuera del modelo, y ocurrió por coincidencia con una magnitud ya conocida, no mediante un procedimiento repetible sobre un problema donde esa magnitud no esté disponible de antemano.

3.3. Contribución de la propuesta

La tabla 3.1 resume el contraste. Leídas en conjunto, las cuatro familias dibujan un panorama asimétrico: obtener un objeto relacional está resuelto por varias vías, y decidir si ese objeto merece crédito no lo está.

Lo que falta es un procedimiento para falsar una estructura leída, es decir, ni aprendida como parámetro, ni impuesta como conocimiento previo, ni obtenida interviniendo el modelo. Los trabajos que evalúan explicaciones lo hacen sobre atribuciones por variable, con métricas que no convergen entre sí [10], [11], y no sobre las relaciones de un grafo. Los que aplican estas arquitecturas a dominios afines predicen bien sin auditar lo que aprendieron [8], [19]. Y el único caso donde la atención resulta informativa por sí sola llegó ahí por coincidencia con un mecanismo conocido de antemano [20].

La propuesta ocupa ese espacio combinando cuatro elementos que el corpus presenta por separado y nunca juntos: obtención de la estructura desde un modelo entrenado para ser legible, sin intervenir el modelo de producción; consenso entre repeticiones del entrenamiento; validación de cada relación contra un conjunto declarado de propiedades exigibles, que traslada la carga de la prueba desde la representación del modelo hacia la relación misma; y una taxonomía que separa relación genuina de atajo predictivo, hallazgo no reproducible y ruido. Cada elemento tiene precedente aislado en la literatura; lo que no tiene precedente es la composición.

Tabla 3.1: Familias del estado del arte, con su aporte y su límite.

Familia	Trabajos	A favor	En contra
Explicabilidad posterior al entrenamiento	[9], [10], [11]	Se aplican sin reentrenar y están consolidadas en la práctica	Entregan importancia por variable o mapa continuo; las métricas que las comparan no convergen
Confiabilidad de las explicaciones	[3], [4], [12]	Acotan con evidencia experimental cuánto se puede confiar	Diagnostican el problema sin entregar un procedimiento de decisión
Estructura aprendida, impuesta o intervenida	[5], [7], [13], [14], [15]	Producen estructura explícita; un caso la contrasta contra topología física verificable	Auditarla exige reentrenar, o es supuesto previo sin hipótesis nula, o requiere intervenir las activaciones
Atención entre variables y dominios afines	[6], [8], [16], [17], [18], [19], [20]	Hacen posible que exista una matriz entre variables y muestran viabilidad en dominios cercanos	No zanzan si la ganancia viene de la atención o del parcheo, y no auditan la estructura aprendida
Propuesta	Modelo agnóstico al desplegado, entrenado como alternativa cuando hace falta, con validación de cada arista contra propiedades declaradas de antemano, consenso entre repeticiones y taxonomía diagnóstica		

4. MARCO TEÓRICO

4.1. Del Transformer estándar al ConvTransformer de índices

Un Transformer estándar, tal como se emplea en procesamiento de lenguaje natural o en visión por computadora, aplica la atención entre tokens que representan posiciones espaciales, como los parches de una imagen, o posiciones dentro de una secuencia. En problemas multivariados donde lo que interesa modelar son las dependencias entre variables, y no entre posiciones, esa configuración presenta dos limitaciones. La atención se diluye entre miles de tokens espaciales, con lo que las relaciones entre variables quedan ocultas, y no existe una matriz de atención $A \in \mathbb{R}^{n \times n}$ explícita entre variables que pueda extraerse y analizarse. El resultado de Liu et al. [6] apunta en la misma dirección desde el lado del desempeño: cuando el token agrupa varias variables del mismo instante, los mapas de atención resultan poco significativos.

El modelo instrumental de este trabajo, un ConvTransformer de índices, resuelve ambas limitaciones tratando cada una de las n variables como un token independiente, de manera que la dimensión n es configurable y no queda atada al dominio de aplicación, y calculando la atención multi-cabeza entre esos tokens y no entre posiciones espaciales ni pasos temporales, lo que produce explícitamente una matriz $A \in \mathbb{R}^{n \times n}$ por cada cabeza y capa. El requisito de diseño que impone el framework sobre ese componente es uno solo: todas las variables deben codificarse con el mismo procedimiento antes de calcular la atención, para que la matriz resultante refleje relaciones del fenómeno y no una capacidad de codificación desigual entre variables. Cómo se implementa esa codificación, arquitectura del encoder, número de capas, dimensiones concretas, es una decisión del caso de estudio y no de la formulación general.

La razón de esta estructura es directa. Si la atención se aplicara entre posiciones espaciales, la matriz tendría tamaño $HW \times HW$, sería inmanejable y no admitiría lectura relacional entre variables. Al aplicarla entre las n variables, la matriz tiene tamaño $n \times n$ y cada celda A_{ij} admite una interpretación concreta: cuánto la variable i atiende a la variable j al producir su predicción. La arquitectura es además agnóstica al dominio, porque los n tokens pueden ser índices espectrales, sensores industriales o variables de proceso, y lo único que se exige es que cada variable tenga una representación procesable por el encoder.

4.2. Agregación entre capas

Un modelo con L capas y h cabezas produce $L \times h$ matrices de atención, de modo que hace falta un procedimiento para obtener una sola que represente al modelo completo. El framework no fija cuál debe ser ese procedimiento, sino las condiciones que su resultado tiene que cumplir, según se detalla en el capítulo 6. La instancia de este trabajo emplea el attention rollout de Abnar y Zuidema [21], que propaga la atención a través de las capas incorporando las conexiones residuales:

$$\tilde{A} = \prod_{\ell=1}^L (\alpha I + (1 - \alpha) \bar{A}^{(\ell)}), \quad (4.1)$$

donde $\bar{A}^{(\ell)}$ es el promedio de las h cabezas de la capa ℓ , la identidad I simula la conexión residual y α es la fracción residual. El resultado se normaliza por filas para que siga siendo estocástico. Los mismos autores advierten el límite del procedimiento: en un Transformer la información se mezcla progresivamente entre tokens al atravesar capas y conexiones residuales, con lo cual los

pesos crudos dejan de corresponder de forma confiable a los tokens de entrada. El rollout atenúa esa mezcla sin eliminarla, y esa es la razón de fondo por la que el grafo que se obtiene después debe tratarse como hipótesis sujeta a verificación y no como lectura directa del mecanismo interno.

4.3. Formalización del operador relacional

Sea un modelo de aprendizaje automático entrenado sobre un conjunto de datos,

$$M_\theta : X \rightarrow Y, \quad (4.2)$$

donde X es el espacio de entrada, Y el espacio de salida y θ los parámetros aprendidos. Durante el entrenamiento el modelo genera una representación latente

$$Z = M_\theta^L(X), \quad (4.3)$$

con Z el espacio interno aprendido por la red en una capa L . A partir de esa representación se construye la matriz de interacción $A \in \mathbb{R}^{n \times n}$, que es la matriz agregada de la sección anterior y no una de las matrices de atención por capa y cabeza de las que proviene, y donde cada elemento A_{ij} expresa la intensidad de interacción entre dos componentes latentes i y j . La matriz es agnóstica al dominio: el índice n puede recorrer índices espectrales, sensores industriales o variables de proceso sin que cambie nada de lo anterior.

Esa matriz se comporta como un operador relacional y debe cumplir tres propiedades para ser entrada válida del framework. Sus valores son no negativos, $A_{ij} \geq 0$. Sus filas suman aproximadamente uno, $\sum_j A_{ij} \approx 1$, lo que permite leerla como una cadena de Markov dirigida. Y es asimétrica, de modo que en general $A_{ij} \neq A_{ji}$ y la dirección de la relación queda codificada. Las tres en conjunto forman la condición de admisibilidad, y una representación que no las satisfaga queda fuera del alcance del framework mientras no se le aplique una adaptación explícita.

4.4. Medición de la calidad de una explicación

Las técnicas necesarias para evaluar el resultado provienen de un cuerpo de trabajo cuya conclusión general es que casi ninguna medida de calidad puede adoptarse sin examinarla antes. Que un mecanismo interno sea legible no implica que gobierne la salida, según mostraron Rizzo et al. [2] al comparar atención y confianza como formas de saliencia sobre un mismo modelo, de manera que la fidelidad hay que medirla en cada caso.

La forma habitual de medirla consiste en perturbar una entrada y observar cuánto cae el desempeño, y ahí aparece un problema conocido. Una perturbación destructiva saca al dato de la distribución con la que el modelo fue entrenado, con lo cual lo que se termina midiendo es la fragilidad del modelo y no la relevancia de lo perturbado. Meng et al. [22] abordan ese defecto generando perturbaciones que permanecen dentro de la distribución mediante un modelo generativo, e identifican con ello menos características críticas para explicar la misma decisión. El análisis de Šimić et al. [23] agrega que la métrica de fidelidad más extendida presenta fallas cuando se traslada a series temporales, y que ningún método de perturbación resulta óptimo para todas las arquitecturas y conjuntos evaluados. Ambos resultados obligan a justificar la medida elegida en lugar de tomarla prestada.

Queda un tercer elemento, más sutil, que atañe al paso de una matriz continua a un conjunto finito de relaciones. Toda regla de corte es en sí misma una fuente de variación, y el fenómeno de fondo lo documentan Bogaert et al. [24] al comparar la variabilidad de explicaciones humanas

con la de explicaciones generadas por modelos: dos configuraciones que coinciden en la predicción pueden diferir en la explicación, y en su experimento la discretización aumenta la coincidencia con el juicio humano sin alterar las predicciones. Por eso el framework trata la regla de discretización como un parámetro cuyo efecto hay que medir, y no como una decisión de implementación que se fija una vez y se olvida.

4.5. Dominio del caso de estudio

El caso de estudio trabaja con índices espectrales derivados de imágenes satelitales. Las bandas, resoluciones e índices disponibles en la constelación Sentinel-2 constituyen la referencia técnica de las variables que forman los nodos del grafo [25], y su aplicación ya consolidada en el seguimiento agrícola de precisión [25] es parte de por qué se eligió este dominio como caso de validación. Estas variables son fuertemente colineales entre sí, condición que vuelve poco practicable establecer la estructura relacional por inspección directa y que explica el interés por obtenerla desde un modelo. La motivación de fondo no es solo predictiva: en las ciencias de la Tierra, donde se emplean estos índices, se espera que un modelo aporte conocimiento sobre el proceso subyacente y no solamente un pronóstico ajustado [1], exigencia que este dominio comparte con el resto de los que el framework busca abarcar.

5. METODOLOGÍA Y PLAN DE TRABAJO

5.1. Estado a la fecha de este informe

El trabajo avanza en tres etapas, y a la fecha de este informe dos están cerradas: la revisión sistemática, que recorrió el protocolo desde la formulación de la pregunta hasta la extracción de datos y dejó como producto el corpus de veinticinco referencias sobre el que se apoya el capítulo 3, y el diseño, con las transformaciones definidas, la condición de entrada válida explícita, el criterio de validación formulado como un conjunto de propiedades exigibles y la taxonomía de resultados definida. La tercera, la etapa de validación, ya está en curso, según se detalla en el resto de este capítulo: el criterio se fijó antes de mirar cualquier resultado, para que no termine acomodándose a lo que los datos entreguen. Las dos etapas cerradas son las que cubren los objetivos específicos primero y segundo del capítulo 2; el tercero depende de la etapa en curso y queda fuera de lo que este informe puede reportar.

El uso de herramientas de inteligencia artificial se concentra en dos puntos, declarados también en la sección 3.1.2: la búsqueda complementaria de literatura y la revisión del formato de este documento contra la pauta de la Escuela, ambas apoyadas en Claude Scientist. La redacción, la decisión de incluir cada estudio y la verificación de cada dato citado contra su fuente son del equipo.

5.2. Datos

El caso de estudio se apoya en doce índices espectrales calculados sobre imágenes Sentinel-2 de nivel L2A, obtenidas a través de Google Earth Engine¹ y alineadas espacial y temporalmente entre sí. Cada índice es un cociente o una combinación de unas pocas bandas de reflectancia del sensor, según las fórmulas del catálogo público de scripts de Sentinel Hub². La tabla 5.1 los reúne con la magnitud que cada uno describe y las bandas de las que se calcula.

Tabla 5.1: Índices espectrales del caso de estudio, con la magnitud que describen y las bandas Sentinel-2 de las que se calculan.

Índice	Qué describe	Bandas
NDVI	Vigor de la vegetación verde, el índice de referencia del área	B8, B4
EVI	Vigor corregido por efecto atmosférico y de suelo, útil donde el NDVI satura	B8, B4, B2
EVI2	Versión del anterior sin banda azul, menos sensible al ruido atmosférico	B8, B4
SAVI	Vigor con corrección de suelo, para coberturas parciales como una viña	B8, B4
KNDVI	Versión no lineal del NDVI, que mantiene sensibilidad en vegetación densa	B8, B4
MARI	Contenido de antocianinas, asociado a estrés y a senescencia foliar	B3, B5, B7
ARI	Contenido de antocianinas en su formulación básica	B3, B5
CHL_REDEGE	Contenido de clorofila estimado desde el borde rojo	B7, B5

¹N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau y R. Moore, “Google Earth Engine: Planetary-scale geospatial analysis for everyone”, *Remote Sensing of Environment*, vol. 202, pp. 18–27, 2017. <https://doi.org/10.1016/j.rse.2017.06.031>.

²Catálogo de índices y scripts para Sentinel-2: <https://custom-scripts.sentinel-hub.com/custom-scripts/sentinel/sentinel-2/>.

Índice	Qué describe	Bandas
NDMI	Humedad de la vegetación, por contraste entre infrarrojo cercano y de onda corta	B8A, B11
NDII	La misma humedad medida con la banda ancha del infrarrojo cercano	B8, B11
NDWI	Contenido de agua en superficie	B3, B8
PSRI	Grado de senescencia de la planta	B4, B2, B6

Intervienen nueve bandas en total, y como cada índice usa solo dos o tres de ellas, los doce quedan repartidos en cinco grupos que comparten las mismas bandas de origen: infrarrojo cercano y rojo para los cinco primeros, verde y borde rojo para los tres de antocianinas y clorofila, el contraste con el infrarrojo de onda corta para los dos de humedad, y un grupo propio para NDWI y otro para PSRI. Esa partición sale de las fórmulas y no de una decisión del método, así que funciona como referencia analítica del caso real. Es parcial, eso sí: dice qué índices comparten bandas de origen, no qué relación existe entre grupos, que es lo que el trabajo busca.

El sitio proviene del catastro de viveros 2024 del Ministerio de Agricultura, publicado en su infraestructura de datos espaciales³: un archivo vectorial en coordenadas UTM huso 19 Sur con 3185 puntos, de los cuales 58 registran vid o uva entre sus especies. De ellos se eligió el de mayor superficie plantada con *Vitis vinifera*, un predio de 41,05 hectáreas en la comuna de Pencahue, Valle del Maule, en torno a los 35,45° de latitud sur y 71,83° de longitud oeste. La ventana temporal cubre desde enero de 2018 hasta diciembre de 2025, ocho temporadas completas, y se conservaron únicamente las escenas con menos del 3 % de píxeles nubosos, lo que deja 186 fechas útiles con una cadencia irregular impuesta por la nubosidad y no por el calendario del satélite. La resolución de trabajo es de 10 metros por píxel sobre una ventana de 500 metros de lado, de modo que el resultado es un tensor de 186 fechas por 52 por 52 píxeles por 12 índices; seis de esos índices dependen de bandas cuya resolución nativa es de 20 metros y quedan remuestreadas, así que su detalle espacial real es la mitad del que sugiere el almacenamiento.

La tarea sobre la que se entrena el modelo es la reconstrucción enmascarada, y su forma concreta merece precisión porque de ella depende que la matriz signifique algo. Cada fecha genera doce muestras, una por índice a reconstruir. Durante el entrenamiento no se oculta solo el índice objetivo: se ocultan cinco de los doce, el objetivo más cuatro sorteados al azar en cada muestra, de modo que el modelo reconstruye desde siete canales visibles. La razón es que varios de los índices son casi colineales entre sí, y ocultando uno solo bastaría con mirar a su vecino más parecido para acertar, con lo cual la atención podría quedar plana sin que el desempeño lo delatara. Ocultando además cuatro distractores, ese vecino está ausente buena parte del tiempo y la fila correspondiente tiene que discriminar. La lectura de la matriz, en cambio, se hace siempre en la condición canónica de un solo índice oculto, para que cada fila responda a la pregunta de quién depende ese índice cuando los otros once están disponibles.

La partición entre entrenamiento y validación es cronológica: las fechas se ordenan y el último 20 % queda para validación. Esa elección respeta el orden temporal, pero deja una asimetría conocida que hay que declarar, porque el ciclo anual de la vid atraviesa cinco fases fenológicas con comportamiento espectral distinto y las fechas no se reparten por igual entre ellas. El bloque final de la serie sobrerrepresenta algunas fases y deja otras casi ausentes, de manera que el criterio

³Infraestructura de Datos Espaciales del Ministerio de Agricultura de Chile: <https://ide.minagri.gob.cl/>.

de parada pesa de forma desigual los regímenes del cultivo. Corregirlo exige particionar dentro de cada fase, y esa variante quedó implementada como control para medir el efecto de la asimetría; cuál de las dos se adopta para la corrida definitiva es una de las decisiones de la etapa de validación.

5.3. Procedimiento

El método se ejecuta en cuatro etapas. La primera prepara el dato: descarga de las escenas, alineamiento entre fechas, descarte por nubosidad, estandarización por canal y armado de las muestras de la tarea enmascarada.

La segunda entrena el modelo del que se obtiene la matriz de interacción, y lo entrena muchas veces con inicializaciones distintas. De cada corrida se conserva la matriz de atención agregada entre capas y cabezas, leída en la condición canónica descrita en la sección anterior. Esa matriz dice qué mira el modelo, que no es lo mismo que decir de qué depende, y resolver esa diferencia es precisamente lo que el criterio de validación tiene a su cargo.

La tercera aplica las dos transformaciones formalizadas en el capítulo 6. La discretización convierte cada matriz en un grafo dirigido y ponderado, y la unidad de análisis deja de ser el grafo de una corrida para pasar a ser la frecuencia con que cada relación reaparece entre corridas; sobre esa estructura de consenso opera después la compresión que reduce el grafo a una hipótesis enunciable fuera del modelo.

La cuarta somete cada relación de esa hipótesis a las propiedades de la sección 6.5, verificándolas una por una y registrando, para cada relación descartada, cuál no cumplió. La falsabilidad externa se apoya, en este caso de estudio, en la partición en grupos de bandas compartidas de la sección anterior, que es la única referencia analítica disponible: una hipótesis que se limitara a reproducir esa partición estaría redescubriendo la aritmética de las fórmulas y no diría nada del cultivo, mientras que una relación entre grupos distintos sí sería una afirmación sobre el fenómeno.

5.4. Actividades y calendario

La tabla 5.2 detalla el plan semana a semana del equipo, desde el inicio del trabajo hasta la última entrega del año. Ese horizonte llega al informe final del 20 de noviembre de 2026, que cierra la entrega del año y no el trabajo de tesis: el reporte relación por relación que pide el tercer objetivo específico pertenece a la etapa posterior a este calendario. Las cuatro primeras semanas corresponden a trabajo concluido y se incluyen para dejar constancia del punto de partida; el resto pertenece a la etapa de validación. La columna *Opcional* recoge una línea de trabajo paralela y no comprometida: la exploración de un segundo dominio ajeno a los datos satelitales, que se aborda solo si el avance de la línea principal lo permite.

Tabla 5.2: Plan de trabajo semana a semana del equipo, integrado por Patricio Javier Figueroa Gallardo y Gabriel Leonardo Sanzana Cuibin.

Semana	Plan para la semana	Opcional
13–19 ago 2026	Revisión del estado del arte; estructuración del framework como método generalizable; pruebas de robustez entre semillas	
20–26 ago 2026	Incorporación del conjunto de datos del Ministerio de Agricultura como referencia de contraste; primeras pruebas del framework propio	
27 ago–2 sept 2026	Puesta en marcha del servidor de cómputo; se constata que el volumen de artículos por filtrar, treinta y seis, exige un cribado sistemático	

Semana	Plan para la semana	Opcional
3–9 sept 2026	Aplicación del protocolo PRISMA; actualización de la carta Gantt; redacción del informe de avance	
11 de septiembre de 2026	Entrega del informe de avance	
14–20 sept 2026	Continuación de los experimentos en curso: experimento de intervención sobre el grafo de dependencia dirigida entre índices espectrales	
21–27 sept 2026	Continuación de los experimentos del framework; documentación de los primeros hallazgos; mejora de la legibilidad de las salidas del código	
28 sept–4 oct 2026	Contraste de los hallazgos del experimento contra la literatura y el marco teórico	
5–11 oct 2026	Repetición de los experimentos sobre distintas coordenadas; ordenamiento de las salidas del código para facilitar su lectura	
12–18 oct 2026	Redacción del análisis del experimento; continuación de los experimentos; redacción de las formulaciones empleadas	Exploración de un segundo dominio que no use datos satelitales
19–25 oct 2026	Profundización de los experimentos según lo que arroje el análisis; elaboración de un diagrama; presentación de las salidas del código	Preparación de los datos y del entorno del segundo dominio; primeros experimentos
26 oct–1 nov 2026	Análisis en profundidad de los resultados y de su relación con la propuesta	Ampliación de los experimentos del segundo dominio y revisión de resultados preliminares
2–8 nov 2026	Revisión general del documento previa a la redacción del informe final; redacción de las formulaciones empleadas	Cierre de los experimentos del segundo dominio y ordenamiento de los hallazgos para el informe final
9–15 nov 2026	Redacción del informe final	
20 de noviembre de 2026	Entrega del informe final, última entrega del año	

6. PROPUESTA

6.1. Planteamiento

Conviene fijar primero qué se persigue, porque de eso depende cómo leer todo lo que sigue: el fin de este trabajo no es explicar un modelo de aprendizaje automático, sino producir una hipótesis relacional sobre el fenómeno que ese modelo aprendió a representar. Explicar el modelo, decir qué relación pesó al producir una salida, es un paso instrumental hacia ese fin, no el fin en sí mismo. Un procedimiento que se detuviera en la explicación del modelo dejaría el trabajo a medio camino, sin haber dicho nada todavía sobre las variables del fenómeno.

De ahí una decisión que conviene declarar explícita: el framework opera de forma agnóstica sobre cualquier modelo cuya atención se calcule entre tokens que representan variables con nombre, el mismo principio que Liu et al. [6] formalizaron al invertir las dimensiones del Transformer estándar para el pronóstico multivariado. Si el modelo ya desplegado cumple esa condición, el procedimiento se aplica directamente sobre él, de forma transparente, para extraer la matriz de interacción; si no la cumple, o para el caso de estudio de esta tesis, se entrena una arquitectura alternativa sobre los mismos datos que sí la satisfaga. El ConvTransformer de índices que describe el capítulo 4 es esa arquitectura alternativa para el caso de estudio; el framework no queda atado a ella ni a los detalles de su implementación, sino al principio de tokens por variable que la sostiene.

De ese modelo, ya sea el desplegado o el entrenado como alternativa, se obtienen, capa por capa y cabeza por cabeza, tantas matrices de atención como produzca la arquitectura. Lo que el framework exige es que exista un procedimiento de agregación que las reduzca a una sola matriz de interacción A y que esa matriz cumpla las condiciones de admisibilidad del capítulo 4; cuál sea ese procedimiento queda como decisión de cada instancia y no como parte de la propuesta. La instancia de esta tesis parte del *attention rollout* de Abnar y Zuidema [21], que propaga la atención a través de las capas incorporando la conexión residual, con la salvedad que los propios autores señalan: la mezcla de información entre tokens al atravesar capas se atenúa, no desaparece. Reemplazarlo por otra agregación que produzca una matriz admisible no altera ninguna de las transformaciones que siguen, y cuál conviene usar es una de las cosas que la etapa de validación tiene que examinar. El objeto de estudio pasa a ser esa matriz A y no el modelo que la produjo.

A eso se suma el tratamiento de la inestabilidad. Como una sola corrida no informa sobre su propia reproducibilidad, el entrenamiento del modelo alternativo se repite muchas veces con inicializaciones distintas, y la unidad de análisis deja de ser la matriz de una corrida: pasa a ser la frecuencia con que una relación reaparece entre repeticiones. El desempeño predictivo del modelo alternativo se reporta apenas como condición de admisibilidad, para verificar que la representación de la que se extrae A proviene de un modelo que efectivamente aprendió algo, y no como un resultado con el que competir: los trabajos que sí compiten en desempeño lo hacen bajo protocolos de *benchmarking* establecidos [6], [16], y esta propuesta no reclama superioridad predictiva sobre ellos. Sobre la estructura que sobrevive al filtro de repeticiones operan las tres transformaciones que siguen.

6.2. Transformación matriz-grafo

La primera transformación del framework corresponde a

$$\Phi : A \rightarrow G, \tag{6.1}$$

donde $G = (V, E, W)$ es un grafo ponderado dirigido, cuyo conjunto de nodos $V =$

$\{v_1, \dots, v_n\}$ tiene un nodo por cada variable interpretable del fenómeno. El conjunto de aristas se define como

$$E = \{(v_i, v_j) : A_{ij} > \tau\}, \quad (6.2)$$

donde τ corresponde al criterio de selección con que se extraen las relaciones relevantes; su forma concreta se fija al ejecutar el procedimiento, y no en esta etapa de diseño.

Esta transformación convierte una representación continua de interacciones en una estructura discreta e interpretable, al precio de introducir un criterio de selección que es en sí mismo una fuente de variación, incluso cuando la predicción del modelo no cambia, tal como documentan Bogaert et al. [24] al comparar explicaciones humanas y generadas por modelos. Esa es precisamente la razón por la que la arista que sale de aquí es una candidata y no un resultado: entre las propiedades que el criterio de validación exige está la de no depender de las decisiones internas del procedimiento, de modo que una arista que solo existe por el corte elegido no sobrevive.

6.3. Transformación grafo-hipótesis

La segunda transformación corresponde a

$$\Psi : G \rightarrow H, \quad (6.3)$$

donde H representa una hipótesis relacional compacta. Formalmente, $H = (E_H, \mathcal{R})$, con E_H el conjunto reducido de relaciones relevantes y $\mathcal{R}$ su interpretación semántica asociada. La extracción de la hipótesis puede plantearse como un problema de compresión,

$$\min_H |H| \quad \text{sujeto a} \quad I(H, G) \geq \gamma, \quad (6.4)$$

donde $I(H, G)$ mide la información preservada entre el grafo original y la hipótesis reducida, y γ es el mínimo aceptable. El objetivo, por lo tanto, no es recuperar todos los circuitos internos del modelo sino obtener una explicación estructural mínima capaz de conservar la información relevante. Esa doble exigencia, que la estructura sea fiel y a la vez lo bastante pequeña para poder inspeccionarse, es la misma que plantean Mekonnen et al. [15] al evaluar sus reglas por fidelidad y por tamaño de forma simultánea.

6.4. Interpretación metodológica

El framework completo puede expresarse como la composición

$$X \rightarrow M_\theta \rightarrow A \xrightarrow{\Phi} G \xrightarrow{\Psi} H \xrightarrow{F} \mathbb{R}, \quad (6.5)$$

donde la tercera transformación, F , evalúa la fidelidad de la hipótesis respecto del comportamiento del modelo y es la que el criterio de la sección 6.5 tiene a su cargo. La figura 6.1 despliega esa misma cadena indicando qué objeto entrega cada eslabón y en qué punto interviene el consenso entre repeticiones. Esta formulación es la que permite diferenciar la propuesta de lo que ya existe.




Figura 6.1: Composición del framework: de los datos del fenómeno a una hipótesis relacional evaluada por fidelidad.

Frente a los modelos matemáticos tradicionales, la diferencia está en el origen de la estructura: allí es impuesta previamente mediante supuestos, y aquí emerge desde la representación aprendida. Frente a los métodos de interpretabilidad clásicos, como el de Chefer et al. [9], la diferencia está en el objeto entregado: esos métodos calculan un mapa de relevancia por variable de entrada, no relaciones entre variables. Frente a la estructura que se aprende como parámetro del propio modelo, como el grafo por escala temporal de Cai et al. [13], la diferencia es que aquí la estructura se obtiene de un modelo construido para ser legible desde el inicio y no como subproducto de una arquitectura orientada a predecir. Frente a la interpretabilidad mecanicista, que recupera circuitos internos mediante intervención directa sobre las activaciones, la diferencia es de objetivo y de costo: ese enfoque explica el modelo y exige acceso a sus estados internos, tal como se aprecia al contrastar con el trabajo de Kalnāre et al. [5], mientras que aquí el modelo se usa como instrumento para hablar del fenómeno sin necesidad de intervenirlo. Y frente a los grafos causales construidos con conocimiento previo, como el de Zhao et al. [14], la diferencia es que la propuesta no requiere una estructura causal preexistente, con lo cual evita sesgar la explicación hacia un conocimiento que podría estar incompleto.

De ahí se sigue la posición del framework respecto de las dos familias descritas en la introducción. No reemplaza al modelo matemático ni al modelo de aprendizaje automático: se ubica entre ambos, usando la capacidad de ajuste del segundo para descubrir estructura, y devolviendo esa estructura en la forma explícita y discutible que caracteriza al primero.

6.5. Propiedades exigibles a una hipótesis relacional extraída de un modelo

Una hipótesis obtenida de esta manera no vale por haber sido obtenida. Las transformaciones anteriores producen relaciones candidatas, y lo que sigue es decidir cuáles merecen sostenerse.

Cada propiedad se enuncia como una exigencia invariante y se acompaña de tres campos que se rellenan al aplicarla: el *procedimiento* con que se verifica, el *alcance* bajo el cual se afirma y el *resultado* obtenido. Un cambio de dominio, de arquitectura o de experimento modifica los tres campos y no el enunciado, que es lo que permite que el framework se traslade sin reescribir su criterio.

P1. Reproducibilidad. La hipótesis reaparece al reajustar el modelo bajo una configuración fija. *Procedimiento:* un estadístico de concordancia entre reajustes independientes, declarado a priori. *Alcance:* la configuración que se fije; la reproducibilidad entre configuraciones distintas corresponde a P8 y no a esta propiedad.

P2. Invariancia a decisiones arbitrarias. La hipótesis sobrevive a variar aquellas decisiones del procedimiento que no alteran la cantidad estimada: el umbral, el esquema de agregación, el submuestreo, el criterio de corte. *Procedimiento:* un barrido de cada decisión sobre un rango

declarado, reteniendo la hipótesis solo si sobrevive en todo él. *Alcance*: la lista de decisiones clasificadas como arbitrarias, que se enumera de forma explícita. Sin esta exigencia el riesgo es concreto, porque dos configuraciones que coinciden en la predicción pueden diferir en lo que señalan [24].

- P3. No redundancia.** La hipótesis aporta algo sobre el conjunto de las demás variables, y no es reproducible ni por efectos de nodo ni por sustitutos que carecen de información de par. *Procedimiento*: al menos un control negativo construido para fallar, declarado antes de medir. *Alcance*: el condicionante respecto del cual se afirma la no redundancia.
- P4. Uso efectivo por el modelo.** El modelo no solo contiene la relación: la emplea. *Procedimiento*: intervención sobre el modelo y medida del cambio de comportamiento, en lugar de cualquier lectura observacional de sus parámetros, porque que un mecanismo interno sea legible no implica que sostenga la predicción [2]. *Alcance*: la intervención concreta y qué caminos deja abiertos. La elección de la intervención no es inocua: una perturbación que se aparta de la distribución de entrenamiento mide la fragilidad del modelo y no la relevancia examinada [22], y ningún método de perturbación se traslada sin más de una arquitectura a otra [23].
- P5. Falsabilidad externa.** La hipótesis es enunciable y contrastable fuera del modelo que la produjo. *Procedimiento*: contraste contra una fuente independiente, con la potencia alcanzable declarada junto al resultado. *Alcance*: la fuente y lo que puede y no puede discriminar. Una hipótesis falsada por este procedimiento se retira y pasa a P7. Cuando el dominio dispone de una estructura conocida de antemano, esta propiedad se verifica por comparación directa, como en el trabajo de Spuler et al. [18], que la impone en el espacio latente. El caso de estudio de esta tesis no dispone de una estructura así, y la única fuente independiente a su alcance es la partición en grupos de índices que comparten bandas de origen del capítulo 5, que discrimina poco: dice qué índices se calculan a partir de las mismas bandas y nada sobre la relación entre grupos distintos.
- P6. Compacidad.** El conjunto retenido es inspeccionable por una persona. *Procedimiento*: un criterio de retención declarado antes de mirar, con el tamaño resultante reportado. *Alcance*: el criterio; si distintos criterios legítimos arrojan tamaños incompatibles, se reportan todos. Es la misma doble exigencia de fidelidad y tamaño que plantean Mekonnen et al. [15].
- P7. Trazabilidad.** Se publican tanto las hipótesis retenidas como las descartadas, cada descarte con la propiedad que falló y el procedimiento que lo detectó. *Procedimiento*: registro acumulativo, sin reescritura retroactiva. *Alcance*: toda la vida del trabajo y no solo su versión final.
- P8. Condicionalidad declarada.** Las decisiones que cambian la cantidad estimada, y no solamente su valor, forman parte del enunciado de la hipótesis y no de sus notas de implementación. *Procedimiento*: enumerar esas decisiones, fijar una y declararla en el enunciado del resultado. *Alcance*: una hipótesis afirmada bajo una configuración constitutiva no se afirma bajo otra sin volver a verificarla.

La octava merece justificación, porque es la que separa esta lista de una enumeración de buenas prácticas. Sin ella, una decisión que redefine qué se está estimando se confunde con una decisión arbitraria, y su efecto aparece como un fallo de P2 cuando no lo es. Distinguir las obli-

ga a clasificar de antemano cada decisión del procedimiento en una de las dos categorías, y esa clasificación pasa a formar parte del diseño y no del anexo técnico.

Dos precisiones sobre cómo se combinan. La primera es que las propiedades no se promedian en un único número: cuando las medidas de calidad se aplican en paralelo y se resumen, informan que algo falla sin señalar dónde, que es la crítica documentada sobre su falta de convergencia [11]. Se evalúan por separado y se reporta cuál falló. La segunda es que no son intercambiables, y la evidencia más clara la aportan Harikrishnan [12], que entrenaron dos arquitecturas con varias semillas sobre imágenes de topografía corneal y midieron por separado la estabilidad de las explicaciones y su fidelidad al modelo: la arquitectura más estable resultó ser la menos fiel. Una relación puede cumplir P1 y fallar P4, de modo que verificar una no ahorra verificar la otra.

De ahí se sigue la lectura del resultado. Una relación que cumple las ocho propiedades es una relación estructural genuina, que es lo que el trabajo persigue. Una que el modelo usa pero que las demás variables explican es un atajo predictivo, que es exactamente el modo de fallo que documentan Lapuschkin et al. [4] en modelos con métricas excelentes que resuelven la tarea por una vía que nadie había mirado. Una que supera el examen sobre los datos pero no reaparece al reajustar es un hallazgo no reproducible. Y una que falla ya en P1 es ruido. El valor del procedimiento está tanto en lo que retiene como en poder decir por qué descartó el resto.

7. CONCLUSIONES PRELIMINARES

La revisión sistemática deja una conclusión bastante nítida sobre el estado del campo. Obtener una estructura relacional desde un modelo de aprendizaje automático está resuelto por varias vías: hay trabajos que la aprenden como parámetro del modelo, otros que la reciben como conocimiento previo y otros que la obtienen interviniendo las activaciones. Lo que no aparece en el corpus revisado es un procedimiento para sostener una estructura obtenida de una representación aprendida en los casos, que son la mayoría, donde no se dispone de una referencia externa contra la cual compararla. Esa ausencia es la que da sentido a la propuesta y define su alcance.

El aporte de esta etapa es un diseño y no un resultado, y conviene decirlo con precisión para no prometer más de lo entregado. Están formalizadas las transformaciones que llevan de la matriz de interacción al grafo y de este a la hipótesis compacta, incluida la condición de que las matrices por capa y cabeza se agreguen en una sola, para la cual el caso de estudio parte del *attention rollout* [21] sin comprometerse con él, está explícita la condición que debe cumplir una representación para ser entrada válida, está especificado el criterio de validación con sus condiciones fijadas antes de ejecutarlo, y está formulada la taxonomía que separa relación genuina de atajo, hallazgo no reproducible y ruido. La ejecución sobre el caso de estudio ya está en curso, según el calendario del capítulo 5, pero este documento no reporta resultados experimentales.

Sobre el planteamiento de fondo, el trabajo sostiene que el espacio entre los modelos matemáticos rígidos y los modelos de aprendizaje automático opacos puede ocuparse sin renunciar a ninguna de las dos virtudes. La flexibilidad se obtiene dejando que un modelo cuya atención opere entre variables con nombre, ya sea el desplegado o uno entrenado como alternativa sobre los mismos datos, encuentre la estructura sin que nadie se la imponga; la transparencia se recupera exigiendo que esa estructura se enuncie de forma discreta, acotada y sometida a un criterio de rechazo declarado de antemano. Esa combinación es lo que el documento defiende, y responde a una exigencia que no es exclusiva de este dominio: en las ciencias de la Tierra en particular se espera que un modelo aporte conocimiento sobre el proceso subyacente y no solamente un pronóstico ajustado [1].

Del propio corpus salen tres advertencias que afectan cómo habrá que interpretar lo que se obtenga, y quedan anotadas aquí antes de la ejecución. La primera es que buena parte de la ganancia atribuida a los Transformers en pronóstico de largo plazo podría provenir del mecanismo de parcheo y no de la atención entre variables [17]; la propuesta no queda invalidada, porque no reclama que la atención mejore el desempeño, pero sí queda obligada a no presentarla como fuente privilegiada de conocimiento sin mostrarlo. La segunda es que el único caso del corpus donde la atención recupera un mecanismo verificable lo hace por coincidencia con una frecuencia que la teoría ya predecía [20], es decir, como hallazgo puntual y no como procedimiento repetible. La tercera es sobre la referencia externa: el trabajo mejor validado dispone de la topología física real de la instalación que modela [7], y entre los índices espectrales derivados de Sentinel-2 que emplea este caso de estudio [25] no existe nada equivalente: lo más cercano es la partición en grupos que comparten bandas de origen, que sale de la aritmética de las fórmulas y no del cultivo. Esa carencia sitúa al caso de estudio justo en el escenario que el corpus deja sin cubrir, y obliga a que el peso de la validación recaiga por completo en propiedades verificables sin patrón externo, la reproducibilidad entre repeticiones, la independencia respecto de las decisiones del procedimiento y la no redundancia frente a las demás variables, en lugar de en una comparación contra una estructura conocida de antemano. A ellas se suma una advertencia sobre cómo medir la propia fidelidad: una

perturbación que saca el dato de la distribución de entrenamiento termina midiendo la fragilidad del modelo y no la relevancia de lo perturbado [22], y ningún método de perturbación se traslada sin más de una arquitectura a otra [23]. El criterio de validación de esta propuesta ya incorpora ambas advertencias, y por eso deja la elección del método concreto para la etapa de ejecución en lugar de fijarla en el diseño.

Queda además una limitación del propio protocolo de revisión, que se declara porque afecta la trazabilidad del corpus: el paso final desde los registros elegibles hasta las referencias incluidas se resolvió por juicio de relevancia documentado caso por caso, sin umbral cuantitativo explícito, y formalizarlo queda pendiente. En una línea parecida, el corpus documenta que dos configuraciones que coinciden en la predicción pueden diferir en la explicación [24], lo que sugiere reportar la variabilidad entre repeticiones como parte del resultado y no tratarla como ruido a suprimir. Aplicado a este trabajo, significa que el reporte final debería incluir cuántas relaciones descartó cada propiedad, y no solo cuáles las cumplieron todas.

REFERENCIAS

- [1] M. Reichstein et al., «Deep learning and process understanding for data-driven Earth system science», *Nature*, vol. 566, n.º 7743, págs. 195-204, 2019. DOI: 10.1038/s41586-019-0912-1
- [2] M. Rizzo, C. Conati, D. Jang y H. Hu. «Evaluating the Faithfulness of Saliency-based Explanations for Deep Learning Models for Temporal Colour Constancy». arXiv: 2211.07982.
- [3] D. Slack, S. Hilgard, E. Jia, S. Singh y H. Lakkaraju, «Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods», en *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 2020, págs. 180-186. DOI: 10.48550/arXiv.1911.02508
- [4] S. Lapuschkin, S. Wäldchen, A. Binder, G. Montavon, W. Samek y K.-R. Müller, «Unmasking Clever Hans Predictors and Assessing What Machines Really Learn», *Nature Communications*, vol. 10, n.º 1, pág. 1096, 2019. DOI: 10.48550/arXiv.1902.10178
- [5] M. Kalnāre, S. Kitharidis, T. Bäck y N. van Stein. «Mechanistic Interpretability for Transformer-based Time Series Classification». arXiv: 2511.21514.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», en *International Conference on Learning Representations*, 2024. DOI: 10.48550/arXiv.2310.06625
- [7] Y. Zhang, Y. Lu, D. Li, S. Bader y E. Zio, «Dynamic Causal Graph Network for Reliable Pipeline Leak Detection», *Reliability Engineering & System Safety*, vol. 275, pág. 112795, 2026. DOI: 10.1016/j.ress.2026.112795
- [8] M. Bouaziz, A. Ben Abbes, M. El Koundi e I. R. Farah, «ConvLSTM-GCN-Transformer: Spatiotemporal graph-attention model for vegetation index map forecasting», *Expert Systems with Applications*, vol. 314, pág. 131596, 2026. DOI: 10.1016/j.eswa.2026.131596
- [9] H. Chefer, S. Gur y L. Wolf, «Transformer Interpretability Beyond Attention Visualization», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, págs. 782-791. DOI: 10.48550/arXiv.2012.09838
- [10] F. Zhou et al., «Understanding Transformer-Based Classifications of Medical Text Using a Large Language Model for the Attribution of Feature Importance», *JMIR Medical Informatics*, vol. 14, e81644, 2026. DOI: 10.2196/81644
- [11] S. Stassin, V. Corduant, S. A. Mahmoudi y X. Siebert, «Explainability and Evaluation of Vision Transformers: An In-Depth Experimental Study», *Electronics*, vol. 13, n.º 1, pág. 175, 2024. DOI: 10.3390/electronics13010175
- [12] S. Harikrishnan, «Instability and interpretability discrepancies between CNNs and vision transformers in keratoconus detection», *Pattern Recognition Letters*, vol. 204, págs. 107-112, 2026. DOI: 10.1016/j.patrec.2026.03.020
- [13] W. Cai, Y. Liang, X. Liu, J. Feng e Y. Wu, «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, págs. 11141-11149, 2024. DOI: 10.48550/arXiv.2401.00423

- [14] S. Zhao, H. Yang, Z. Wang, F. Khan y Q. Wang, «A causal-guided graph transformer with interpretability analysis for process fault diagnosis», *Journal of Loss Prevention in the Process Industries*, vol. 102, pág. 106 022, 2026. DOI: 10.1016/j.jlp.2026.106022
- [15] E. T. Mekonnen, L. Longo y P. Dondio, «A global model-agnostic rule-based XAI method based on Parameterized Event Primitives for time series classifiers», *Frontiers in Artificial Intelligence*, vol. 7, 2024. DOI: 10.3389/frai.2024.1381921
- [16] D. Villaboni, A. Castellini, I. L. Danesi y A. Farinelli. «SENTINEL: Multi-Patch Transformer with Temporal and Channel Attention for Time Series Forecasting». arXiv: 2503.17658.
- [17] P. Tang y W. Zhang. «Unlocking the Power of Patch: Patch-Based MLP for Long-Term Time Series Forecasting». arXiv: 2405.13575.
- [18] F. Spuler, M. Kretschmer, M. A. Balmaseda, M. Gudoshava y T. G. Shepherd, «Disentangling Regional Impacts of Joint Teleconnections Using Causal Representation Learning», *Journal of Climate*, vol. 39, n.º 17, págs. 5173-5192, 2026. DOI: 10.1175/JCLI-D-25-0700.1
- [19] M. Altieri, M. Ceci y R. Corizzo, «An end-to-end explainability framework for spatio-temporal predictive modeling», *Machine Learning*, vol. 114, n.º 4, 2025. DOI: 10.1007/s10994-024-06733-6
- [20] X. Zhou, J. Sun, J. Zhao y F. Shuang, «Explainable AI in Rotorcraft Aerodynamics: Autonomous Discovery and Dynamic Tracking of Vortex Ring State Mechanisms via Vision Transformers», *Aerospace*, vol. 13, n.º 7, pág. 590, 2026. DOI: 10.3390/aerospace13070590
- [21] S. Abnar y W. Zuidema, «Quantifying Attention Flow in Transformers», en *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, Association for Computational Linguistics, 2020, págs. 4190-4197. DOI: 10.48550/arXiv.2005.00928
- [22] H. Meng, C. Wagner e I. Triguero, «Explaining time series classifiers through meaningful perturbation and optimisation», *Information Sciences*, vol. 645, pág. 119 334, 2023. DOI: 10.1016/j.ins.2023.119334
- [23] I. Šimić, E. Veas y V. Sabol, «A comprehensive analysis of perturbation methods in explainable AI feature attribution validation for neural time series classifiers», *Scientific Reports*, vol. 15, 2025. DOI: 10.1038/s41598-025-09538-2
- [24] J. Bogaert, L. Escoufflaire, A. Descampe, C. Fairon, M.-C. de Marneffe y F.-X. Standaert, «Explanation Variability in Text Classification: Humans vs. LLMs», *Computational Linguistics*, págs. 1-31, 2026. DOI: 10.1162/COLI.a.624
- [25] J. Segarra, M. L. Buchailot, J. L. Araus y S. C. Kefauver, «Remote Sensing for Precision Agriculture: Sentinel-2 Improved Features and Applications», *Agronomy*, vol. 10, n.º 5, pág. 641, 2020. DOI: 10.3390/agronomy10050641