

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

RECONSTRUCCIÓN DE HIPÓTESIS RELACIONALES A PARTIR DE LA ATENCIÓN DE MODELOS PROFUNDOS

**PATRICIO FIGUEROA
GABRIEL SANZANA**

**SEMINARIO DE TÍTULO
INFORME DE AVANCE
SEPTIEMBRE 2026**

RESUMEN

Los modelos profundos basados en atención superan a los modelos clásicos en desempeño predictivo sobre problemas multivariados, pero no entregan una descripción de las relaciones entre variables que sostiene esa predicción. Las técnicas de explicabilidad establecidas tampoco la entregan, porque asignan importancia a cada variable por separado o dibujan la relevancia como un mapa continuo, y ninguno de esos objetos puede enunciarse fuera del modelo que lo produjo, compararse con conocimiento previo del fenómeno ni someterse a refutación. De ahí surge la pregunta que ordena el trabajo: si es posible transformar las matrices de atención de un modelo Transformer en grafos dirigidos compactos que generen hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales.

Para responderla se propone un framework metodológico que opera sobre un modelo ya entrenado, sin reentrenarlo ni modificar su arquitectura, y que encadena tres transformaciones: convertir la matriz de atención en un grafo dirigido sobre variables con nombre, reducir ese grafo a una hipótesis relacional compacta y evaluar esa hipótesis contra el comportamiento del modelo. La contribución no está en extraer el grafo, operación algorítmicamente sencilla que varios trabajos ya resuelven, sino en el criterio que decide cuándo una relación extraída merece tratarse como hipótesis científica. Ese criterio se organiza como una cadena de evidencia acumulativa, donde cada relación debe mostrar que reaparece al reentrenar el modelo, que resiste el cambio de la regla con que se discretiza, que es improbable bajo una hipótesis nula explícita, que el modelo efectivamente depende de ella, y que su efecto es específico. Los umbrales quedan declarados antes de ejecutar el procedimiento, y la evidencia se contrasta con paradigmas que no comparten supuestos.

Este informe corresponde a la etapa de avance y documenta el diseño, no su ejecución. El framework está formalizado, el criterio de validación está especificado y el estado del arte que lo sustenta proviene de una revisión sistemática conducida bajo el protocolo PRISMA 2020, de la que salieron las 25 referencias que respaldan el trabajo. Aplicar el procedimiento sobre el caso de estudio, un conjunto de índices espectrales derivados de imágenes satelitales, es el programa de la etapa siguiente y aparece calendarizado en el plan de trabajo.

Palabras clave: interpretabilidad, mecanismos de atención, grafo relacional, series de tiempo multivariadas, revisión sistemática.

ABSTRACT

Attention-based deep models outperform classical models on multivariate prediction tasks, yet they do not expose the relations among variables that support those predictions. Established explainability techniques do not expose them either, since they assign importance to each variable

in isolation or render relevance as a continuous map, and neither object can be stated outside the model that produced it, compared against prior knowledge of the phenomenon, or subjected to refutation. Hence the question that organises this work: whether the attention matrices of a Transformer model can be turned into compact directed graphs that yield reproducible and falsifiable relational hypotheses, with greater faithfulness to the model’s behaviour than traditional techniques offer.

The proposed answer is a methodological framework that operates on an already trained model, without retraining it or modifying its architecture, and that chains three transformations: turning the attention matrix into a directed graph over named variables, reducing that graph to a compact relational hypothesis, and evaluating that hypothesis against the behaviour of the model. The contribution does not lie in extracting the graph, which is algorithmically simple and already solved in several works, but in the criterion that decides when an extracted relation deserves to be treated as a scientific hypothesis. That criterion is organised as a cumulative chain of evidence, in which each relation must show that it reappears when the model is retrained, that it withstands a change in the discretisation rule, that it is unlikely under an explicit null hypothesis, that the model actually depends on it, and that its effect is specific. Thresholds are declared before the procedure runs, and the evidence is contrasted with paradigms that do not share assumptions.

This document reports on the progress stage and describes the design rather than its execution. The framework is formalised, the validation criterion is specified, and the supporting state of the art comes from a systematic review conducted under the PRISMA 2020 protocol, which yielded the 25 references behind this work. Running the procedure on the case study, a set of spectral indices derived from satellite imagery, is the programme for the next stage and appears scheduled in the work plan.

Keywords: interpretability, attention mechanisms, relational graph, multivariate time series, systematic review.

ÍNDICE GENERAL

Resumen/Abstract	I
Índice General	III
Lista de Tablas	V
1. Introducción	1
1.1. Contexto del problema	1
1.2. El problema	1
1.3. Qué se ha hecho hasta ahora	2
1.4. Propuesta y contribución	3
2. Objetivos	4
2.1. Objetivo general	4
2.2. Objetivos específicos	4
3. Estado del arte	6
3.1. Obtención del corpus	6
3.2. Trabajos similares	6
3.3. Contribución de la propuesta	8
4. Marco teórico	10
4.1. Definición formal del problema	10
4.2. Técnicas necesarias	11
5. Plan de trabajo	13
5.1. Estado a la fecha de este informe	13
5.2. Actividades y calendario	13
5.3. Dependencias y riesgos	14

6. Propuesta **15**

6.1. Qué propone el framework 15

6.2. El instrumento y su lugar en la propuesta 15

6.3. El criterio de validación 16

6.4. Contraste entre paradigmas 16

6.5. Taxonomía de resultados 17

6.6. Alcance de esta etapa 17

7. Conclusiones preliminares **19**

Referencias **20**

ÍNDICE DE CUADROS

3.1. Registros identificados por base de datos. 6

3.2. Familias del estado del arte, con su aporte y su límite. 9

5.1. Actividades del plan de trabajo, con periodo estimado y estado. 13

1. INTRODUCCIÓN

1.1. Contexto del problema

La pregunta que ordena este trabajo se fijó al diseñar el protocolo de revisión sistemática y quedó registrada en estos términos: si es posible desarrollar un framework metodológico que transforme las matrices de atención de modelos Transformer en grafos dirigidos compactos, capaces de generar hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales de explicabilidad posteriores al entrenamiento. Cada parte de esa formulación delimita algo distinto. De ella salen tanto el estado del arte como los objetivos del capítulo siguiente, así que vale desarmarla por partes.

La población que interesa son los modelos profundos basados en la arquitectura Transformer, y dentro de ellos un subconjunto estrecho: aquellos donde la atención se calcula entre tokens que representan variables con significado propio, y no entre posiciones espaciales o instantes de tiempo. Esa distinción no es un detalle de implementación. Determina qué describe la matriz de atención y, por lo tanto, si tiene sentido leerla como una afirmación sobre el fenómeno o solo sobre el procesamiento interno del modelo. La condición que se problematiza es la opacidad de esos modelos, agravada por un hecho incómodo: sus matrices de atención cambian entre ejecuciones aunque el desempeño se mantenga, de modo que la representación interna depende de la semilla de entrenamiento tanto como del fenómeno. El comparador son las técnicas de explicabilidad ya establecidas, que atribuyen importancia a cada variable por separado o dibujan la relevancia como un mapa continuo. Y el resultado que se persigue es una hipótesis relacional compacta, dirigida, definida sobre variables con nombre, que pueda enunciarse fuera del modelo y someterse a refutación.

Detrás de la pregunta hay una expectativa que excede lo predictivo. En disciplinas como las ciencias de la Tierra se espera que un modelo entregue conocimiento sobre el proceso y no solamente una predicción ajustada, expectativa que vuelve insuficiente un buen desempeño por sí solo (Reichstein et al., 2019). Un modelo que anticipa correctamente el comportamiento de un conjunto de variables, pero que no permite formular ninguna hipótesis sobre cómo se relacionan entre sí, deja el trabajo científico a medio camino.

1.2. El problema

La matriz de atención parece el lugar natural donde buscar esa estructura relacional, porque registra cuánto pesa cada variable al procesar a las demás. Tratarla directamente como explicación, sin embargo, tropieza con tres obstáculos que la literatura ya documentó y que este trabajo toma como punto de partida.

El primero es la inestabilidad. La matriz no es una propiedad del problema sino un producto del entrenamiento, y dos corridas del mismo modelo sobre los mismos datos, con semillas distintas, producen matrices que no coinciden aunque su desempeño sea equivalente. Cualquier explicación derivada de una sola corrida hereda ese problema sin declararlo, ya que nada en el resultado informa

sobre su propia reproducibilidad.

El segundo es que la legibilidad de un mecanismo interno no garantiza que ese mecanismo gobierne la predicción. Rizzo et al. (2022) adaptaron dos pruebas de fidelidad provenientes del procesamiento de lenguaje natural a un modelo de constancia de color temporal y observaron que la atención no sostiene una relación causal con la salida, mientras que la confianza, otra forma de saliencia interna del mismo modelo, sí la sostiene. El resultado obliga a medir la fidelidad caso por caso en lugar de suponerla, que es justamente lo que este trabajo incorpora a su protocolo de validación.

El tercero es que la alternativa más usada tampoco resiste el escrutinio. Slack et al. (2020) construyeron una técnica de andamiaje capaz de detectar cuándo una entrada proviene de las perturbaciones que generan LIME y SHAP, y con ella lograron que un clasificador abiertamente discriminatorio no fuera señalado por ninguno de los dos métodos en ninguna instancia de prueba. Antes que ellos, Lapuschkin et al. (2019) habían mostrado que un modelo con exactitud de estado del arte puede estar resolviendo la tarea por un atajo espurio, como el clasificador que distinguía una categoría por una marca de agua presente solo en esas imágenes, sin que las métricas de desempeño delataran nada. Kalnāre et al. (2025) resumen la situación en una frase que sirve de diagnóstico general: «Existing explainability methods often focus on input-output attributions, leaving the internal mechanisms largely opaque».

El problema, entonces, admite un enunciado breve. No existe un procedimiento que permita decidir, con criterios declarados de antemano, cuándo una relación entre variables extraída de la representación interna de un modelo profundo constituye una hipótesis sobre el fenómeno y cuándo es un artefacto del entrenamiento.

1.3. Qué se ha hecho hasta ahora

La literatura revisada avanzó bastante en obtener estructura relacional y bastante menos en verificarla, y esa asimetría es el hueco donde se inserta la propuesta.

Del lado arquitectónico, el trabajo de Liu et al. (2024) mostró que invertir las dimensiones del Transformer, de manera que cada serie completa constituya un token en lugar de cada instante, mejora el desempeño en pronóstico multivariado de largo plazo. Ese resultado hace posible el problema que aquí se plantea, porque de él se sigue que hoy existen modelos publicados cuya atención describe correlaciones entre variables y no entre posiciones. Sin esa inversión previa, la matriz que se quiere analizar sencillamente no existiría.

Del lado de la estructura relacional, varios trabajos la incorporan al modelo en lugar de leerla de él. El caso más exigente en validación es el de Zhang et al. (2026), que reemplazan el grafo de correlaciones entre sensores por uno de dependencias condicionales y contrastan la estructura aprendida contra la topología física real de una instalación de tuberías. Ese contraste marca a la vez el estándar y la dificultad: la validación funciona porque existe una referencia externa verificable, y en el problema que este trabajo aborda esa referencia no existe. En el extremo opuesto está el uso puramente predictivo, ejemplificado por Bouaziz et al. (2026), cuyo modelo combina memoria convolucional, convolución de grafo y atención, predice con error bajo, transfiere entre sensores, y

en ningún momento comprueba qué relación entre variables aprendió para conseguirlo.

Entre esos dos extremos queda el espacio vacío. Hay maneras de obtener una estructura y hay dominios donde compararla contra una verdad conocida, pero falta un procedimiento que permita sostener una estructura leída de un modelo ya entrenado cuando esa verdad conocida no está disponible.

1.4. Propuesta y contribución

La propuesta consiste en un framework que opera como capa posterior al entrenamiento y encadena tres transformaciones: convertir la matriz de atención en un grafo dirigido y ponderado, reducir ese grafo a una hipótesis relacional compacta, y evaluar esa hipótesis contra el comportamiento del modelo del que salió. Ninguna de las tres modifica los pesos ni la arquitectura, lo que permite aplicarlas sobre un modelo ya desplegado.

La contribución que se reclama está en el tercer paso. Obtener un grafo desde una matriz es un ejercicio algorítmicamente simple y varios trabajos ya lo hacen; lo que la literatura revisada no reúne es un criterio explícito para decidir si ese grafo merece crédito. El framework responde con una cadena de evidencia acumulativa, cuyos umbrales se declaran antes de ejecutarla, y con una triangulación entre paradigmas que no comparten supuestos, de modo que el veredicto sobre una relación no dependa de una sola familia de métodos. A eso se suma una taxonomía que distingue una relación estructural genuina de un atajo predictivo, de un artefacto de la arquitectura y de ruido estocástico.

Este informe de avance documenta el diseño, su fundamento en la literatura y el alcance comprometido para la etapa siguiente. No reporta resultados experimentales, porque la ejecución del protocolo sobre el caso de estudio corresponde al periodo detallado en el capítulo 5.

2. OBJETIVOS

2.1. Objetivo general

Desarrollar un framework metodológico, independiente del dominio, que transforme la representación latente aprendida por un modelo profundo ya entrenado en una hipótesis relacional compacta, interpretable y evaluable, y que la someta a un criterio de validación multicriterio capaz de integrar estabilidad estadística, fidelidad respecto del modelo y contraste contra referencias construidas por fuera de él.

2.2. Objetivos específicos

Los objetivos específicos siguen las tres etapas del trabajo. La primera fija qué hay que conocer antes de diseñar, la segunda construye el artefacto y la tercera decide si el artefacto sirve.

2.2.1. Estudio

La etapa de estudio delimita el terreno. Además de mapear qué se ha hecho, tiene que dejar resueltas dos preguntas que condicionan el diseño posterior: cuánto varía la representación interna de un modelo entre corridas equivalentes, y con qué métricas tiene sentido evaluar una explicación cuando el dato es temporal. Sobre la primera, Harikrishnan (2026) documenta un compromiso que el diseño tiene que administrar desde el principio, ya que en su comparación entre redes convolucionales y Transformers de visión la arquitectura más estable entre semillas resultó ser la menos fiel. Sobre la segunda, Šimić et al. (2025) muestran que la métrica de fidelidad más extendida falla al trasladarse a series temporales, y Mekonnen et al. (2024) añaden el criterio de que una estructura explicativa se evalúa a la vez por fidelidad y por tamaño.

1. Revisar sistemáticamente la literatura bajo el protocolo PRISMA 2020, identificando las familias metodológicas existentes, sus límites y el espacio que dejan abierto para la propuesta.
2. Establecer los criterios de evaluación del framework, tanto los que miden estabilidad frente a la variabilidad del entrenamiento como los que miden fidelidad y compacidad de la estructura resultante.

2.2.2. Desarrollo

La etapa de desarrollo produce el artefacto. Comprende la definición matemática de las transformaciones que componen el pipeline, junto con las condiciones que debe cumplir una representación para ser entrada válida, y el criterio de decisión que se aplicará sobre cada relación extraída.

3. Formalizar las transformaciones que llevan de la matriz de atención al grafo, del grafo a la hipótesis relacional compacta y de la hipótesis a su evaluación contra el modelo.
4. Construir el criterio de validación como una cadena de evidencia acumulativa, con umbrales declarados antes de la ejecución, y formular la taxonomía que permita distinguir una rela-

ción estructural genuina de un atajo predictivo, de un artefacto de la arquitectura y de ruido estocástico.

2.2.3. Validación

La etapa de validación pone a prueba el diseño. Se aplica primero sobre el caso de estudio y después sobre escenarios donde exista una referencia externa contra la cual contrastar, que es la única manera de saber si el procedimiento distingue lo que dice distinguir.

5. Aplicar la cadena de evidencia sobre el caso de estudio y reportar, relación por relación, en qué punto del recorrido cada una sobrevive o queda descartada.
6. Evaluar la generalidad del framework sobre un conjunto sintético de estructura conocida y sobre un segundo dominio real distinto del caso de estudio principal.

3. ESTADO DEL ARTE

3.1. Obtención del corpus

La revisión se condujo bajo el protocolo PRISMA 2020, elegido porque documenta cada decisión de selección y permite que un tercero reconstruya el corpus a partir del mismo registro. De la pregunta de investigación presentada en el capítulo anterior se derivó una cadena de búsqueda con cuatro bloques de términos, uno por cada componente de la pregunta, unidos entre sí con el operador AND y con sinónimos enlazados por OR dentro de cada bloque. Esa cadena se ejecutó sobre Scopus, Web of Science y PubMed, con los resultados que recoge la tabla 3.1, y se complementó con búsquedas por citas y registros.

Los criterios de inclusión restringieron la búsqueda a publicaciones entre 2022 y 2026, en inglés, y a artículos de investigación primaria o trabajos de conferencia, sin restricción de tipo documental en PubMed para no perder literatura técnica no clínica. El cribado posterior se llevó en Zotero, que permitió depurar duplicados y descartar registros sin identificador auditable o sin texto completo disponible. De ahí salieron las 25 referencias que componen el corpus de este informe, todas leídas de forma completa y registradas en una matriz de extracción con su descripción, muestra, metodología, resultados y conclusión, junto con la sección de la tesis a la que aporta cada una.

Cuadro 3.1: Registros identificados por base de datos.

Base de datos	Registros
Scopus	191
Web of Science	100
PubMed	28
Total identificado	319

3.2. Trabajos similares

El contraste se organiza por familias y no trabajo por trabajo, porque investigaciones que a primera vista no se parecen terminan compartiendo la misma limitación estructural. Lo que define cada familia es el tipo de objeto que entrega como explicación y el momento del ciclo de vida del modelo en que ese objeto se produce.

3.2.1. Explicabilidad posterior al entrenamiento y su fiabilidad

La primera familia calcula relevancia sobre un modelo ya entrenado, que es la práctica dominante cuando hay que explicar un sistema opaco sin tocarlo. Chefer et al. (2021) propusieron calcularla mediante descomposición de Taylor propagada por capas, incluidas las conexiones residuales, y su método supera tanto a los mapas de atención crudos como a la propagación heurística. La dificultad aparece al comparar métodos entre sí. Sobre un clasificador Transformer de texto mé-

dico, SHAP y gradientes integrados alcanzan una fidelidad prácticamente igual, en torno a 0,22, y sin embargo solo correlacionan de forma moderada (F. Zhou et al., 2026), es decir, dos explicaciones igualmente fieles ordenan las variables de manera distinta. El problema se generaliza en la evaluación sistemática de Stassin et al. (2024), donde métricas que dicen medir la misma propiedad convergen mínimamente entre sí, con la consecuencia incómoda de que el orden de mérito entre métodos depende de cuál métrica se haya elegido para construirlo.

A esa inconsistencia se suma un cuerpo de trabajos que mide directamente cuánto se puede confiar en una explicación, y cuyas conclusiones condicionan el diseño de la propuesta más que cualquier otra familia. Ya se mencionó el ataque de Slack et al. (2020) sobre los métodos basados en perturbación y el caso de aprendizaje por atajo que documentaron Lapuschkin et al. (2019). Un tercer resultado, más reciente, agrega una tensión que el diseño tiene que administrar: al reentrenar redes convolucionales y Transformers de visión con siete semillas sobre la misma tarea, la arquitectura de atención produce explicaciones más parecidas entre corridas, pero borrar las regiones que destaca apenas altera su confianza (Harikrishnan, 2026). Estabilidad y fidelidad, entonces, no son la misma propiedad y pueden moverse en direcciones opuestas. El límite común de toda esta familia es el tipo de objeto que produce, una importancia por variable o un mapa continuo, sobre el cual no se puede formular una hipótesis enumerable.

3.2.2. Estructura relacional aprendida, impuesta o intervenida

La segunda familia sí produce estructura, aunque la obtiene por vías que la propuesta no puede seguir. Una parte la aprende como componente del modelo: Cai et al. (2024) combinan descomposición en frecuencia con convolución de grafo adaptativa y exponen un grafo interpretable por escala temporal. Otra parte la recibe de antemano, como en el Transformer de grafo de Zhao et al. (2026), que construye un grafo de propagación de fallos mediante cribado de causalidad de Granger y lo usa para condicionar el cálculo de la atención, de modo que el análisis de interpretabilidad termina realizándose sobre una topología que el propio modelo no puede poner a prueba. El trabajo de Zhang et al. (2026) es el más sólido del grupo en cuanto a validación, porque contrasta el grafo de dependencias condicionales que aprende contra la topología física real de la instalación que modela, y también el que mejor expone la dificultad del problema aquí planteado: esa validación es posible porque existe una referencia externa, y entre las variables del caso de estudio no la hay. Cierra el grupo la propuesta de Mekonnen et al. (2024), que destila un clasificador en un conjunto compacto de reglas y lo evalúa a la vez por fidelidad y por tamaño, criterio doble que este trabajo adopta.

Un caso aparte, y el más cercano a la propuesta, es el de Kalnāre et al. (2025), que traslada técnicas de interpretabilidad mecanicista desde el procesamiento de lenguaje a un Transformer de clasificación de series temporales y construye grafos causales del flujo interno de información entre cabezas de atención. El objeto que obtiene es exactamente el que aquí se persigue. La diferencia está en el precio: para conseguirlo interviene el modelo mediante parcheo de activaciones y necesita acceso a sus estados internos, lo que descarta su aplicación sobre un modelo ya desplegado del que solo se dispone de la matriz de atención. Ese contraste define por oposición el alcance de la propuesta, que renuncia a intervenir el modelo y asume el costo de tener que validar de otra manera.

3.2.3. Arquitecturas afines y aplicaciones de dominio

La tercera familia no aborda interpretabilidad, sino dónde conviene aplicar la atención y qué se gana con ello. Junto al resultado ya citado de Liu et al. (2024), la arquitectura de Villaboni et al. (2025) combina atención de canal con atención temporal mediante parches múltiples y alcanza resultados comparables o mejores que el estado del arte. En sentido contrario apunta el trabajo de Tang y Zhang (2024), para quienes buena parte del mérito atribuido a los Transformers en pronóstico de largo plazo procede del mecanismo de parcheo y no de la atención entre variables, afirmación que sostienen mostrando que un perceptrón multicapa sobre parches iguala a arquitecturas bastante más complejas. La familia respalda la condición que hace posible este trabajo, la existencia de una matriz de atención entre variables, sin resolver de dónde viene la ganancia predictiva.

Las aplicaciones a dominios cercanos completan el panorama y muestran el hueco con más claridad que cualquier argumento teórico. El modelo de Bouaziz et al. (2026) predice mapas de índices de vegetación con error bajo y transfiere entre sensores, sin auditar en ningún momento la estructura que aprendió. Spuler et al. (2026) insertan un grafo acíclico dirigido con sentido físico en el espacio latente de un autocodificador variacional y validan el resultado contra experimentos numéricos, aunque la estructura causal en su caso viene impuesta y no extraída. Altieri et al. (2025) desarrollan explicaciones agnósticas al modelo para redes de sensores espacio-temporales y, de paso, muestran que las herramientas pensadas para datos tabulares o de imagen resultan inefectivas en ese contexto. El caso más llamativo es el de X. Zhou et al. (2026), donde la atención de un Transformer de visión converge por sí sola sobre una banda de frecuencia que la teoría aerodinámica predice de forma independiente. Es el único trabajo del corpus donde la atención recupera un mecanismo verificable por fuera del modelo, y precisamente por eso resulta útil: ocurrió una vez, por coincidencia con una magnitud ya conocida, no por un procedimiento que pueda repetirse en otro problema.

3.3. Contribución de la propuesta

La tabla 3.2 resume el contraste. Leídas en conjunto, las tres familias dibujan un panorama asimétrico, donde obtener un objeto relacional está resuelto por varias vías y decidir si ese objeto merece crédito no lo está.

Lo que falta es un procedimiento para falsar una estructura leída, es decir, ni aprendida como parámetro, ni impuesta como conocimiento previo, ni obtenida interviniendo el modelo. Los trabajos que evalúan explicaciones lo hacen sobre atribuciones por variable, con métricas que no convergen entre sí (Stassin et al., 2024; F. Zhou et al., 2026), y no sobre las relaciones de un grafo. Los que aplican estas arquitecturas a dominios afines predicen bien sin auditar lo que aprendieron (Altieri et al., 2025; Bouaziz et al., 2026). Y el único caso donde la atención resulta informativa por sí sola llegó ahí por coincidencia con un mecanismo conocido de antemano (X. Zhou et al., 2026).

La propuesta ocupa ese espacio combinando cinco elementos que el corpus revisado presenta por separado y nunca juntos: extracción posterior al entrenamiento sin reentrenar ni intervenir el modelo, consenso frente a una hipótesis nula explícita, medición de fidelidad relación por relación, contraste entre paradigmas que no comparten supuestos, y una taxonomía que separa relación genuina de atajo predictivo, artefacto y ruido. Cada uno tiene precedente aislado en la literatura; lo

que no tiene precedente es la composición.

Cuadro 3.2: Familias del estado del arte, con su aporte y su límite.

Familia	Trabajos	A favor	En contra
Explicabilidad posterior al entrenamiento y su fiabilidad	(Chefer et al., 2021; Harikrishnan, 2026; Lapuschkin et al., 2019; Slack et al., 2020; Stassin et al., 2024; F. Zhou et al., 2026)	Se aplican sin reentrenar y acotan con evidencia experimental cuánto se puede confiar en una explicación	Entregan importancia por variable o mapa continuo; las métricas que las comparan no convergen entre sí
Estructura aprendida, impuesta o intervenida	(Cai et al., 2024; Kalnāre et al., 2025; Mekonnen et al., 2024; Zhang et al., 2026; Zhao et al., 2026)	Producen estructura explícita; un caso la contrasta contra topología física y otro obtiene un grafo causal verificable	Auditarla exige reentrenar, o es supuesto previo sin hipótesis nula, o requiere intervenir las activaciones
Arquitecturas afines y aplicaciones de dominio	(Altieri et al., 2025; Bouaziz et al., 2026; Liu et al., 2024; Spuler et al., 2026; Tang & Zhang, 2024; Villaboni et al., 2025; X. Zhou et al., 2026)	Sostienen que atender entre variables es efectivo y muestran viabilidad en dominios cercanos	No zanzan si la ganancia viene de la atención o del parcheo, y no auditan la estructura aprendida
Propuesta	Extracción posterior al entrenamiento sin intervenir el modelo, con criterio de validación acumulativo, hipótesis nula explícita, contraste entre paradigmas y taxonomía diagnóstica		

4. MARCO TEÓRICO

4.1. Definición formal del problema

La entrada del framework es una representación relacional y no un modelo. Sea $M_\theta : X \rightarrow Y$ un modelo profundo ya entrenado, del cual se extrae una matriz $A \in \mathbb{R}^{n \times n}$ donde cada elemento A_{ij} representa la intensidad de la interacción dirigida entre las componentes i y j . Todo lo que el framework necesita de M_θ está contenido en esa matriz, siempre que cumpla tres condiciones. Los valores deben ser no negativos, $A_{ij} \geq 0$; las filas deben sumar aproximadamente uno, $\sum_j A_{ij} \approx 1$, lo que permite leer la matriz como una cadena de Markov dirigida; y la matriz debe ser asimétrica, de manera que en general $A_{ij} \neq A_{ji}$ y la dirección de la relación quede codificada. Esas tres condiciones forman la condición de admisibilidad, y una representación que no las satisfaga queda fuera del alcance del framework mientras no se le aplique una adaptación explícita. Nótese que la definición no menciona en ningún punto de dónde viene A , por lo que el índice n puede recorrer índices espectrales, sensores industriales o variables de proceso sin que cambie nada de lo anterior.

Sobre esa entrada, el problema consiste en producir un objeto discreto H de tamaño acotado, definido sobre variables con nombre, que conserve la información relacional relevante y que pueda someterse a prueba. Formalmente se busca

$$\min_H |H| \quad \text{sujeto a} \quad I(H, G) \geq \epsilon, \quad (4.1)$$

donde G es el grafo dirigido derivado de A , la función $I(H, G)$ mide la información que la hipótesis conserva respecto de ese grafo y ϵ es el mínimo aceptable. La intención no es reconstruir todos los circuitos internos del modelo, sino quedarse con la explicación estructural más pequeña que siga diciendo algo.

A la exigencia de compacidad se agrega la de fidelidad, que es lo que impide que la hipótesis se convierta en una descripción elegante y desconectada del modelo que la produjo. Si $M(X)$ es la predicción original y $M_H(X)$ la que se obtiene cuando solo se conserva la información representada por H , entonces

$$F(H, M) = 1 - \mathcal{L}(M(X), M_H(X)), \quad (4.2)$$

y la hipótesis se considera fiel cuando $F(H, M) \geq \delta$. El problema completo, entonces, no consiste en encontrar un H cualquiera sino uno que sea simultáneamente compacto, fiel al modelo y estable frente a las fuentes de variación que introduce el entrenamiento.

El caso de estudio sobre el que se instrumenta este planteamiento trabaja con índices espectrales derivados de imágenes satelitales, cuyas bandas, resoluciones e índices derivados están documentados para la constelación Sentinel-2 y sus aplicaciones agrícolas (Segarra et al., 2020).

Estas variables son fuertemente colineales entre sí, condición que vuelve poco practicable establecer la estructura relacional por inspección directa y que explica el interés por extraerla desde el modelo.

4.2. Técnicas necesarias

4.2.1. Atención entre variables y su agregación

El mecanismo de atención produce, para cada capa y cada cabeza, una matriz que indica cuánto pesa cada token al construir la representación de los demás. Lo que esa matriz significa depende por completo del eje sobre el que se aplica la atención. Cuando los tokens son posiciones espaciales o instantes de tiempo, la matriz describe relaciones entre posiciones y su tamaño crece con la resolución del dato, de modo que no hay una lectura relacional entre variables que rescatar. Cuando cada token es una variable completa, en cambio, la matriz tiene tamaño $n \times n$ sobre las variables del fenómeno y cada celda admite la lectura directa que el framework necesita. Invertir las dimensiones del Transformer en ese sentido es una decisión de diseño validada por desempeño y no solo por conveniencia interpretativa (Liu et al., 2024).

Un modelo con L capas y h cabezas produce $L \times h$ matrices, así que hace falta un procedimiento para obtener una sola que represente al modelo completo. El attention rollout que propusieron Abnar y Zuidema (2020) propaga la atención a través de las capas incorporando las conexiones residuales:

$$\tilde{A} = \prod_{\ell=1}^L (\gamma I + (1 - \gamma) \bar{A}^{(\ell)}), \quad (4.3)$$

donde $\bar{A}^{(\ell)}$ es el promedio de las h cabezas de la capa ℓ , la identidad I simula la conexión residual y γ es la fracción residual. El resultado se normaliza por filas para que siga cumpliendo la condición de admisibilidad. Los mismos autores advierten el límite del procedimiento: en un Transformer la información se mezcla progresivamente entre tokens al atravesar capas y conexiones residuales, con lo cual los pesos crudos dejan de corresponder de forma confiable a los tokens de entrada. El rollout atenúa esa mezcla sin eliminarla, y esa es la razón de fondo por la que el grafo que se obtiene después debe tratarse como hipótesis y no como lectura directa del mecanismo interno.

4.2.2. Qué se sabe sobre medir una explicación

La segunda familia de técnicas necesarias tiene que ver con la evaluación, y su conclusión general es que casi ninguna medida de calidad puede adoptarse sin examinarla antes. Que un mecanismo interno sea legible no implica que gobierne la salida, según mostraron Rizzo et al. (2022) al comparar atención y confianza como formas de saliencia sobre un mismo modelo, de manera que la fidelidad hay que medirla en cada caso.

La forma habitual de medirla consiste en perturbar una entrada y observar cuánto cae el desempeño, y ahí aparece un problema conocido. Una perturbación destructiva saca al dato de la

distribución con la que el modelo fue entrenado, con lo cual lo que se termina midiendo es la fragilidad del modelo y no la relevancia de lo perturbado. Meng et al. (2023) abordan ese defecto generando perturbaciones que permanecen dentro de la distribución, y con ello identifican menos características críticas para explicar la misma decisión. El análisis de Šimić et al. (2025) agrega que la métrica de fidelidad más extendida presenta fallas cuando se traslada a series temporales, y que ningún método de perturbación resulta óptimo para todas las arquitecturas y conjuntos evaluados. Ambos resultados obligan a justificar la medida elegida en lugar de tomarla prestada.

Queda un tercer elemento, más sutil, que atañe al paso de una matriz continua a un conjunto finito de relaciones. Toda regla de corte es en sí misma una fuente de variación, y el fenómeno de fondo lo documentan Bogaert et al. (2026) al comparar la variabilidad de explicaciones humanas con la de explicaciones generadas por modelos: dos configuraciones que coinciden en la predicción pueden diferir en la explicación, y en su experimento la discretización aumenta la coincidencia con el juicio humano sin alterar las predicciones. Por eso el framework trata la regla de discretización como un parámetro cuyo efecto hay que medir y no como una decisión de implementación que se fija una vez y se olvida.

5. PLAN DE TRABAJO

5.1. Estado a la fecha de este informe

El trabajo sigue las tres etapas en que se agruparon los objetivos específicos del capítulo 2, y a la fecha de este informe dos de ellas están cerradas. La etapa de estudio recorrió el protocolo de revisión sistemática desde la formulación de la pregunta hasta la extracción de datos, y dejó como producto el corpus de 25 referencias sobre el que se apoya el capítulo 3; la redacción del estudio, que es la última etapa del protocolo, se cierra con este documento. La etapa de desarrollo también está concluida en lo que respecta al diseño: las transformaciones están definidas, la condición que debe cumplir una representación para ser entrada válida quedó explícita, el criterio de validación está especificado paso por paso con sus umbrales, y la taxonomía que interpreta los resultados está formulada.

Queda pendiente, entonces, la etapa de validación completa, que es donde el diseño se pone a prueba y donde se concentra el resto del calendario. Vale la pena señalar que ese reparto es deliberado: el trabajo optó por especificar los umbrales de decisión antes de mirar cualquier resultado, precisamente para que el criterio no termine ajustándose a lo que los datos entreguen.

5.2. Actividades y calendario

La tabla 5.1 detalla las actividades comprometidas. Las tres primeras filas corresponden a trabajo ya concluido y se incluyen para dejar constancia del punto de partida; el resto pertenece a la etapa de validación y aparece ordenado por dependencia, ya que cada pregunta de la cadena de evidencia solo tiene sentido sobre las relaciones que superaron la anterior. Ese encadenamiento hace que el orden de las filas sea también el orden obligado de ejecución, con poco margen para paralelizar.

Cuadro 5.1: Actividades del plan de trabajo, con periodo estimado y estado.

Actividad	Periodo	Estado
Revisión sistemática de literatura bajo protocolo PRISMA 2020	Hasta septiembre 2026	Concluida
Formalización de las transformaciones y de la condición de admisibilidad	Hasta septiembre 2026	Concluida
Especificación del criterio de validación y de la taxonomía de resultados	Hasta septiembre 2026	Concluida
Redacción del informe de avance	Septiembre 2026	En curso
Implementación del pipeline sobre el caso de estudio y entrenamiento del conjunto de modelos	Octubre 2026	Pendiente
Evaluación de la estabilidad de las relaciones ante la semilla de entrenamiento	Octubre 2026	Pendiente

Actividad	Periodo	Estado
Evaluación de la estabilidad ante la regla que decide qué relaciones entran	Octubre 2026	Pendiente
Contraste de las relaciones frente a la hipótesis nula	Noviembre 2026	Pendiente
Medición de la dependencia del modelo respecto de cada relación	Noviembre 2026	Pendiente
Evaluación de especificidad, robustez y compacidad de la hipótesis	Noviembre a diciembre 2026	Pendiente
Contraste entre los paradigmas ortogonales y las referencias externas	Diciembre 2026	Pendiente
Aplicación de la taxonomía sobre los resultados obtenidos	Diciembre 2026	Pendiente
Validación sobre un conjunto sintético de estructura conocida	Enero 2027	Pendiente
Validación sobre un segundo dominio real	Enero a febrero 2027	Pendiente
Redacción del informe final	Marzo 2027	Pendiente

5.3. Dependencias y riesgos

Tres dependencias condicionan ese calendario. La primera es de cómputo, porque evaluar la estabilidad exige entrenar varias decenas de modelos equivalentes y el costo por corrida determina cuánto puede avanzarse por semana. La segunda es la disponibilidad del segundo dominio, que necesita acceso al modelo y no solo a su matriz, ya que medir la dependencia del modelo respecto de una relación obliga a volver a predecir bajo condiciones alteradas. La tercera es la construcción del conjunto sintético, cuya estructura conocida será la única referencia externa con la que cuente el trabajo, dado que entre las variables del caso de estudio no existe una topología verificada de antemano.

El riesgo principal es que la cadena de evidencia se detenga temprano, es decir, que ninguna relación extraída supere la primera o la segunda pregunta y no quede material sobre el cual continuar. Ese desenlace sería incómodo, aunque no invalidaría el trabajo: la cadena está construida de manera que el punto donde una relación cae funcione como diagnóstico, y un resultado negativo sobre el caso de estudio seguiría siendo un resultado informativo sobre la relación entre atención y estructura del fenómeno. En ese escenario el conjunto sintético pasa a primer plano, porque permite verificar si el procedimiento detecta una estructura que se sabe que existe.

6. PROPUESTA

6.1. Qué propone el framework

La propuesta consiste en tratar la matriz de atención de un modelo ya entrenado como material de análisis y no como un subproducto que se descarta después de predecir. Sobre esa matriz operan tres transformaciones encadenadas,

$$A \xrightarrow{\Phi} G \xrightarrow{\Psi} H \xrightarrow{F} \mathbb{R}, \quad (6.1)$$

donde la primera convierte la matriz en un grafo dirigido y ponderado sobre las variables, la segunda reduce ese grafo a una hipótesis relacional compacta, y la tercera evalúa esa hipótesis contra el comportamiento del modelo del que salió. Las tres actúan después del entrenamiento y ninguna toca los pesos ni la arquitectura.

Esa condición marca la distancia con las alternativas revisadas. Un grafo que se aprende como parámetro del modelo, según hacen Cai et al. (2024), existe porque el entrenamiento lo hizo existir, y auditarlo obliga a volver a entrenar. Un grafo que se recibe de antemano, como el que condiciona la atención en el trabajo de Zhao et al. (2026), es un supuesto de partida y no una conclusión que pueda resultar improbable. Y un grafo obtenido interviniendo el modelo, como el de Kalnāre et al. (2025), exige acceso a sus estados internos, algo que no siempre está disponible. El framework renuncia a las tres vías y se queda con la más restrictiva, leer lo que el modelo ya produjo, precisamente porque es la única aplicable a un modelo desplegado del que solo se tiene la matriz.

La contribución que se reclama, sin embargo, no está en esa lectura. Extraer un grafo desde una matriz es sencillo, y varios de los trabajos citados lo resuelven de una u otra forma. Lo que este trabajo agrega es el criterio que decide si el grafo obtenido merece tratarse como hipótesis sobre el fenómeno, que es lo que las secciones siguientes desarrollan.

6.2. El instrumento y su lugar en la propuesta

Para que exista una matriz de atención entre variables hace falta un modelo cuya atención opere sobre ese eje, y el caso de estudio usa para eso un ConvTransformer donde cada variable es un token independiente, con un codificador compartido entre tokens de modo que la matriz no termine reflejando capacidades desiguales de codificación en lugar de relaciones del fenómeno.

Conviene delimitar el papel de ese componente, porque de ahí depende cómo se lee el resto del trabajo. El ConvTransformer no es la novedad de la propuesta: es un vehículo instrumental cuya única función consiste en producir, de manera controlada, una matriz entre variables interpretables sin depender de un grafo predefinido. La delimitación importa por dos razones. La primera es de honestidad comparativa, ya que los trabajos que compiten en desempeño predictivo lo hacen bajo protocolos de benchmarking establecidos (Liu et al., 2024; Villaboni et al., 2025), y este trabajo no

compite en ese terreno ni reclama superioridad predictiva; el desempeño se reporta apenas como condición de admisibilidad, para verificar que la representación proviene de un modelo que aprendió algo del fenómeno. La segunda es de generalidad: la primera transformación depende de las propiedades algebraicas de la matriz y no de su procedencia, de manera que en principio puede aplicarse a la matriz de atención entre variables de otras arquitecturas sin tocar sus pesos.

6.3. El criterio de validación

El punto donde la propuesta se juega es la tercera transformación, y la decisión de diseño central consiste en que no se resuelve con una métrica. Se resuelve con una cadena de evidencia acumulativa, donde cada relación extraída debe superar una pregunta antes de que tenga sentido hacerle la siguiente, y donde los umbrales quedan declarados antes de ejecutar el procedimiento y no después de ver los resultados.

La primera pregunta es si la relación reaparece al reentrenar el modelo con semillas distintas. Una relación que solo existe en una corrida no informa sobre el fenómeno sino sobre esa inicialización particular, y descartarla temprano evita arrastrar ruido por el resto del recorrido. La segunda pregunta es si la relación sobrevive al cambiar la regla con la que se decide qué relaciones entran en la hipótesis, porque una relación que depende del corte elegido es un artefacto de esa decisión. La tercera es si la relación aparece con más frecuencia de la que cabría esperar por azar, para lo cual se contrasta contra una hipótesis nula explícita en lugar de confiar en que una frecuencia alta hable por sí sola. La cuarta pregunta es si el modelo efectivamente depende de esa relación para predecir, lo que separa las relaciones que el modelo usa de las que simplemente aparecen en su representación interna. La quinta y última verifica que el efecto sea específico de la relación examinada y no un efecto general del procedimiento, y que la hipótesis resultante se mantenga acotada en tamaño, criterio doble que sigue el planteamiento de Mekonnen et al. (2024) sobre evaluar una estructura explicativa a la vez por fidelidad y por compacidad.

El orden importa tanto como las preguntas. Cuando las medidas de calidad se aplican en paralelo informan que algo falla sin señalar dónde, que es la crítica documentada sobre su falta de convergencia (Stassin et al., 2024). En una cadena ordenada, en cambio, el punto donde una relación cae constituye por sí mismo el diagnóstico de por qué cayó.

6.4. Contraste entre paradigmas

Los cinco pasos anteriores comparten parcialmente familia de supuestos, de modo que superarlos todos no descarta la posibilidad de un error común a esa familia. Para acotarlo, la evidencia se contrasta además con paradigmas que razonan de manera distinta: el probabilístico, que ya opera en el tercer paso, más otros cuatro que le son ortogonales. Uno interviene sobre la representación y observa el efecto. Otro compara los grafos por sus propiedades geométricas y topológicas. Un tercero mide dependencia con herramientas de teoría de la información, sin suponer que la relación sea lineal. El cuarto contrasta el grafo obtenido contra referencias construidas por fuera del modelo, entre ellas la correlación lineal entre variables y un grafo generado al azar.

El contraste contra la correlación lineal se lee de forma invertida respecto de lo que sería habitual. Si el grafo extraído coincide en alto grado con ella, la conclusión no es que el resultado

esté confirmado sino que el modelo no aprendió nada que no estuviera ya disponible sin él, y que el framework no aportó valor en ese caso. Es, deliberadamente, un criterio de falsación de la propia contribución.

6.5. Taxonomía de resultados

Cada relación termina caracterizada por cómo le fue en cada paso, y esa caracterización se conserva completa en lugar de promediarse en un solo número, porque la discordancia entre criterios es informativa y un promedio la borraría. De ahí salen cuatro lecturas posibles. Una relación estructural genuina es la que se mantiene entre semillas, resiste el cambio de regla de corte, resulta improbable bajo la hipótesis nula y demuestra que el modelo depende de ella. Un atajo predictivo es la que el modelo sí usa, y por eso pasa la prueba de fidelidad, pero que no encuentra respaldo en los paradigmas ortogonales ni corresponde a nada conocido del fenómeno. Un artefacto de la arquitectura aparece de forma estable y frecuente pero sin que el desempeño dependa de ella, patrón característico de un sumidero de atención. Y el ruido estocástico queda descartado ya en la primera pregunta, por no reaparecer entre corridas.

Distinguir las dos primeras categorías es lo que motiva todo el diseño, y recoge directamente la evidencia de Lapuschkin et al. (2019) sobre modelos con métricas excelentes que resuelven la tarea por una vía que nadie había mirado.

6.6. Alcance de esta etapa

Conviene declarar qué queda dentro y qué queda fuera de lo que este informe compromete. Dentro está el diseño completo del framework, la formalización de sus transformaciones, la especificación del criterio de validación con sus umbrales y la taxonomía anterior. Fuera queda la ejecución sobre el caso de estudio, que corresponde al periodo del capítulo 5, y con ella cualquier afirmación sobre resultados. El framework tampoco reclama mejoras de desempeño predictivo, ni pretende reconstruir el mecanismo interno completo del modelo, sino apenas una descripción estructural mínima que pueda ponerse a prueba.

En cuanto a la transferencia a otros dominios, la pregunta relevante no es sobre el fenómeno estudiado sino sobre el eje de la atención del modelo disponible, y admite tres respuestas. Hay dominios de aplicación directa, donde el modelo publicado ya expone una representación relacional entre variables, como ocurre con las redes de sensores espacio-temporales que documentan Altieri et al. (2025) o con la reconstrucción de dependencias entre sensores industriales de Zhang et al. (2026). Hay dominios que requieren adaptación, donde existe atención accesible pero su eje no son las variables nombradas, situación de los modelos de Bouaziz et al. (2026) y X. Zhou et al. (2026). Y hay dominios que requieren un modelo nuevo, donde la estructura viene impuesta de antemano en el espacio latente en lugar de leerse de una representación entrenada, como en el trabajo de Spuler et al. (2026).

Para elegir el segundo dominio de validación pesan cinco condiciones, en este orden: que los tokens del modelo sean variables, que haya acceso al modelo y no solo a su matriz, que el costo de entrenamiento admita repetir el experimento con varias decenas de semillas, que los datos sean públicos, y que exista conocimiento previo del fenómeno contra el cual contrastar el resultado. Bajo

esas condiciones, las redes de sensores ambientales con datos públicos aparecen como el candidato más realista.

7. CONCLUSIONES PRELIMINARES

La revisión sistemática deja una conclusión bastante nítida sobre el estado del campo. Obtener una estructura relacional desde un modelo profundo está resuelto por varias vías: hay trabajos que la aprenden como parámetro, otros que la reciben como conocimiento previo y otros que la obtienen interviniendo las activaciones del modelo. Lo que no aparece en el corpus revisado es un procedimiento para sostener una estructura leída de un modelo ya entrenado en los casos, que son la mayoría, donde no se dispone de una referencia externa contra la cual compararla. Esa ausencia es la que da sentido a la propuesta y define su alcance.

Sobre esa brecha, el aporte de esta etapa es un diseño y no un resultado. Las tres transformaciones del pipeline están formalizadas, la condición que debe cumplir una representación para ser entrada válida quedó explícita, el criterio de validación está especificado con umbrales fijados antes de ejecutarlo, y la taxonomía que separa relación genuina de atajo predictivo, artefacto y ruido está formulada. Corresponde ser literal en este punto, porque de otro modo el informe prometería más de lo que entrega: nada de eso se ha ejecutado todavía sobre el caso de estudio, este documento no reporta resultados experimentales, y la ejecución completa es el contenido del periodo calendarizado en el capítulo 5.

Del propio corpus salen tres advertencias que afectan cómo habrá que interpretar lo que se obtenga, y quedan anotadas aquí antes de esa ejecución. La primera la formulan Tang y Zhang (2024), para quienes buena parte de la ganancia atribuida a los Transformers en pronóstico de largo plazo procede del mecanismo de parcheo y no de la atención entre variables; la propuesta no queda invalidada por eso, ya que no reclama que la atención mejore el desempeño, pero sí queda obligada a no presentarla como fuente privilegiada de conocimiento mientras no lo demuestre. La segunda proviene del trabajo de X. Zhou et al. (2026), único caso del corpus donde la atención recupera un mecanismo verificable, y que lo consigue por coincidencia con una frecuencia que la teoría ya predecía, es decir, como hallazgo puntual antes que como procedimiento repetible. La tercera tiene que ver con la referencia externa: el trabajo más exigente en validación de todo el corpus dispone de la topología física real de la instalación que modela (Zhang et al., 2026), y entre las variables del caso de estudio no existe nada equivalente, de modo que el conjunto sintético de estructura conocida deja de ser un complemento del plan y pasa a ser su única referencia externa.

Queda por último una consideración sobre cómo reportar lo que venga. Bogaert et al. (2026) documentan que dos configuraciones que coinciden en la predicción pueden diferir en la explicación, lo que sugiere tratar la variabilidad entre corridas como parte del resultado y no como ruido que conviene suprimir antes de mostrarlo. Aplicado a este trabajo, significa que el reporte final debería incluir cuántas relaciones cayeron en cada punto de la cadena y no solo cuáles sobrevivieron, porque el patrón de caídas dice tanto sobre el modelo examinado como la hipótesis que finalmente se sostenga.

REFERENCIAS

- Abnar, S., & Zuidema, W. (2020). Quantifying Attention Flow in Transformers. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 4190-4197. <https://doi.org/10.48550/arXiv.2005.00928>
- Altieri, M., Ceci, M., & Corizzo, R. (2025). An end-to-end explainability framework for spatio-temporal predictive modeling. *Machine Learning*, 114(4). <https://doi.org/10.1007/s10994-024-06733-6>
- Bogaert, J., Escoufflaire, L., Descampe, A., Fairon, C., de Marneffe, M.-C., & Standaert, F.-X. (2026). Explanation Variability in Text Classification: Humans vs. LLMs. *Computational Linguistics*, 1-31. <https://doi.org/10.1162/COLI.a.624>
- Bouaziz, M., Ben Abbes, A., El Koundi, M., & Farah, I. R. (2026). ConvLSTM-GCN-Transformer: Spatiotemporal graph-attention model for vegetation index map forecasting. *Expert Systems with Applications*, 314, 131596. <https://doi.org/10.1016/j.eswa.2026.131596>
- Cai, W., Liang, Y., Liu, X., Feng, J., & Wu, Y. (2024). MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10), 11141-11149. <https://doi.org/10.48550/arXiv.2401.00423>
- Chefer, H., Gur, S., & Wolf, L. (2021). Transformer Interpretability Beyond Attention Visualization. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 782-791. <https://doi.org/10.48550/arXiv.2012.09838>
- Harikrishnan, S. (2026). Instability and interpretability discrepancies between CNNs and vision transformers in keratoconus detection. *Pattern Recognition Letters*, 204, 107-112. <https://doi.org/10.1016/j.patrec.2026.03.020>
- Kalnāre, M., Kitharidis, S., Bäck, T., & van Stein, N. (2025). *Mechanistic Interpretability for Transformer-based Time Series Classification*. arXiv: 2511.21514. <https://doi.org/10.48550/arXiv.2511.21514>
- Lapuschkin, S., Wäldchen, S., Binder, A., Montavon, G., Samek, W., & Müller, K.-R. (2019). Unmasking Clever Hans Predictors and Assessing What Machines Really Learn. *Nature Communications*, 10(1), 1096. <https://doi.org/10.48550/arXiv.1902.10178>
- Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. *International Conference on Learning Representations*. <https://doi.org/10.48550/arXiv.2310.06625>
- Mekonnen, E. T., Longo, L., & Dondio, P. (2024). A global model-agnostic rule-based XAI method based on Parameterized Event Primitives for time series classifiers. *Frontiers in Artificial Intelligence*, 7. <https://doi.org/10.3389/frai.2024.1381921>
- Meng, H., Wagner, C., & Triguero, I. (2023). Explaining time series classifiers through meaningful perturbation and optimisation. *Information Sciences*, 645, 119334. <https://doi.org/10.1016/j.ins.2023.119334>
- Reichstein, M., Camps-Valls, G., Stevens, B., Jung, M., Denzler, J., Carvalhais, N., & Prabhat. (2019). Deep learning and process understanding for data-driven Earth system science. *Nature*, 566(7743), 195-204. <https://doi.org/10.1038/s41586-019-0912-1>

- Rizzo, M., Conati, C., Jang, D., & Hu, H. (2022). *Evaluating the Faithfulness of Saliency-based Explanations for Deep Learning Models for Temporal Colour Constancy*. arXiv: 2211.07982. <https://doi.org/10.48550/arXiv.2211.07982>
- Segarra, J., Buchaillot, M. L., Araus, J. L., & Kefauver, S. C. (2020). Remote Sensing for Precision Agriculture: Sentinel-2 Improved Features and Applications. *Agronomy*, 10(5), 641. <https://doi.org/10.3390/agronomy10050641>
- Šimić, I., Veas, E., & Sabol, V. (2025). A comprehensive analysis of perturbation methods in explainable AI feature attribution validation for neural time series classifiers. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-09538-2>
- Slack, D., Hilgard, S., Jia, E., Singh, S., & Lakkaraju, H. (2020). Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 180-186. <https://doi.org/10.48550/arXiv.1911.02508>
- Spuler, F., Kretschmer, M., Balmaseda, M. A., Gudoshava, M., & Shepherd, T. G. (2026). Disentangling Regional Impacts of Joint Teleconnections Using Causal Representation Learning. *Journal of Climate*, 39(17), 5173-5192. <https://doi.org/10.1175/JCLI-D-25-0700.1>
- Stassin, S., Corduant, V., Mahmoudi, S. A., & Siebert, X. (2024). Explainability and Evaluation of Vision Transformers: An In-Depth Experimental Study. *Electronics*, 13(1), 175. <https://doi.org/10.3390/electronics13010175>
- Tang, P., & Zhang, W. (2024). *Unlocking the Power of Patch: Patch-Based MLP for Long-Term Time Series Forecasting*. arXiv: 2405.13575. <https://doi.org/10.48550/arXiv.2405.13575>
- Villaboni, D., Castellini, A., Danesi, I. L., & Farinelli, A. (2025). *SENTINEL: Multi-Patch Transformer with Temporal and Channel Attention for Time Series Forecasting*. arXiv: 2503.17658. <https://doi.org/10.48550/arXiv.2503.17658>
- Zhang, Y., Lu, Y., Li, D., Bader, S., & Zio, E. (2026). Dynamic Causal Graph Network for Reliable Pipeline Leak Detection. *Reliability Engineering & System Safety*, 275, 112795. <https://doi.org/10.1016/j.ress.2026.112795>
- Zhao, S., Yang, H., Wang, Z., Khan, F., & Wang, Q. (2026). A causal-guided graph transformer with interpretability analysis for process fault diagnosis. *Journal of Loss Prevention in the Process Industries*, 102, 106022. <https://doi.org/10.1016/j.jlp.2026.106022>
- Zhou, F., Saha, A., Afzal, M., Parrish, R., Haynes, R. B., Iorio, A., & Lokker, C. (2026). Understanding Transformer-Based Classifications of Medical Text Using a Large Language Model for the Attribution of Feature Importance. *JMIR Medical Informatics*, 14, e81644. <https://doi.org/10.2196/81644>
- Zhou, X., Sun, J., Zhao, J., & Shuang, F. (2026). Explainable AI in Rotorcraft Aerodynamics: Autonomous Discovery and Dynamic Tracking of Vortex Ring State Mechanisms via Vision Transformers. *Aerospace*, 13(7), 590. <https://doi.org/10.3390/aerospace13070590>