

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

RECONSTRUCCIÓN DE HIPÓTESIS RELACIONALES A PARTIR DE LA ATENCIÓN DE MODELOS PROFUNDOS

**PATRICIO FIGUEROA
GABRIEL SANZANA**

**SEMINARIO DE TÍTULO
INFORME DE AVANCE
SEPTIEMBRE 2026**

RESUMEN

Para estudiar un fenómeno con muchas variables acopladas existen hoy dos familias de herramientas, y ninguna resuelve el problema completo. Los modelos matemáticos clásicos son transparentes, porque la relación entre variables está escrita en sus ecuaciones, pero son rígidos: exigen fijar de antemano qué depende de qué, y cuando el fenómeno no se ajusta a esos supuestos el modelo pierde capacidad de representarlo. Los modelos de aprendizaje automático invierten exactamente esas propiedades. Se ajustan a los datos sin necesidad de suponer la estructura, alcanzan un desempeño predictivo mayor, y a cambio son opacos: entregan una predicción sin decir qué relación entre variables aprendieron para producirla. Quien trabaja con datos multivariados termina eligiendo entre entender y predecir.

Este trabajo propone un framework metodológico que apunta al espacio entre ambas familias. La idea no consiste en abrir el modelo de producción ni en modificarlo, sino en entrenar un modelo alternativo sobre los mismos datos con los que se entrenó el principal, diseñado desde el inicio para que su representación interna sea legible. Ese modelo alternativo trata cada variable como un token, de manera que la atención se calcule entre variables y no entre posiciones espaciales o instantes de tiempo, y produzca así una matriz de interacción entre las variables del fenómeno. El entrenamiento se repite muchas veces con inicializaciones distintas, se conserva aquello que persiste entre repeticiones, y esa estructura estable se convierte primero en un grafo dirigido y después en una hipótesis relacional compacta sobre los datos: un conjunto acotado de relaciones entre variables con nombre, enunciable fuera del modelo y evaluable.

El presente documento corresponde a la etapa de avance del trabajo y describe el diseño, no su ejecución. Están formalizadas las transformaciones que componen el pipeline, las condiciones que debe cumplir la representación de entrada y el criterio con el que se decidirá si una relación extraída merece sostenerse. El estado del arte que respalda esas decisiones proviene de una revisión sistemática conducida bajo el protocolo PRISMA 2020, de la que resultaron las veinticinco referencias que sustentan el informe. La aplicación del procedimiento sobre el caso de estudio, un conjunto de índices espectrales derivados de imágenes satelitales, corresponde a la etapa siguiente.

Palabras clave: interpretabilidad, aprendizaje automático, mecanismos de atención, hipótesis relacional, revisión sistemática.

ABSTRACT

Two families of tools are available today for studying a phenomenon with many coupled variables, and neither solves the whole problem. Classical mathematical models are transparent, since the relation among variables is written into their equations, but they are rigid: they require deciding beforehand what depends on what, and when the phenomenon does not match those assumptions the model loses its ability to represent it. Machine learning models invert precisely those properties. They fit the data without assuming a structure, reach higher predictive performance, and in exchange they are opaque: they return a prediction without stating which relation among variables they learned in order to produce it. Anyone working with multivariate data ends up choosing between

understanding and predicting.

This work proposes a methodological framework aimed at the space between both families. The idea is not to open the production model or modify it, but to train an alternative model on the same data used to train the main one, designed from the outset so that its internal representation is readable. That alternative model treats each variable as a token, so that attention is computed among variables rather than among spatial positions or time steps, thereby producing an interaction matrix over the variables of the phenomenon. Training is repeated many times under different initialisations, whatever persists across repetitions is kept, and that stable structure is turned first into a directed graph and then into a compact relational hypothesis about the data: a bounded set of relations among named variables, storable outside the model and open to evaluation.

This document corresponds to the progress stage of the work and describes the design rather than its execution. The transformations that make up the pipeline are formalised, together with the conditions the input representation must satisfy and the criterion that will decide whether an extracted relation deserves to be upheld. The state of the art supporting those decisions comes from a systematic review conducted under the PRISMA 2020 protocol, which yielded the twenty-five references behind this report. Applying the procedure to the case study, a set of spectral indices derived from satellite imagery, belongs to the next stage.

Keywords: interpretability, machine learning, attention mechanisms, relational hypothesis, systematic review.

ÍNDICE GENERAL

Resumen/Abstract	I
Índice General	III
Lista de Tablas	V
1. Introducción	1
1.1. Contexto del problema	1
1.2. Descripción del problema	1
1.3. Qué se ha hecho hasta ahora	2
1.4. Propuesta y contribución	3
2. Objetivos	4
2.1. Objetivo general	4
2.2. Objetivos específicos	4
3. Estado del arte	5
3.1. Metodología de la revisión	5
3.1.1. Definición de la investigación	5
3.1.2. Búsqueda de literatura	5
3.1.3. Verificación de los artículos	6
3.2. Trabajos similares	7
3.2.1. Explicabilidad posterior al entrenamiento	7
3.2.2. Cuán confiable es una explicación	8
3.2.3. Estructura relacional aprendida, impuesta o intervenida	8
3.2.4. Atención entre variables y aplicaciones de dominio	9
3.3. Contribución de la propuesta	10
4. Marco teórico	11
4.1. Del Transformer estándar al ConvTransformer de índices	11
4.2. Agregación entre capas	11
4.3. Formalización del operador relacional	12
4.4. Qué se sabe sobre medir una explicación	12
4.5. Dominio del caso de estudio	13
5. Metodología y plan de trabajo	14
5.1. Estado a la fecha de este informe	14
5.2. Actividades y calendario	14
5.3. Dependencias y riesgos	14
6. Propuesta	15
6.1. Planteamiento	15
6.2. Transformación matriz-grafo	15
6.3. Transformación grafo-hipótesis	16
6.4. Interpretación metodológica	16

6.5. Criterio de validación	17
6.6. Alcance de esta etapa	18
7. Conclusiones preliminares	19
Referencias	21

ÍNDICE DE CUADROS

3.1. Familias del estado del arte, con su aporte y su límite. 10

5.1. Actividades del plan de trabajo, con periodo estimado y estado. 14

1. INTRODUCCIÓN

1.1. Contexto del problema

La pregunta que ordena este trabajo quedó fijada al diseñar el protocolo de revisión sistemática, y se formuló en estos términos: si es posible desarrollar un framework metodológico que transforme las matrices de atención de modelos Transformer en grafos dirigidos compactos, capaces de generar hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales de explicabilidad posteriores al entrenamiento.

Esa pregunta nace de una tensión que atraviesa cualquier disciplina que trabaje con fenómenos multivariantes. Por un lado están los modelos matemáticos clásicos, donde la relación entre variables se escribe explícitamente en las ecuaciones. Son transparentes y auditables, y su límite es la rigidez: obligan a decidir de antemano qué depende de qué, de modo que cuando el fenómeno no se comporta según esos supuestos el modelo no tiene cómo acomodarse. Por otro lado está el aprendizaje automático, que invierte ambas propiedades. Ajusta los datos sin exigir una estructura previa y predice mejor, pero no dice qué relación aprendió para lograrlo. La consecuencia práctica es que quien estudia un fenómeno complejo debe elegir entre una herramienta que entiende y no se adapta, y otra que se adapta y no explica.

Esa elección resulta especialmente incómoda en disciplinas donde el objetivo no se agota en predecir. En las ciencias de la Tierra se espera que un modelo aporte conocimiento sobre el proceso subyacente, y no solamente un pronóstico ajustado [1]. Un modelo que anticipa correctamente el comportamiento de un conjunto de índices espectrales, pero que no permite formular ninguna hipótesis sobre cómo se relacionan entre sí, deja el trabajo científico a medio camino. El interés por cerrar esa brecha es lo que motiva el presente trabajo.

Los componentes de la pregunta acotan el alcance. La población son los modelos basados en la arquitectura Transformer, y dentro de ellos aquellos donde la atención se calcula entre tokens que representan variables con significado propio, no entre posiciones espaciales ni entre instantes de tiempo. Esa distinción determina qué describe la matriz de atención y, por lo tanto, si tiene sentido leerla como una afirmación sobre el fenómeno. La condición que se problematiza es la opacidad de esos modelos, agravada porque sus matrices cambian entre ejecuciones aunque el desempeño se mantenga. El comparador son las técnicas de explicabilidad ya establecidas, que atribuyen importancia a cada variable por separado o presentan la relevancia como un mapa continuo. Y el resultado buscado es una hipótesis relacional compacta y dirigida, definida sobre variables con nombre, que pueda enunciarse fuera del modelo y someterse a refutación.

1.2. Descripción del problema

La matriz de atención parece el lugar natural donde buscar esa estructura relacional, porque registra cuánto pesa cada variable al procesar a las demás. Leerla directamente como si fuera una explicación tropieza, sin embargo, con tres obstáculos que la literatura revisada documenta con evidencia experimental.

El primero es la inestabilidad. La matriz no es una propiedad del fenómeno sino un producto del entrenamiento, y dos corridas del mismo modelo sobre los mismos datos, con semillas distintas, producen matrices que no coinciden aunque su desempeño sea equivalente. Toda explicación derivada de una sola corrida hereda ese problema sin declararlo, porque nada en el resultado informa

sobre su propia reproducibilidad.

El segundo es que la legibilidad de un mecanismo interno no garantiza que ese mecanismo gobierne la predicción. Rizzo et al. [2] adaptaron dos pruebas de fidelidad provenientes del procesamiento de lenguaje natural a un modelo de constancia de color temporal, y observaron que la atención no sostiene una relación causal con la salida, mientras que la confianza, otra forma de saliencia interna del mismo modelo, sí la sostiene. El resultado obliga a medir la fidelidad en cada caso en lugar de suponerla.

El tercero es que la alternativa más difundida tampoco resiste el escrutinio. Slack et al. [3] construyeron una técnica capaz de detectar cuándo una entrada proviene de las perturbaciones que generan LIME y SHAP, y con ella lograron que un clasificador abiertamente discriminatorio no fuera señalado por ninguno de los dos métodos en ninguna instancia de prueba. Antes que ellos, Lapuschkin et al. [4] habían mostrado que un modelo con exactitud de estado del arte puede estar resolviendo la tarea por un atajo espurio, como el clasificador que distinguía una categoría por una marca de agua presente solo en esas imágenes, sin que las métricas de desempeño delataran nada. En palabras de Kalnāre et al. [5], «Existing explainability methods often focus on input-output attributions, leaving the internal mechanisms largely opaque».

De ahí se sigue el enunciado del problema. No existe un procedimiento que permita decidir, con criterios declarados de antemano, cuándo una relación entre variables obtenida desde la representación interna de un modelo de aprendizaje automático constituye una hipótesis sobre el fenómeno, y cuándo es un artefacto del entrenamiento.

1.3. Qué se ha hecho hasta ahora

La literatura avanzó bastante en obtener estructura relacional y bastante menos en verificarla. Esa asimetría es el hueco donde se inserta la propuesta, y conviene mostrarla con los dos extremos que la delimitan.

Del lado arquitectónico, Liu et al. [6] demostraron que invertir las dimensiones del Transformer, de manera que cada serie completa constituya un token en lugar de cada instante, mejora el desempeño en pronóstico multivariado de largo plazo. Ese resultado es la condición de posibilidad del problema aquí planteado: de él se sigue que un modelo puede diseñarse para que su atención describa relaciones entre variables, en vez de relaciones entre posiciones. Sin esa inversión previa, la matriz que se quiere analizar simplemente no existiría.

Del lado de la validación, el trabajo más exigente del corpus es el de Zhang et al. [7], que reemplaza el grafo de correlaciones entre sensores por uno de dependencias condicionales y contrasta la estructura aprendida contra la topología física real de una instalación de tuberías. Ese contraste fija el estándar y, al mismo tiempo, expone la dificultad del caso que aquí se aborda: la validación funciona porque existe una referencia externa verificable, y entre las variables del caso de estudio esa referencia no existe. En el extremo opuesto está el uso puramente predictivo, ejemplificado por Bouaziz et al. [8], cuyo modelo combina memoria convolucional, convolución de grafo y atención, predice con error bajo, transfiere entre sensores, y en ningún momento comprueba qué relación entre variables aprendió para conseguirlo.

Entre ambos extremos queda el espacio vacío: existen maneras de obtener una estructura y existen dominios donde compararla contra una verdad conocida, pero falta un procedimiento que permita sostener una estructura obtenida de un modelo cuando esa verdad conocida no está disponible.

1.4. Propuesta y contribución

La propuesta no consiste en abrir el modelo que ya está en producción ni en modificarlo. Consiste en entrenar un modelo alternativo sobre los mismos datos con los que se entrenó el modelo principal, construido desde el inicio para que su representación interna sea legible. Ese modelo alternativo trata cada variable como un token, de modo que la atención se calcule entre variables y produzca una matriz de interacción sobre el fenómeno; el entrenamiento se repite muchas veces con inicializaciones distintas y se conserva lo que persiste entre repeticiones. Sobre esa estructura estable operan tres transformaciones encadenadas, que convierten la matriz en un grafo dirigido, el grafo en una hipótesis relacional compacta, y la hipótesis en una medida de su propia fidelidad.

La contribución que se reclama está en el criterio, no en la extracción. Obtener un grafo desde una matriz es un ejercicio algorítmicamente simple, y varios de los trabajos revisados lo resuelven de una u otra forma. Lo que ninguno reúne es una manera explícita de decidir si ese grafo dice algo del fenómeno o solo del entrenamiento que lo produjo. El framework responde con una cadena de evidencia acumulativa cuyos criterios se declaran antes de ejecutarla, con un contraste entre paradigmas que no comparten supuestos, y con una taxonomía que separa una relación estructural genuina de un atajo predictivo, de un artefacto de la arquitectura y de ruido estocástico.

El presente informe documenta ese diseño, la revisión que lo sustenta y el alcance comprometido para la etapa siguiente. No reporta resultados experimentales: la ejecución del procedimiento sobre el caso de estudio corresponde al periodo detallado en el capítulo 5.

2. OBJETIVOS

2.1. Objetivo general

Desarrollar un framework metodológico que transforme la representación relacional aprendida por un modelo de aprendizaje automático, entrenado sobre los mismos datos que el modelo principal del dominio, en una hipótesis relacional compacta e interpretable sobre las variables del fenómeno, y establecer el criterio que decide cuándo esa hipótesis puede sostenerse.

2.2. Objetivos específicos

Los tres objetivos siguientes cubren, en orden, la formalización del método, la construcción del criterio con que se lo evalúa y su aplicación sobre el caso de estudio. Su alcance está acotado deliberadamente al trabajo que puede completarse dentro del periodo de la tesis.

1. Formalizar matemáticamente las transformaciones que llevan de la matriz de interacción entre variables al grafo dirigido, y de este a la hipótesis relacional compacta, junto con las condiciones que debe cumplir una representación para ser entrada válida del framework.
2. Construir el criterio de validación de la hipótesis reconstruida, en términos de estabilidad frente a la variabilidad del entrenamiento y de fidelidad respecto del modelo. La construcción de ese criterio recoge dos advertencias del estado del arte: que una explicación más estable no es necesariamente más fiel [9], y que la métrica de fidelidad más extendida presenta fallas al trasladarse a datos temporales [10]. A ellas se suma la exigencia de evaluar la estructura resultante también por su tamaño, siguiendo el criterio doble de fidelidad y compacidad que plantean Mekonnen et al. [11].
3. Aplicar el framework sobre el caso de estudio de índices espectrales y evaluar la hipótesis obtenida con el criterio anterior, reportando relación por relación cuáles se sostienen y cuáles quedan descartadas.

3. ESTADO DEL ARTE

3.1. Metodología de la revisión

Esta sección describe, en cuatro fases (definición de la investigación, búsqueda de literatura, verificación de los artículos y análisis de la investigación), el procedimiento seguido para identificar, filtrar y analizar la literatura sobre la conversión de matrices de atención en estructuras relacionales interpretables, según las directrices PRISMA 2020¹, elegidas porque dejan registro de cada decisión de selección y permiten reconstruir el corpus a partir de ese registro.

3.1.1. Definición de la investigación

El área de estudio son los modelos de aprendizaje profundo basados en la arquitectura Transformer donde la atención se calcula entre tokens que representan variables con significado físico, con foco en la opacidad de sus mecanismos de decisión y en la inestabilidad estocástica de sus matrices de atención entre ejecuciones de entrenamiento. La revisión responde a la siguiente pregunta, formulada según el modelo PICO: ¿es posible desarrollar un framework metodológico que transforme las matrices de atención de modelos Transformer en grafos dirigidos compactos, capaces de generar hipótesis relacionales reproducibles y falsables, con mayor fidelidad al comportamiento del modelo que las técnicas tradicionales de explicabilidad post-hoc?

El alcance queda delimitado por los cuatro componentes de la pregunta y por un marco temporal de publicaciones entre 2022 y 2026:

- **Población.** Modelos profundos basados en Transformer cuya atención opera entre tokens que representan variables con significado físico.
- **Intervención.** La condición de caja negra de estos modelos: opacidad del mecanismo de decisión e inestabilidad de la matriz de atención entre ejecuciones.
- **Comparador.** Métodos tradicionales de explicabilidad, es decir técnicas de atribución marginal por variable como SHAP y LIME, y la visualización de mapas continuos de atención.
- **Resultado.** La reconstrucción de una hipótesis relacional compacta, dirigida y falsable sobre las variables, estadísticamente reproducible y fiel al comportamiento del modelo.

3.1.2. Búsqueda de literatura

Se construyó un conjunto de términos por cada componente PICO, con sinónimos unidos por el operador OR dentro de cada componente y los cuatro grupos combinados entre sí con AND; por ejemplo, población incluye “Transformer”, “attention matrix” e “iTransformer”; intervención incluye “black box” y “attention instability”; comparador incluye “XAI”, “SHAP” y “LIME”; y resultado incluye “relational graph”, “falsifiable” y “reproducibility”. La cadena resultante se aplicó de forma consistente en las tres bases consultadas, sobre los campos de título, resumen y palabras clave: Scopus ($n = 191$), Web of Science ($n = 100$) y PubMed ($n = 28$), con un total de 319 registros identificados; no se consultaron registros de protocolos. La consolidación de los archivos .ris, la deduplicación y el filtrado progresivo se realizaron en Zotero, con la última actualización del conjunto de referencias el 5 de septiembre de 2026.

¹Page MJ, McKenzie JE, Bossuyt PM, et al. “The PRISMA 2020 statement: an updated guideline for reporting systematic reviews”. *BMJ*, 372:n71, 2021. <https://doi.org/10.1136/bmj.n71>. Plantilla del diagrama de flujo disponible en <https://www.prisma-statement.org/prisma-2020-flow-diagram>.

Además de las bases de datos se realizó una búsqueda complementaria asistida por inteligencia artificial, que aportó 36 artículos obtenidos a texto completo el 5 de septiembre de 2026, ninguno duplicado respecto de los registros ya recuperados. Al obtenerse ya completos y de forma individual, estos documentos no pasaron por los filtros de deduplicación, identificador DOI ni acceso al texto, ni por el cribado de título y resumen: entraron directamente a la evaluación de elegibilidad con los criterios de la sección 3.1.3, y de ellos quedaron 13 incluidos. El diagrama de flujo de la figura 3.1 recoge esa diferencia de recorrido: la columna de otros métodos va de la identificación a la evaluación de elegibilidad, sin cajas de cribado. De los 25 estudios incluidos, 13 provienen de esta búsqueda complementaria y 12 de las bases de datos; entre los primeros están las referencias fundacionales de las técnicas que la propuesta emplea, incluida la que introduce la propagación de atención por capas, que la cadena booleana no recuperó.

Se consideraron únicamente artículos redactados en inglés; los escritos en otros idiomas se descartaron. En total se incluyeron 25 documentos en la revisión, y la figura 3.1 ilustra el flujo detallado de cribado e inclusión según PRISMA 2020.




Figura 3.1: Diagrama de flujo PRISMA 2020 del proceso de identificación, cribado y selección de estudios.

3.1.3. Verificación de los artículos

El cribado por resumen de los 137 registros y la posterior evaluación a texto completo los realizaron los dos autores, Gabriel Sanzana y Patricio Figueroa, contrastando cada documento con los criterios de inclusión (periodo de publicación 2022–2026, redacción en inglés, y tipo de documento restringido a artículos de investigación primaria y trabajos de conferencia en Scopus y Web of Science, sin restricción en PubMed para no perder literatura técnica no clínica) y de exclusión (lo opuesto, más registro duplicado detectado en Zotero, de 319 a 221 registros (−98); ausencia de identificador DOI auditable, de 221 a 201 (−20); y texto completo no disponible a través de

los accesos institucionales del equipo, de 201 a 137 (−64)). Los desacuerdos entre revisores se resolvieron por discusión hasta alcanzar una decisión común sobre cada estudio.

Sobre los 137 registros restantes se aplicó el cribado por resumen, que excluyó 116 documentos por no auditar un mecanismo interno de atención ni producir una estructura relacional entre variables. De los 21 estudios buscados a texto completo se recuperaron 17; de estos se excluyeron 5 durante la evaluación de elegibilidad, cuatro por contenido redundante con un estudio ya incluido y uno por quedar superado por evidencia primaria localizada en la búsqueda complementaria. En esa búsqueda se evaluaron los 36 documentos y se excluyeron 23: cuatro por no disponer de un mecanismo interno de atención auditable, ocho por ser revisiones de dominio sin aporte metodológico y once por aplicar explicabilidad post-hoc sin producir ni evaluar estructura relacional entre variables.

Los 25 estudios incluidos se clasificaron en seis bloques temáticos según su función en la revisión (premisa de la atención como objeto auditable, insuficiencia de la explicabilidad tradicional, validación por perturbación, estructura relacional compacta, arquitectura y tokenización, y dominio y aplicación), y se asociaron, mediante una matriz de doble entrada entre estudio y sección, a las secciones del informe a las que aportan; eso admite que un mismo estudio se cite en más de una.

Para el análisis, de cada estudio incluido se extrajeron título, DOI, descripción del aporte, fecha de publicación, muestra, metodología, resultados y conclusión, verificados contra el texto completo y no contra el resumen, para corregir descripciones cuyo detalle experimental no coincidía con lo declarado en él. Los datos se analizaron señalando el aporte al framework propuesto y sus límites, incorporando a la síntesis tanto los estudios que la respaldan como aquellos cuyos resultados la cuestionan, entre ellos los que atribuyen la mejora de rendimiento al mecanismo de parcheo y no a la atención, y los que muestran que dos métodos de atribución igualmente fieles ordenan las variables de forma distinta. El análisis de las citas de estas veinticinco referencias, es decir a qué trabajos citan ellas mismas, queda fuera del alcance de esta revisión y se declara como línea de trabajo futuro.

3.2. Trabajos similares

El contraste se organiza por familias y no trabajo por trabajo, porque investigaciones que a primera vista no se parecen terminan compartiendo la misma limitación. Lo que define cada familia es el tipo de objeto que entrega como explicación y el momento del ciclo de vida del modelo en que ese objeto se produce.

3.2.1. Explicabilidad posterior al entrenamiento

La primera familia calcula relevancia sobre un modelo ya entrenado. Chefer et al. [12] propusieron calcularla mediante descomposición de Taylor propagada por capas, conservando la relevancia total a través de los bloques de atención y de las conexiones residuales; evaluada sobre el conjunto de validación de ImageNet, sobre el subconjunto anotado ImageNet-Segmentation y sobre una tarea de texto, su propuesta supera de forma consistente a los mapas de atención crudos y a la propagación heurística. Aun así, su salida es un mapa de relevancia espacial: responde qué partes de la entrada pesaron, no qué relación entre variables sostiene la predicción.

El límite se vuelve más incómodo al comparar métodos entre sí. Zhou et al. [13] evaluaron cuatro explicadores sobre un clasificador Transformer de texto médico, con doscientos estudios estratificados y más de ochenta mil tokens atribuidos, y encontraron que SHAP y gradientes integrados alcanzan una fidelidad prácticamente igual, en torno a 0,22, con correlación mutua apenas

moderada: dos explicaciones igualmente fieles ordenan las variables de manera distinta. Stassin et al. [14] generalizaron el problema al cruzar varios métodos de explicación con métricas de fidelidad, coherencia, robustez y complejidad sobre arquitecturas de visión: métricas que declaran medir la misma propiedad muestran convergencia y correlación mínimas entre sí, de modo que el orden de mérito entre métodos depende de cuál métrica se haya elegido para construirlo. Por eso este trabajo calibra su criterio de contraste contra un modelo nulo propio en lugar de adoptar valores de referencia tomados de la literatura.

3.2.2. Cuán confiable es una explicación

La segunda familia no propone explicaciones, sino que mide cuánto se puede confiar en ellas. Slack et al. [3] construyeron una técnica de andamiaje que detecta si una entrada proviene de la distribución real o de las perturbaciones que generan LIME y SHAP, y responde con un modelo distinto en cada caso; aplicada sobre tres conjuntos de decisiones de alto riesgo, consiguió que clasificadores contruidos para discriminar por raza no fueran señalados por ninguno de los dos métodos en ninguna instancia. Lapuschkin et al. [4] habían mostrado antes, mediante propagación de relevancia y análisis espectral sobre PASCAL VOC 2007 y sobre agentes de aprendizaje por refuerzo, que un modelo con exactitud de estado del arte puede estar resolviendo la tarea por un atajo espurio: el caso de la categoría caballo, detectada en realidad por una marca de agua presente solo en esas imágenes, es el origen del término Clever Hans que forma parte de la pregunta de este trabajo. La conclusión conjunta es que el rendimiento no valida el mecanismo.

A esos resultados se suma un hallazgo más reciente. Harikrishnan [9] entrenaron una red convolucional y un Transformer de visión con siete semillas distintas sobre cuatro mil imágenes de topografía corneal, y midieron la fiabilidad de las explicaciones por inestabilidad de los mapas, similitud estructural entre semillas y caída de rendimiento al borrar las regiones destacadas. El Transformer resultó bastante más estable entre semillas que la red convolucional, con un orden de magnitud menos de inestabilidad, y a la vez menos fiel: borrar lo que señala apenas afecta su confianza. Estabilidad y fidelidad no son la misma propiedad y pueden moverse en direcciones opuestas, razón por la cual el criterio de validación de este trabajo las trata como dos exigencias separadas.

3.2.3. Estructura relacional aprendida, impuesta o intervenida

La tercera familia sí produce estructura, aunque por vías que la propuesta no puede seguir. Una parte la aprende como componente del modelo: Cai et al. [15] descomponen la serie en el dominio de la frecuencia para separar escalas y aplican convolución de grafo adaptativa de saltos múltiples, con lo que obtienen un grafo interpretable por escala temporal. Otra parte la recibe de antemano, como el Graph Transformer de Zhao et al. [16], que construye un grafo de propagación de fallos mediante cribado de causalidad de Granger consciente del retardo, lo esparsifica y lo usa para condicionar el cálculo de la atención: es el trabajo más parecido a la tubería completa que aquí se propone, y a la vez muestra la diferencia de fondo, pues su análisis de interpretabilidad se realiza sobre una topología que el modelo recibió y no puede poner a prueba.

El caso mejor validado del corpus es el de Zhang et al. [7], que reemplaza el grafo de correlaciones entre sensores por uno de dependencias condicionales, reconstruido mediante independencia condicional momentánea, y lo contrasta contra la topología física real de la instalación: el esqueleto causal aprendido coincide con la disposición conocida de la planta, incluso bajo ruido severo en la señal. Ese trabajo fija el estándar de validación y delimita la dificultad del problema abordado aquí: la validación es posible porque existe una verdad de referencia física, y entre índices espectrales no

la hay. Cierra el grupo Mekonnen et al. [11], que destila un clasificador de series temporales en un conjunto compacto de reglas a partir de primitivas de evento parametrizadas, evaluándolo con cinco métricas que incluyen exactitud, fidelidad, robustez, profundidad del árbol y número de nodos; su doble exigencia, que la estructura sea fiel al modelo y lo bastante pequeña para inspeccionarse, es la que este trabajo adopta.

Un caso aparte es el de Kalnāre et al. [5], que traslada técnicas de interpretabilidad mecanicista desde el procesamiento de lenguaje a un Transformer de clasificación de series temporales. Mediante parcheo de activaciones, saliencia de atención y autocodificadores dispersos, tratando cada cabeza y cada instante como unidades causales que se intervienen de forma sistemática, construyen grafos causales dirigidos del flujo interno de información hasta los logits de clase: el objeto que obtienen es exactamente el que aquí se persigue. La diferencia está en el precio que pagan, pues intervenir el modelo exige acceso a sus estados internos y a la posibilidad de modificarlos durante la inferencia, algo que no siempre está disponible; la propuesta renuncia a eso y asume el costo de validar por otra vía.

3.2.4. Atención entre variables y aplicaciones de dominio

La cuarta familia no aborda interpretabilidad, sino dónde conviene aplicar la atención, y de ella depende que exista siquiera la matriz que este trabajo analiza. Liu et al. [6] invirtieron las dimensiones del Transformer de modo que cada serie completa sea un token, reutilizando los componentes de la arquitectura sin modificarlos, y alcanzaron el estado del arte sobre siete familias de conjuntos de referencia además de mejorar la generalización entre variables: cuando el token agrupa varias variables del mismo instante, los mapas de atención resultan poco significativos. Villaboni et al. [17] avanzaron en la misma dirección combinando atención de canal con atención temporal mediante un mecanismo de parches múltiples que sustituye el reparto en cabezas, con resultados comparables o mejores que el estado del arte sobre seis conjuntos de predicción a largo plazo. En sentido contrario, Tang y Zhang [18] atribuyen buena parte del mérito de los Transformers al mecanismo de parcheo antes que a la atención entre variables, y lo sostienen mostrando que un perceptrón multicapa sobre parches iguala o supera a arquitecturas bastante más complejas: obliga a no presentar la atención como fuente privilegiada de conocimiento sin haberlo demostrado.

Las aplicaciones a dominios cercanos muestran el mismo vacío. Bouaziz et al. [8] combinan memoria convolucional, convolución de grafo y Transformer para predecir mapas completos de índices de vegetación sobre una serie mensual de casi tres décadas, con validación cruzada entre sensores e índices distintos; el modelo predice bien y transfiere, y en ningún momento comprueba qué relación entre índices aprendió. Spuler et al. [19] insertan un grafo acíclico dirigido con sentido físico en el espacio latente de un autocodificador variacional para separar influencias climáticas simultáneas, y validan el resultado contra experimentos numéricos de reemplazo de temperatura superficial del mar; su estructura causal viene impuesta y no extraída. Altieri et al. [20] desarrollan explicaciones agnósticas al modelo para redes de sensores espacio-temporales mediante metaoptimización de máscaras, sobre cuatro conjuntos reales que incluyen calidad del aire, plantas solares y monitoreo fotovoltaico, y muestran de paso que las herramientas pensadas para datos tabulares, de imagen o de grafo resultan inefectivas en ese contexto.

El caso más llamativo del corpus es el de Zhou et al. [21], donde un Transformer de visión aplicado a señales de vibración de un vehículo no tripulado concentra su atención en una banda centrada en 41,7 Hz, que coincide con la frecuencia fundamental de una vuelta por revolución derivada de forma independiente por la teoría aerodinámica: es el único trabajo revisado donde la atención

recupera un mecanismo verificable por fuera del modelo, y ocurrió una vez, por coincidencia con una magnitud que ya se conocía, no mediante un procedimiento repetible sobre un problema donde esa magnitud no esté disponible de antemano.

3.3. Contribución de la propuesta

La tabla 3.1 resume el contraste. Léidas en conjunto, las cuatro familias dibujan un panorama asimétrico: obtener un objeto relacional está resuelto por varias vías, y decidir si ese objeto merece crédito no lo está.

Lo que falta es un procedimiento para falsar una estructura leída, es decir, ni aprendida como parámetro, ni impuesta como conocimiento previo, ni obtenida interviniendo el modelo. Los trabajos que evalúan explicaciones lo hacen sobre atribuciones por variable, con métricas que no convergen entre sí [13], [14], y no sobre las relaciones de un grafo. Los que aplican estas arquitecturas a dominios afines predicen bien sin auditar lo que aprendieron [8], [20]. Y el único caso donde la atención resulta informativa por sí sola llegó ahí por coincidencia con un mecanismo conocido de antemano [21].

La propuesta ocupa ese espacio combinando cinco elementos que el corpus presenta por separado y nunca juntos: obtención de la estructura desde un modelo entrenado para ser legible, sin intervenir el modelo de producción; consenso entre repeticiones del entrenamiento frente a una hipótesis nula explícita; medición de fidelidad relación por relación; contraste entre paradigmas que no comparten supuestos; y una taxonomía que separa relación genuina de atajo predictivo, artefacto y ruido. Cada elemento tiene precedente aislado en la literatura; lo que no tiene precedente es la composición.

Cuadro 3.1: Familias del estado del arte, con su aporte y su límite.

Familia	Trabajos	A favor	En contra
Explicabilidad posterior al entrenamiento	[12], [13], [14]	Se aplican sin reentrenar y están consolidadas en la práctica	Entregan importancia por variable o mapa continuo; las métricas que las comparan no convergen
Confiabilidad de las explicaciones	[3], [4], [9]	Acotan con evidencia experimental cuánto se puede confiar	Diagnostican el problema sin entregar un procedimiento de decisión
Estructura aprendida, impuesta o intervenida	[5], [7], [11], [15], [16]	Producen estructura explícita; un caso la contrasta contra topología física verificable	Auditarla exige reentrenar, o es supuesto previo sin hipótesis nula, o requiere intervenir las activaciones
Atención entre variables y dominios afines	[6], [8], [17], [18], [19], [20], [21]	Hacen posible que exista una matriz entre variables y muestran viabilidad en dominios cercanos	No zanján si la ganancia viene de la atención o del parcheo, y no auditan la estructura aprendida
Propuesta	Modelo alternativo entrenado sobre los mismos datos y diseñado para ser legible, con criterio de validación acumulativo, hipótesis nula explícita, contraste entre paradigmas y taxonomía diagnóstica		

4. MARCO TEÓRICO

4.1. Del Transformer estándar al ConvTransformer de índices

Un Transformer estándar, tal como se emplea en procesamiento de lenguaje natural o en visión por computadora, aplica la atención entre tokens que representan posiciones espaciales, como los parches de una imagen, o posiciones dentro de una secuencia. En problemas multivariados donde lo que interesa modelar son las dependencias entre variables, y no entre posiciones, esa configuración presenta dos limitaciones. La atención se diluye entre miles de tokens espaciales, con lo que las relaciones entre variables quedan ocultas, y no existe una matriz de atención $A \in \mathbb{R}^{n \times n}$ explícita entre variables que pueda extraerse y analizarse. El resultado de Liu et al. [6] apunta en la misma dirección desde el lado del desempeño: cuando el token agrupa varias variables del mismo instante, los mapas de atención resultan poco significativos.

El modelo instrumental de este trabajo, un ConvTransformer de índices, resuelve ambas limitaciones tratando cada una de las n variables como un token independiente, de manera que la dimensión n es configurable y no queda atada al dominio de aplicación, y calculando la atención multi-cabeza entre esos tokens y no entre posiciones espaciales ni pasos temporales, lo que produce explícitamente una matriz $A \in \mathbb{R}^{n \times n}$ por cada cabeza y capa. El requisito de diseño que impone el framework sobre ese componente es uno solo: todas las variables deben codificarse con el mismo procedimiento antes de calcular la atención, para que la matriz resultante refleje relaciones del fenómeno y no una capacidad de codificación desigual entre variables. Cómo se implementa esa codificación —arquitectura del encoder, número de capas, dimensiones concretas— es una decisión del caso de estudio y no de la formulación general.

La razón de esta estructura es directa. Si la atención se aplicara entre posiciones espaciales, la matriz tendría tamaño $HW \times HW$, sería inmanejable y no admitiría lectura relacional entre variables. Al aplicarla entre las n variables, la matriz tiene tamaño $n \times n$ y cada celda A_{ij} admite una interpretación concreta: cuánto la variable i atiende a la variable j al producir su predicción. La arquitectura es además agnóstica al dominio, porque los n tokens pueden ser índices espectrales, sensores industriales o variables de proceso, y lo único que se exige es que cada variable tenga una representación procesable por el encoder.

4.2. Agregación entre capas

Un modelo con L capas y h cabezas produce $L \times h$ matrices de atención, de modo que hace falta un procedimiento para obtener una sola que represente al modelo completo. Se emplea para eso el attention rollout de Abnar y Zuidema [22], que propaga la atención a través de las capas incorporando las conexiones residuales:

$$\tilde{A} = \prod_{\ell=1}^L (\alpha I + (1 - \alpha) \bar{A}^{(\ell)}), \quad (4.1)$$

donde $\bar{A}^{(\ell)}$ es el promedio de las h cabezas de la capa ℓ , la identidad I simula la conexión residual y α es la fracción residual. El resultado se normaliza por filas para que siga siendo estocástico. Los mismos autores advierten el límite del procedimiento: en un Transformer la información se mezcla progresivamente entre tokens al atravesar capas y conexiones residuales, con lo cual los pesos crudos dejan de corresponder de forma confiable a los tokens de entrada. El rollout atenúa

esa mezcla sin eliminarla, y esa es la razón de fondo por la que el grafo que se obtiene después debe tratarse como hipótesis sujeta a verificación y no como lectura directa del mecanismo interno.

4.3. Formalización del operador relacional

Sea un modelo de aprendizaje automático entrenado sobre un conjunto de datos,

$$M_\theta : X \rightarrow Y, \quad (4.2)$$

donde X es el espacio de entrada, Y el espacio de salida y θ los parámetros aprendidos. Durante el entrenamiento el modelo genera una representación latente

$$Z = M_\theta^L(X), \quad (4.3)$$

con Z el espacio interno aprendido por la red en una capa L . A partir de esa representación se construye la matriz relacional $A \in \mathbb{R}^{n \times n}$, donde cada elemento A_{ij} expresa la intensidad de interacción entre dos componentes latentes i y j . La matriz es agnóstica al dominio: el índice n puede recorrer índices espectrales, sensores industriales o variables de proceso sin que cambie nada de lo anterior.

Esa matriz se comporta como un operador relacional y debe cumplir tres propiedades para ser entrada válida del framework. Sus valores son no negativos, $A_{ij} \geq 0$. Sus filas suman aproximadamente uno, $\sum_j A_{ij} \approx 1$, lo que permite leerla como una cadena de Markov dirigida. Y es asimétrica, de modo que en general $A_{ij} \neq A_{ji}$ y la dirección de la relación queda codificada. Las tres en conjunto forman la condición de admisibilidad, y una representación que no las satisfaga queda fuera del alcance del framework mientras no se le aplique una adaptación explícita.

4.4. Qué se sabe sobre medir una explicación

Las técnicas necesarias para evaluar el resultado provienen de un cuerpo de trabajo cuya conclusión general es que casi ninguna medida de calidad puede adoptarse sin examinarla antes. Que un mecanismo interno sea legible no implica que gobierne la salida, según mostraron Rizzo et al. [2] al comparar atención y confianza como formas de saliencia sobre un mismo modelo, de manera que la fidelidad hay que medirla en cada caso.

La forma habitual de medirla consiste en perturbar una entrada y observar cuánto cae el desempeño, y ahí aparece un problema conocido. Una perturbación destructiva saca al dato de la distribución con la que el modelo fue entrenado, con lo cual lo que se termina midiendo es la fragilidad del modelo y no la relevancia de lo perturbado. Meng et al. [23] abordan ese defecto generando perturbaciones que permanecen dentro de la distribución mediante un modelo generativo, e identifican con ello menos características críticas para explicar la misma decisión. El análisis de Šimić et al. [10] agrega que la métrica de fidelidad más extendida presenta fallas cuando se traslada a series temporales, y que ningún método de perturbación resulta óptimo para todas las arquitecturas y conjuntos evaluados. Ambos resultados obligan a justificar la medida elegida en lugar de tomarla prestada.

Queda un tercer elemento, más sutil, que atañe al paso de una matriz continua a un conjunto finito de relaciones. Toda regla de corte es en sí misma una fuente de variación, y el fenómeno de fondo lo documentan Bogaert et al. [24] al comparar la variabilidad de explicaciones humanas con la de explicaciones generadas por modelos: dos configuraciones que coinciden en la predicción pueden diferir en la explicación, y en su experimento la discretización aumenta la coincidencia con

el juicio humano sin alterar las predicciones. Por eso el framework trata la regla de discretización como un parámetro cuyo efecto hay que medir, y no como una decisión de implementación que se fija una vez y se olvida.

4.5. Dominio del caso de estudio

El caso de estudio trabaja con índices espectrales derivados de imágenes satelitales. Las bandas, resoluciones e índices disponibles en la constelación Sentinel-2 constituyen la referencia técnica de las variables que forman los nodos del grafo [25], y su aplicación ya consolidada en el seguimiento agrícola de precisión [25] es parte de por qué se eligió este dominio como caso de validación. Estas variables son fuertemente colineales entre sí, condición que vuelve poco practicable establecer la estructura relacional por inspección directa y que explica el interés por obtenerla desde un modelo. La motivación de fondo no es solo predictiva: en las ciencias de la Tierra, donde se emplean estos índices, se espera que un modelo aporte conocimiento sobre el proceso subyacente y no solamente un pronóstico ajustado [1], exigencia que este dominio comparte con el resto de los que el framework busca abarcar.

5. METODOLOGÍA Y PLAN DE TRABAJO

5.1. Estado a la fecha de este informe

El trabajo avanza en tres etapas, y a la fecha de este informe dos están cerradas: la revisión sistemática, que recorrió el protocolo desde la formulación de la pregunta hasta la extracción de datos y dejó como producto el corpus de veinticinco referencias sobre el que se apoya el capítulo 3, y el diseño, con las transformaciones definidas, la condición de entrada válida explícita, el criterio de validación especificado pregunta por pregunta y la taxonomía de resultados formulada. Queda pendiente la etapa de validación, donde el diseño se pone a prueba y se concentra el resto del calendario: el criterio se fijó antes de mirar cualquier resultado, para que no termine acomodándose a lo que los datos entreguen.

5.2. Actividades y calendario

La tabla 5.1 detalla las actividades comprometidas. Las tres primeras filas corresponden a trabajo concluido y se incluyen para dejar constancia del punto de partida; el resto pertenece a la etapa de validación y aparece ordenado por dependencia, ya que cada pregunta del criterio solo tiene sentido sobre las relaciones que superaron la anterior, lo que deja poco margen para paralelizar.

Cuadro 5.1: Actividades del plan de trabajo, con periodo estimado y estado.

Actividad	Periodo	Estado
Revisión sistemática de literatura bajo protocolo PRISMA 2020	Hasta septiembre 2026	Concluida
Formalización de las transformaciones y de la condición de admisibilidad	Hasta septiembre 2026	Concluida
Especificación del criterio de validación y de la taxonomía de resultados	Hasta septiembre 2026	Concluida
Redacción del informe de avance	Septiembre 2026	En curso
Implementación del modelo alternativo y entrenamiento del conjunto de repeticiones	Octubre 2026	Pendiente
Evaluación de la estabilidad de las relaciones ante la inicialización del entrenamiento	Octubre 2026	Pendiente
Evaluación de la estabilidad ante el criterio de discretización	Octubre 2026	Pendiente
Contraste de las relaciones frente a la hipótesis nula	Noviembre 2026	Pendiente
Medición de la dependencia del modelo respecto de cada relación	Noviembre 2026	Pendiente
Evaluación de especificidad y compacidad de la hipótesis	Noviembre a diciembre 2026	Pendiente
Contraste contra referencias construidas fuera del modelo	Diciembre 2026	Pendiente
Aplicación de la taxonomía sobre los resultados obtenidos	Diciembre 2026	Pendiente
Validación sobre un conjunto sintético de estructura conocida	Enero 2027	Pendiente
Validación sobre un segundo dominio real	Enero a febrero 2027	Pendiente
Redacción del informe final	Marzo 2027	Pendiente

5.3. Dependencias y riesgos

Tres dependencias condicionan ese calendario: el cómputo, porque evaluar la estabilidad exige entrenar varias decenas de modelos equivalentes y el costo por corrida determina cuánto puede avanzarse por semana; la disponibilidad del segundo dominio, que exige acceso al modelo y no solo a su matriz, para poder repredecir bajo condiciones alteradas; y la construcción del conjunto sintético, única referencia externa con la que cuente el trabajo, dado que no existe una topología verificada de antemano entre las variables del caso de estudio. El riesgo principal es que la cadena se detenga temprano y ninguna relación supere la primera o segunda pregunta; aun así no invalidaría el trabajo, porque cada caída diagnostica la relación entre atención y estructura, y ahí sirve el conjunto sintético, para verificar si detecta una estructura conocida.

6. PROPUESTA

6.1. Planteamiento

Conviene fijar primero qué se persigue, porque de eso depende cómo leer todo lo que sigue: el fin de este trabajo no es explicar un modelo de aprendizaje automático, sino producir una hipótesis relacional sobre el fenómeno que ese modelo aprendió a representar. Explicar el modelo —decir qué relación pesó al producir una salida— es un paso instrumental hacia ese fin, no el fin en sí mismo. Un procedimiento que se detuviera en la explicación del modelo dejaría el trabajo a medio camino, sin haber dicho nada todavía sobre las variables del fenómeno.

De ahí una decisión que conviene declarar explícita: el framework no abre el modelo que ya está en producción ni lo modifica. En su lugar entrena un modelo alternativo sobre los mismos datos con los que se entrenó el principal, construido desde el inicio para que su representación interna sea legible. El único requisito general sobre ese modelo alternativo es que trate cada variable del fenómeno como un token, de modo que la atención se calcule entre variables y no entre posiciones espaciales ni entre instantes de tiempo —el mismo principio que Liu et al. [6] formalizaron al invertir las dimensiones del Transformer estándar para el pronóstico multivariado. El ConvTransformer de índices que describe el capítulo 4 es una instancia concreta de ese requisito, construida para el caso de estudio de esta tesis; el framework no queda atado a esa arquitectura ni a los detalles de su implementación, sino al principio de tokens por variable que la sostiene.

De ese modelo alternativo se obtienen, capa por capa y cabeza por cabeza, tantas matrices de atención como produzca la arquitectura. Agregarlas en una sola matriz de interacción A exige un procedimiento, y el que emplea este trabajo es el *attention rollout* de Abnar y Zuidema [22], que propaga la atención a través de las capas incorporando la conexión residual (ver capítulo 4 para la formalización completa). El objeto de estudio pasa a ser esa matriz A y no el modelo que la produjo.

A eso se suma el tratamiento de la inestabilidad. Como una sola corrida no informa sobre su propia reproducibilidad, el entrenamiento del modelo alternativo se repite muchas veces con inicializaciones distintas, y la unidad de análisis deja de ser la matriz de una corrida: pasa a ser la frecuencia con que una relación reaparece entre repeticiones. El desempeño predictivo del modelo alternativo se reporta apenas como condición de admisibilidad —para verificar que la representación de la que se extrae A proviene de un modelo que efectivamente aprendió algo— y no como resultado que competir: los trabajos que sí compiten en desempeño lo hacen bajo protocolos de *benchmarking* establecidos [6], [17], y esta propuesta no reclama superioridad predictiva sobre ellos. Sobre la estructura que sobrevive al filtro de repeticiones operan las tres transformaciones que siguen.

6.2. Transformación matriz-grafo

La primera transformación del framework corresponde a

$$\Phi : A \rightarrow G, \tag{6.1}$$

donde $G = (V, E, W)$ es un grafo ponderado dirigido. El conjunto de nodos es $V = \{v_1, v_2, \dots, v_n\}$, y cada nodo representa una variable interpretable del fenómeno. El conjunto de aristas se define como

$$E = \{(v_i, v_j) : A_{ij} > \tau\}, \quad (6.2)$$

donde τ corresponde al criterio de selección con que se extraen las relaciones relevantes; su forma concreta se fija al ejecutar el procedimiento, y no en esta etapa de diseño.

Esta transformación convierte una representación continua de interacciones en una estructura discreta e interpretable, al precio de introducir un criterio de selección que es en sí mismo una fuente de variación —incluso cuando la predicción del modelo no cambia—, tal como documentan Bogaert et al. [24] al comparar explicaciones humanas y generadas por modelos. Esa es precisamente la razón por la que el criterio de validación exige, más adelante, que una relación sobreviva al cambio de ese criterio de selección para no confundirse con un artefacto de la elección.

6.3. Transformación grafo-hipótesis

La segunda transformación corresponde a

$$\Psi : G \rightarrow H, \quad (6.3)$$

donde H representa una hipótesis relacional compacta. Formalmente, $H = (E_H, \mathcal{R})$, con E_H el conjunto reducido de relaciones relevantes y $\mathcal{R}$ su interpretación semántica asociada. La extracción de la hipótesis puede plantearse como un problema de compresión,

$$\min_H |H| \quad \text{sujeto a} \quad I(H, G) \geq \gamma, \quad (6.4)$$

donde $I(H, G)$ mide la información preservada entre el grafo original y la hipótesis reducida, y γ es el mínimo aceptable. El objetivo, por lo tanto, no es recuperar todos los circuitos internos del modelo sino obtener una explicación estructural mínima capaz de conservar la información relevante. Esa doble exigencia, que la estructura sea fiel y a la vez lo bastante pequeña para poder inspeccionarse, es la misma que plantean Mekonnen et al. [11] al evaluar sus reglas por fidelidad y por tamaño de forma simultánea.

6.4. Interpretación metodológica

El framework completo puede expresarse como la composición

$$X \rightarrow M_\theta \rightarrow A \xrightarrow{\Phi} G \xrightarrow{\Psi} H \xrightarrow{F} \mathbb{R}, \quad (6.5)$$

donde F evalúa la fidelidad de la hipótesis respecto del comportamiento del modelo. La figura 6.1 despliega esa misma cadena indicando qué objeto entrega cada eslabón y en qué punto interviene el consenso entre repeticiones. Esta formulación es la que permite diferenciar la propuesta de lo que ya existe.

Frente a los modelos matemáticos tradicionales, la diferencia está en el origen de la estructura: allí es impuesta previamente mediante supuestos, y aquí emerge desde la representación aprendida. Frente a los métodos de interpretabilidad clásicos, como el de Chefer et al. [12], la diferencia está en el objeto entregado: esos métodos calculan un mapa de relevancia por variable de entrada, no relaciones entre variables. Frente a la estructura que se aprende como parámetro del propio modelo, como el grafo por escala temporal de Cai et al. [15], la diferencia es que aquí la estructura se obtiene de un modelo construido para ser legible desde el inicio y no como subproducto de




Figura 6.1: Composición del framework: de los datos del fenómeno a una hipótesis relacional evaluada por fidelidad.

una arquitectura orientada a predecir. Frente a la interpretabilidad mecanicista, que recupera circuitos internos mediante intervención directa sobre las activaciones, la diferencia es de objetivo y de costo: ese enfoque explica el modelo y exige acceso a sus estados internos, tal como se aprecia al contrastar con el trabajo de Kalnāre et al. [5], mientras que aquí el modelo se usa como instrumento para hablar del fenómeno sin necesidad de intervenirlo. Y frente a los grafos causales construidos con conocimiento previo, como el de Zhao et al. [16], la diferencia es que la propuesta no requiere una estructura causal preexistente, con lo cual evita sesgar la explicación hacia un conocimiento que podría estar incompleto.

De ahí se sigue la posición del framework respecto de las dos familias descritas en la introducción. No reemplaza al modelo matemático ni al modelo de aprendizaje automático: se ubica entre ambos, usando la capacidad de ajuste del segundo para descubrir estructura, y devolviendo esa estructura en la forma explícita y discutible que caracteriza al primero.

6.5. Criterio de validación

Una hipótesis obtenida de esta manera no vale por haber sido obtenida. El criterio que decide si merece sostenerse se organiza como una cadena de preguntas acumulativas, donde cada relación debe superar una antes de que tenga sentido hacerle la siguiente, y donde los criterios de aceptación quedan declarados antes de ejecutar el procedimiento y no después de ver los resultados.

La primera pregunta es si la relación reaparece al reentrenar el modelo alternativo con inicializaciones distintas, ya que una relación presente en una sola corrida informa sobre esa inicialización y no sobre el fenómeno. La segunda es si sobrevive al cambiar el criterio de discretización, porque una relación que depende del corte elegido es un artefacto de esa elección. La tercera es si aparece con más frecuencia de la que cabría esperar por azar, para lo cual se contrasta contra una hipótesis nula explícita en lugar de confiar en que una frecuencia alta hable por sí sola. La cuarta es si el modelo efectivamente depende de esa relación para predecir, lo que separa las relaciones que el modelo usa de las que solo están presentes en su representación interna sin gobernar la salida —una distinción necesaria porque, como muestran Rizzo et al. [2] al comparar atención y confianza como dos formas de saliencia sobre un mismo modelo, que un mecanismo interno sea legible no implica que sostenga la predicción. La quinta verifica que el efecto sea específico de la relación examinada y que la hipótesis resultante se mantenga acotada en tamaño.

La cuarta pregunta exige, además, cuidado metodológico al medirla: no cualquier perturbación de la entrada sirve para aislar si el modelo depende de una relación o solo la contiene. Meng et al. [23] muestran que una perturbación que se aparta de la distribución de entrenamiento termina midiendo la fragilidad del modelo y no la relevancia examinada; Šimić et al. [10] agregan que ningún método de este tipo funciona igual de bien para toda arquitectura, por lo que la elección debe

justificarse en cada caso y se deja para la etapa de ejecución.

El orden importa tanto como las preguntas. Cuando las medidas de calidad se aplican en paralelo informan que algo falla sin señalar dónde, que es la crítica documentada sobre su falta de convergencia [14]. En una cadena ordenada, el punto donde una relación cae constituye por sí mismo el diagnóstico de por qué cayó. Ese diagnóstico se traduce en cuatro lecturas posibles: una relación estructural genuina, que se mantiene entre repeticiones, resiste el cambio de corte, resulta improbable bajo la hipótesis nula y muestra que el modelo depende de ella; un atajo predictivo, que el modelo sí usa pero que no encuentra respaldo fuera de él; un artefacto de la arquitectura, estable y frecuente pero sin efecto sobre la predicción; y ruido, descartado ya en la primera pregunta. Distinguir las dos primeras categorías es lo que motiva todo el diseño, y recoge directamente la evidencia de Lapuschkin et al. [4] sobre modelos con métricas excelentes que resuelven la tarea por una vía que nadie había mirado.

6.6. Alcance de esta etapa

Conviene declarar qué queda dentro y qué queda fuera de lo que este informe compromete. Dentro está el diseño del framework, la formalización de sus transformaciones, la especificación del criterio de validación y la taxonomía anterior. Fuera queda la ejecución sobre el caso de estudio, que corresponde al periodo del capítulo 5, y con ella cualquier afirmación sobre resultados. El framework tampoco reclama mejoras de desempeño predictivo ni pretende reconstruir el mecanismo interno completo del modelo, sino una descripción estructural mínima que pueda ponerse a prueba.

En cuanto a la transferencia a otros dominios, la pregunta relevante no es sobre el fenómeno estudiado sino sobre el eje de la atención del modelo disponible en cada situación, y admite tres respuestas distintas según el caso. Hay dominios de aplicación directa, donde ya existe una representación relacional entre variables de la que puede partirse, como las redes de sensores espacio-temporales que documentan Altieri et al. [20] o la reconstrucción de dependencias entre sensores industriales de Zhang et al. [7]. Hay dominios que requieren adaptación, donde existe atención accesible pero su eje no son las variables nombradas, situación de los modelos de Bouaziz et al. [8] y Zhou et al. [21]. Y hay dominios que requieren un modelo nuevo, donde la estructura viene impuesta de antemano en el espacio latente en lugar de emerger de una representación entrenada, como en el trabajo de Spuler et al. [19]. El caso de estudio de esta tesis es solo uno de esos escenarios posibles, y el criterio para elegir un segundo dominio de validación se decide en cada situación concreta, según qué tan cerca esté de alguna de las tres respuestas anteriores: no hay una regla única ni un orden fijo de condiciones que el framework imponga de antemano, porque el diseño está pensado precisamente para adaptarse a la situación que se le presente y no para operar sobre un único tipo de dato.

7. CONCLUSIONES PRELIMINARES

La revisión sistemática deja una conclusión bastante nítida sobre el estado del campo. Obtener una estructura relacional desde un modelo de aprendizaje automático está resuelto por varias vías: hay trabajos que la aprenden como parámetro del modelo, otros que la reciben como conocimiento previo y otros que la obtienen interviniendo las activaciones. Lo que no aparece en el corpus revisado es un procedimiento para sostener una estructura obtenida de una representación aprendida en los casos, que son la mayoría, donde no se dispone de una referencia externa contra la cual compararla. Esa ausencia es la que da sentido a la propuesta y define su alcance.

El aporte de esta etapa es un diseño y no un resultado, y conviene decirlo con precisión para no prometer más de lo entregado. Están formalizadas las transformaciones que llevan de la matriz de interacción al grafo y de este a la hipótesis compacta —incluida la agregación entre capas mediante *attention rollout* [22]—, está explícita la condición que debe cumplir una representación para ser entrada válida, está especificado el criterio de validación con sus condiciones fijadas antes de ejecutarlo, y está formulada la taxonomía que separa relación genuina de atajo predictivo, artefacto y ruido. Nada de eso se ha ejecutado todavía sobre el caso de estudio, este documento no reporta resultados experimentales, y la ejecución completa es el contenido del periodo calendarizado en el capítulo 5.

Sobre el planteamiento de fondo, el trabajo sostiene que el espacio entre los modelos matemáticos rígidos y los modelos de aprendizaje automático opacos puede ocuparse sin renunciar a ninguna de las dos virtudes. La flexibilidad se obtiene dejando que un modelo alternativo, entrenado sobre los mismos datos, encuentre la estructura sin que nadie se la imponga; la transparencia se recupera exigiendo que esa estructura se enuncie de forma discreta, acotada y sometida a un criterio de rechazo declarado de antemano. Esa combinación es lo que el documento defiende, y responde a una exigencia que no es exclusiva de este dominio: en las ciencias de la Tierra en particular se espera que un modelo aporte conocimiento sobre el proceso subyacente y no solamente un pronóstico ajustado [1].

Del propio corpus salen tres advertencias que afectan cómo habrá que interpretar lo que se obtenga, y quedan anotadas aquí antes de la ejecución. La primera es que buena parte de la ganancia atribuida a los Transformers en pronóstico de largo plazo podría provenir del mecanismo de parcheo y no de la atención entre variables [18]; la propuesta no queda invalidada, porque no reclama que la atención mejore el desempeño, pero sí queda obligada a no presentarla como fuente privilegiada de conocimiento sin mostrarlo. La segunda es que el único caso del corpus donde la atención recupera un mecanismo verificable lo hace por coincidencia con una frecuencia que la teoría ya predecía [21], es decir, como hallazgo puntual y no como procedimiento repetible. La tercera es sobre la referencia externa: el trabajo mejor validado dispone de la topología física real de la instalación que modela [7], y entre los índices espectrales derivados de Sentinel-2 que emplea este caso de estudio [25] no existe nada equivalente, con lo cual el conjunto sintético de estructura conocida deja de ser un complemento del plan y pasa a ser su única referencia externa. A ellas se suma una advertencia sobre cómo medir la propia fidelidad: una perturbación que saca el dato de la distribución de entrenamiento termina midiendo la fragilidad del modelo y no la relevancia de lo perturbado [23], lo que el criterio de validación de esta propuesta ya incorpora.

Queda además una limitación del propio protocolo de revisión, que se declara porque afecta la trazabilidad del corpus: el paso final desde los registros elegibles hasta las referencias incluidas

se resolvió por juicio de relevancia documentado caso por caso, sin umbral cuantitativo explícito, y formalizarlo queda pendiente. En una línea parecida, el corpus documenta que dos configuraciones que coinciden en la predicción pueden diferir en la explicación [24], lo que sugiere reportar la variabilidad entre repeticiones como parte del resultado y no tratarla como ruido a suprimir. Aplicado a este trabajo, significa que el reporte final debería incluir cuántas relaciones cayeron en cada punto de la cadena y no solo cuáles sobrevivieron.

REFERENCIAS

- [1] M. Reichstein et al., «Deep learning and process understanding for data-driven Earth system science», *Nature*, vol. 566, n.º 7743, págs. 195-204, 2019. DOI: 10.1038/s41586-019-0912-1
- [2] M. Rizzo, C. Conati, D. Jang y H. Hu. «Evaluating the Faithfulness of Saliency-based Explanations for Deep Learning Models for Temporal Colour Constancy». arXiv: 2211.07982.
- [3] D. Slack, S. Hilgard, E. Jia, S. Singh y H. Lakkaraju, «Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods», en *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 2020, págs. 180-186. DOI: 10.48550/arXiv.1911.02508
- [4] S. Lapuschkin, S. Wäldchen, A. Binder, G. Montavon, W. Samek y K.-R. Müller, «Unmasking Clever Hans Predictors and Assessing What Machines Really Learn», *Nature Communications*, vol. 10, n.º 1, pág. 1096, 2019. DOI: 10.48550/arXiv.1902.10178
- [5] M. Kalnāre, S. Kitharidis, T. Bäck y N. van Stein. «Mechanistic Interpretability for Transformer-based Time Series Classification». arXiv: 2511.21514.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», en *International Conference on Learning Representations*, 2024. DOI: 10.48550/arXiv.2310.06625
- [7] Y. Zhang, Y. Lu, D. Li, S. Bader y E. Zio, «Dynamic Causal Graph Network for Reliable Pipeline Leak Detection», *Reliability Engineering & System Safety*, vol. 275, pág. 112795, 2026. DOI: 10.1016/j.ress.2026.112795
- [8] M. Bouaziz, A. Ben Abbes, M. El Koundi e I. R. Farah, «ConvLSTM-GCN-Transformer: Spatiotemporal graph-attention model for vegetation index map forecasting», *Expert Systems with Applications*, vol. 314, pág. 131596, 2026. DOI: 10.1016/j.eswa.2026.131596
- [9] S. Harikrishnan, «Instability and interpretability discrepancies between CNNs and vision transformers in keratoconus detection», *Pattern Recognition Letters*, vol. 204, págs. 107-112, 2026. DOI: 10.1016/j.patrec.2026.03.020
- [10] I. Šimić, E. Veas y V. Sabol, «A comprehensive analysis of perturbation methods in explainable AI feature attribution validation for neural time series classifiers», *Scientific Reports*, vol. 15, 2025. DOI: 10.1038/s41598-025-09538-2
- [11] E. T. Mekonnen, L. Longo y P. Dondio, «A global model-agnostic rule-based XAI method based on Parameterized Event Primitives for time series classifiers», *Frontiers in Artificial Intelligence*, vol. 7, 2024. DOI: 10.3389/frai.2024.1381921
- [12] H. Chefer, S. Gur y L. Wolf, «Transformer Interpretability Beyond Attention Visualization», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, págs. 782-791. DOI: 10.48550/arXiv.2012.09838
- [13] F. Zhou et al., «Understanding Transformer-Based Classifications of Medical Text Using a Large Language Model for the Attribution of Feature Importance», *JMIR Medical Informatics*, vol. 14, e81644, 2026. DOI: 10.2196/81644

- [14] S. Stassin, V. Corduant, S. A. Mahmoudi y X. Siebert, «Explainability and Evaluation of Vision Transformers: An In-Depth Experimental Study», *Electronics*, vol. 13, n.º 1, pág. 175, 2024. DOI: 10.3390/electronics13010175
- [15] W. Cai, Y. Liang, X. Liu, J. Feng e Y. Wu, «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, págs. 11 141-11 149, 2024. DOI: 10.48550/arXiv.2401.00423
- [16] S. Zhao, H. Yang, Z. Wang, F. Khan y Q. Wang, «A causal-guided graph transformer with interpretability analysis for process fault diagnosis», *Journal of Loss Prevention in the Process Industries*, vol. 102, pág. 106 022, 2026. DOI: 10.1016/j.jlp.2026.106022
- [17] D. Villaboni, A. Castellini, I. L. Danesi y A. Farinelli. «SENTINEL: Multi-Patch Transformer with Temporal and Channel Attention for Time Series Forecasting». arXiv: 2503.17658.
- [18] P. Tang y W. Zhang. «Unlocking the Power of Patch: Patch-Based MLP for Long-Term Time Series Forecasting». arXiv: 2405.13575.
- [19] F. Spuler, M. Kretschmer, M. A. Balmaseda, M. Gudoshava y T. G. Shepherd, «Disentangling Regional Impacts of Joint Teleconnections Using Causal Representation Learning», *Journal of Climate*, vol. 39, n.º 17, págs. 5173-5192, 2026. DOI: 10.1175/JCLI-D-25-0700.1
- [20] M. Altieri, M. Ceci y R. Corizzo, «An end-to-end explainability framework for spatio-temporal predictive modeling», *Machine Learning*, vol. 114, n.º 4, 2025. DOI: 10.1007/s10994-024-06733-6
- [21] X. Zhou, J. Sun, J. Zhao y F. Shuang, «Explainable AI in Rotorcraft Aerodynamics: Autonomous Discovery and Dynamic Tracking of Vortex Ring State Mechanisms via Vision Transformers», *Aerospace*, vol. 13, n.º 7, pág. 590, 2026. DOI: 10.3390/aerospace13070590
- [22] S. Abnar y W. Zuidema, «Quantifying Attention Flow in Transformers», en *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, Association for Computational Linguistics, 2020, págs. 4190-4197. DOI: 10.48550/arXiv.2005.00928
- [23] H. Meng, C. Wagner e I. Triguero, «Explaining time series classifiers through meaningful perturbation and optimisation», *Information Sciences*, vol. 645, pág. 119 334, 2023. DOI: 10.1016/j.ins.2023.119334
- [24] J. Bogaert, L. Escoufflaire, A. Descampe, C. Fairon, M.-C. de Marneffe y F.-X. Standaert, «Explanation Variability in Text Classification: Humans vs. LLMs», *Computational Linguistics*, págs. 1-31, 2026. DOI: 10.1162/COLI.a.624
- [25] J. Segarra, M. L. Buchailot, J. L. Araus y S. C. Kefauver, «Remote Sensing for Precision Agriculture: Sentinel-2 Improved Features and Applications», *Agronomy*, vol. 10, n.º 5, pág. 641, 2020. DOI: 10.3390/agronomy10050641